

第一篇【贝叶斯优化与高维代理模型篇】

本篇覆盖论文

01、02、07、11、13。这一条主线回答一个问题：当一次 CFD 贵得要命时，下一个点该算在哪里？
从校准采集函数（CR-EI），到多保真并行分配（Filter-GEI），再到 126 维下被迫改换门庭的代理进化（GSDE）与子空间聚合（DA-EGO），最后以「多保真也会骗人」这一反直觉发现（EMFS / MSFO）收尾。

过桥 A · 从第零章到第 01

讲：问题已经清楚，答案从「下一次采样」开始
第零章结束时，你手里只有一个问题，没有算法：

在高维、昂贵、无导数的黑箱里，下一个点该算在哪里？

从现在起，第一篇（第 01-05

讲）给出第一条主线答案：让每一次采样更聪明。

你将依次遇见	它专治的病
第 01 讲 CR-EI	采样「瞎逛」
第 02 讲 Filter-GEI	机房「空转」
第 03 讲 GSDE	高维下 GP「失明」
第 04 讲 DA-EGO	整屋翻修太贵
第 05 讲 EMFS	多保真「后期假优」

阅读纪律（本篇通用）：

1. 先读开场 90 秒的三句口诀；
2. 图看懂了再啃〔式〕；
3. 深潜框可跳，知识不丢；
4. 章末自测做不出来，回到心智图，不要硬背符号。

下一页反派登场，它的名字叫瞎逛。

【第01讲】CR-EI：贝叶斯优化为什么会“瞎逛”——过度探索的发现与校准（论文 01）

【靶】开讲前（5 分钟）：用 预习向导 Prompt 让 AI 帮你建立直觉框架，再开始读正文。

本讲开场 90 秒

上讲闪回（第零章）：叶片设计是 HEB 问题——维数高、每次 CFD 贵、没有导数。全书都在问：下一笔预算该砸哪？

本讲反派：「瞎逛」——采样次数已经很多，算法却在明显很差的空白区打转，不出来。

只要带走 3 句口诀：

1. 病根是 $z \leq 0$ ：不确定度 σ 大的地方，未必是好地方。
2. 治则是改 ξ ，不是改 σ ：前人爱调探索权重；本文抬高“当前最优”这根尺子。
3. 近处 CEI、远处 REI，EI 瞎了再换班：值班经理三规则。

「第01讲心智图：CR-EI 治瞎逛」



第01讲心智图：z、瞎逛与 CR-EI 调度（手绘笔记版）（mindmap）

看图三秒：中间是参数 z ；左边 $z>0$ 是“有希望的街区”；右边 $z\leq 0$ 是工业区瞎逛；底部三条口诀请先刻住，后面只是在证明它们。

本讲赌注：若放任 $z\leq 0$ 的瞎逛，有限 CFD 预算会永久巡逻工业区。

1. 生活与物理直觉引子：三种“找最佳餐厅”的策略



restaurant map 口味地图： $z>0$ 好街区 vs $z\leq 0$ 工业区瞎逛

指读：左有希望区、右工业区巡逻；CR-EI 改的是尺子 ξ 与近远分工。

假设你搬到一座新城市，给自己定了死规矩：30 天内，找到全城最好吃的那家面馆。

每一顿饭都要花钱、花时间——这顿饭就是一次昂贵实验。放到叶片设计里，它对应动辄几小时的一次 CFD。

你口袋里的钱，只够吃大约几十顿。于是策略选择，比“爱吃辣还是爱清汤”更要命。



找面馆三策略漫画（restaurant comic，教学比喻）

指读：左格人死守小巷（河对岸的神店永远没机会）；中格人专钻空白工业区（反复确认“这儿难吃”）；右格人手里有一张口味地图——颜色深的是已知好吃，问号是不确定。

策略 A · 纯开发（exploitation）

找到一家还不错的，就天天去，只在附近小巷换着吃。

风险：全市第一在河对岸，你这辈子不会知道。

策略 B · 纯探索（exploration）

专挑地图上空白的地方。

风险：空白区常常是没人去的工业区，你只是在验证“确实难吃”。

策略 C · 聪明折中

维护一张“口味地图”：

- 已知好吃的街区 → 猜附近也可能好吃；

- 空白处 → 标成“不确定”，不确定越大，越值得去试试。

贝叶斯优化里的期望改善（Expected Improvement, EI），就是策略 C 的数学版。

本讲要讲的，是策略 C 里一个藏了二十年的陷阱：地图用着用着，会把你系统性、持续地推进工业区——而且还可能永远出不来。我们给它起个绰号：瞎逛。

生活元素	工程元素	本讲符号（先混个眼熟）
面馆坐标	设计变量	x
口味得分	性能（如 $-L/D$ 、损失）	y
口味地图的“估计均分”	代理模型预测均值	$\hat{y}(x)$
地图上的“不确定带宽”	预测标准差	$\sigma(x)$
目前吃过的最高分	当前最优（incumbent）	ξ
要不要再去这家的冲动	期望改善	$EI(x)$

先猜后揭：若算法开始专挑“地图上最空白、但也最可能难吃”的点，病在地图 (o) 还是在尺子 (ξ)？

揭晓在 §3：主流改 σ，本文改 ξ。

策略 C 的藏二十年陷阱（加长）：

口味地图用着用着，会系统性把你推进工业区：好区被采密后 σ

变小，差区反而更空、σ 更大，EI 听空白的话。


这不像偷懒，像勤奋——所以叫瞎逛更阴。郭振东等指出过度探索与过度开发是一对病，只治贫不够。

2. 叶轮机械中的真实工程死穴：算不起，但停不下

把面馆换成叶片。现场是这样的：

周五下班前，组长丢来一句话——「下个型号的叶型，预算只够再跑几百次 CFD，给我一个比现在更好的外形。」


你面对的并不是一道可以慢慢推的数学题，而是一个昂贵黑箱：



昂贵黑箱：设计参数、CFD 求解器与预算三者的关系（手绘笔记版）

指读：左边塞进几何参数 x，中间黑箱是 CFD，右边吐出一个数 y。箭头上写着时间与金钱。

- 给一组几何参数 x（厚度分布、安装角、端壁型线……），求解器吐出性能 y；
- 一次高保真 CFD 可能要几小时到几十小时；
- 一个设计周期能负担的次数往往只有几百到几千次 [原文 P07 §1]；
- 设计变量轻易超过 100 维 [原文 P07 摘要]。



预算沙漏 hourglass：每一次采样都必须值回票价

指读：上半斗是有限次数，每粒沙标着“1 小时”；下半斗是高维空间里稀疏的点。红章的意思只有一个——点错一次，就烧一笔不可回收的预算。

在这种现场，EI 成为贝叶斯优化的默认配置，是因为它直接回答：

「这个点，值得再花一次 CFD 吗？」

可 EI 有个久治不愈的毛病：次数已经很多了，结果却卡在次优解上。

此前学界常说：那是过度开发——算法太贪，只在当前最优附近打转。

郭振东等指出：这个解释只对了一半。还有一半叫过度探索，而且更阴险——它长得像“勤奋地探索”，其实是在工业区永久巡逻。这就是本讲反派瞎逛。

预算沙漏的第二读法：

上半斗是次数，下半斗是维数稀疏。

EI 默认很香，是因为它直接回答「值不值得再花一次」；


但当 z 掉到明显负值，它回答的其实是「空白大不大」，不是「空白处好不好」。

CR-EI

的贡献，是把值班经理请回来：瞎了换班，而不是继续勤奋地错。

3. 数学公式从 0 到 1 推导：一个参数 z，两种病

【AI】卡壳？数学推导看不懂时，不要硬啃。把你的困惑发给 AI，用苏格拉底引导 Prompt。先自己想 5 分钟，再让 AI 一步步追问。



z pocket card 速记：z 正负与瞎逛换班

指读：z >> 0 过度开发；z << 0 瞎逛；治则抬 ξ、近 CEI 远 REI。

先把公式关掉。只用餐厅语言说一遍：

你的口味地图在每个位置给出两个量：

估计均分 $\hat{y}$ ，和 不确定带宽 σ。

你还记得目前吃过的最高分 ξ。


定义一个无量纲分数 z，衡量“最高分比估计均分高多少个不确定带宽”。

z 很大 → 地图很有把握地说“这儿不如已经最好的那家” → 你只会已在已知好区精耕（贪）。


z 很小（很负） → 你几乎只听带宽 σ 的话 → 专往空白处钻；而空白处常常是差区 → 瞎逛。

下面用符号把这话说死。本讲正文只留 3

条核心式；偏导与积分细节在深潜框，不挡路。



一个参数 z、两种病：z < -3 过度探索与 z > 3 过度开发（手绘手账版）



高斯过程后验与期望改善采集函数（中文标注版）

指读 GP 图：上半幅是后验均值与置信带——样本越密，带子越瘦；下半幅是 EI 曲线，它在“预测更好”与“更不确定”之间拉扯。后面 CEI/REI/GEI 改的都是这张图上的东西。

3B. 本讲符号卡（建议截图留存）

符号	人话	备注
x	设计点（面馆坐标）	向量
$\hat{y}(x)$	地图估计均分	越小/越大取决于问题方向；本文按原文最小化语境理解
$\sigma(x)$	不确定带宽	只反映稀疏，不反映好吃
ξ	目前最优观测	incumbent
z	$(\xi - \hat{y})/\sigma$	全文题眼
Φ, ϕ	标准正态的“累积”与“钟形密度”	可先当两个已知函数
$EI(x)$	去 x 的“期望改善冲动”	
y_{PBS}	当前最优设计点上的值	
$\xi_{\text{Calibrated}}$	被抬高的尺子	CEI 用
δ_1, δ_2	近处/远处地盘开关	互补
y_T	已有样本的中位数	瞎逛预警线
$n_{\text{Breakthrough}}$	连续突破计数	调度用

3C. 主路径只要三条式

核心式 ① — z 的定义

$$[式] \quad z = (\xi - \hat{y}(x)) / (\sigma(x))$$

回译： z 是“比当前最优好（或差）多少个不确定带宽”。

停顿：若 σ 很大，分母大， z

的绝对值容易变小——地图会更听“空白”的话。

核心式 ② — EI 的人话版（结构）

EI 可以写成（原文式 5、式 11）：

$$[式] \quad EI(x) = \sigma(x) \cdot (z \Phi(z) + \phi(z)) = \sigma(x) \cdot EI^*(z)$$

回译：

- 前面的 $\sigma(x)$ 像“冲动的音量”；

- 括号里的 $EI^*(z)$ 像“这首歌好不好听”。

z 决定你唱的是开发调还是探索调。

核心式 ③ — 符号约束（为什么瞎逛不出来）

$$[式] \quad z > 0 \Rightarrow \hat{y}(x^*_{EI}) < \xi \text{（被关在有希望区）}; \quad z \leq 0 \Rightarrow \text{对 } \hat{y} \text{ 无任何约束}$$

回译：

$z > 0$ 时，EI 选出的点，预测值必须优于当前最优——像只在“可能超越冠军”的街区转。

$z \leq 0$ 时，这道门消失。再叠加“ σ 大的地方往往是早期没人去的差区”，算法就会系统性地、持续地冲进工业区。

两种病（看图 L01_s3，不必先啃偏导）：

病名	z 的极端	行为	餐厅版
过度开发	$z > 3$	几乎只跟 $\hat{y}$ 走	死守已经好吃的小巷
过度探索（瞎逛）	$z < -3$	几乎只跟 σ 走	永久巡逻工业区

论文里的触目惊心例子 [原文 P01 § 3.1]：

6 维 Hartman6 上，EI 用 LHS 撒 36 个初始点后很快陷入过度探索（ z 在 -5 附近抖， $\sigma^2/\sigma^2_{\text{max}} \approx 1$ ， $\max EI$ 从 10-5 掉到 10-20）。若按“ $\max EI$ 小于阈值就停”，得到 -2.7890，而真全局最优是 -3.0424。

附带结论（仍属主路径）： $EI(z)$ 在 $z > 0$ 近似线性好优化，在 $z \leq 0$ 指数衰减、极难优化。所以保持 $z > 0$

是明智的*；但简单加阈值停机又会早熟。这就是 CR-EI 要解的死结。

【深潜 | 可跳过】完整解析式、偏导与梯度权重

完整写法（原文式 5）：

$$[式] \quad EI(x) = \int_{-\infty}^{\infty} (\xi - Y) dF_Y = (\xi - \hat{y}) \Phi(z) + \sigma \phi(z)$$

偏导（用于理解权重，不必会推）：

$$[式] \quad \partial EI / \partial \hat{y} = -\Phi(z), \quad \partial EI / \partial \sigma = \phi(z)$$

负梯度：

$$[式] \quad -\nabla EI(x) = \Phi(z) (\partial \hat{y} / \partial x) - \phi(z) (\partial \sigma / \partial x)$$


- 第一项开发、第二项探索；权重分别是 $\Phi(z)$ 、 $\phi(z)$ 。
 - $z > 3$ 时 $\Phi \gg \phi \rightarrow [式] \quad -\nabla EI|_{z>3} \approx \Phi(z) (\partial \hat{y} / \partial x) \rightarrow$ 过度开发
 - $z < -3$ 时 $\phi \gg \Phi \rightarrow [式] \quad -\nabla EI|_{z<-3} \approx -\phi(z) (\partial \sigma / \partial x) \rightarrow$ 过度探索
- 读完可以回到正文 § 4，不影响值班手册。

4. 算法控制流：EI / CEI / REI 三兄弟如何轮班

核心思想，一句就够：

别再拧 σ 那个旋钮了（前人都拧过）。改 incumbent 这根尺子 ξ 。

CR-EI：三个采集函数轮流出手



EI / CEI / REI 三者分工与翼型 L/D 对比（cei rei roster，数值见 [原文 P01 Table 2]）

指读：三人分工——EI 主攻、CEI 守近处、REI 侦远处；右侧比分是后文伏笔。

(a) CEI — 校准 EI：治瞎逛，强化近处开发

把尺子从 y_{PBS} 抬高到 $\xi_{\text{Calibrated}} > y_{\text{PBS}}$ ，重算 z ：

$$[式] \quad \tilde{z} = (\xi_{\text{Calibrated}} - \hat{y}(x)) / \sigma(x), \quad CEI(x) = \sigma(x) (\tilde{z} \Phi(\tilde{z}) + \phi(\tilde{z}))$$

回译：许多原来 $z \leq 0$ 的点，被抬尺后变成

$z > 0$ ，重新关回“有希望区”。

再叠加距离窗 δ_1 ：只接受落在当前最优点附近的建议（ $\epsilon < \|x - x_{\text{PBS}}\| \leq d_T$ 时为 1， ϵ 常取 0.001 防重复采样）。

(b) REI — 重校准 EI：治死守小巷，强化远处探索


$$[式] \quad REI(x) = CEI(x) \cdot \delta_2 (\|x - x_{\text{PBS}}\|), \quad \delta_2 = 1 - \delta_1$$

回译：REI 只在近处地盘之外取点。 δ_1 与 δ_2

像两块互补的城区规划——CEI 管近，REI 管远。

(c) 值班经理手册 — CR-EI 调度（原文式 17-18）

预警线 y_T = 已有样本目标值的中位数；计数器 $n_{\text{Breakthrough}}$ 看 EI 是否还在“打破纪录”。



CR-EI 值班经理手册三分支决策树（schedule tree）

指读：从上往下互斥优先。绿：EI 正常只采 EI；黄：有进展则 EI+REI 并行；红：EI 建议点比中位数还差 → 判定瞎逛，改 CEI+REI。

1. $n_{\text{Breakthrough}} = 0$ （EI 正常）→ 只采 EI：

$$[式] \quad x_{\text{new}} = \{x_{EI}\}$$

2. $n_{\text{Breakthrough}} > 0$ （仍有进展）→ EI 与 REI 并行：

$$[式] \quad x_{\text{new}} = \{x_{EI}, x^*_{REI}\}$$

3. $y(x_{EI}) \geq y_T$ （疑似瞎逛）→ 改 CEI + REI：

$$[式] \quad x_{\text{new}} = \{x_{CEI}, x_{REI}\}$$

餐厅版回扣：

EI 像主探路员；REI 是派去河对岸的侦察兵；一旦主探路员开始在工业区空转（建议点还不如半数已吃过的店），经理立刻把主探路员换成"只准在冠军店附近精耕"的 CEI，同时保留远侦察。

一句话记住：EI 顺就让它跑，同时派 REI 远眺；EI 一瞎逛，就换成 CEI 收近 + REI 保远。

CEI/REI 餐厅排班表：

|角色|地盘|一句话||CEI|冠军店附近|抬尺，只精耕有希望区||REI|河对岸|保远方选项，防死守小巷||EI|全局默认|正常时主攻|
经理看中位数预警线：建议点还不如半数已吃过的店 → 判定瞎逛换班。

5. 实验验证与量化突破

先报胜负：在 7 个基准和翼型工程题上，CR-EI 相对经典 EI 变体，更快、更稳、更好。

算例一：7 个基准函数（每算法 20 次独立运行；对手 EGO / PEI / GEI / E3I）

函数	EGO	PEI	GEI	E3I	CR-EI
Shekel4 成功率	17/20	20/20	6/20	14/20	20/20
Trid10 成功率	14/20	10/20	13/20	20/20	20/20

原文结论：除 10 维 Trid10 外，CR-EI 在其余 6 个基准上均以更快收敛取得最优 [原文 P01 Table 1 / § 4.3] 。

算例二：低速翼型（工程级）

- 参数化：GAN + UIUC 翼型库，13 维；
- 求解器 XFOIL；Re = 1.8×10^6 、Ma = 0.01、AoA = 0°；
- 目标：最大化升阻比 L/D（实现为最小化 -L/D）；每组 10 次运行。

指标	EGO	PEI	GEI	E3I	CR-EI
均值 ± 标准差	-239.34 ± 8.60	-240.66 ± 6.41	-240.70 ± 4.57	-242.20 ± 4.48	-246.34 ± 3.56
中位数	-241.44	-242.74	-240.82	-241.92	-248.09

体感换算（只读两格就够）：

- 相对 EGO，平均 L/D 提升 2.92% [由 Table 2: $(246.34 - 239.34) / 239.34$] ；
- 标准差 8.60 → 3.56，离散度降 58.6% [由 Table 2] ——不是"平均好看一点"，而是十次里次次更稳。对要签字画押的工程设计，这比均值更救命。

参数敏感性：距离参数 α 、incumbent 参数 β 。Camel6 / Hartman6 扫描显示 $\beta = 0.1$ 综合最优； β 越大越抗瞎逛，但搜索区膨胀，过大则约束作废 [原文 P01 § 4.5] 。

翼型工程读法加长：

均值更好：平均 L/D 更香。

标准差下降：十次独立运行更挤在一起——签字要的是可重复，不是一次运气。

$\beta = 0.1$ 是综合甜点：越大越抗瞎逛，过大搜索区膨胀约束作废 [原文 P01 § 4.5] 。

6. 审稿人批判与承前启后

把软肋放上可信度刻度（0 = 完全不信，5 = 可当默认工具）：

维度	打分	人话
机理清晰度	4	z 的故事完整、好讲
实验充分度	4	基准 + 翼型，有对照
超参稳健	2	β 、 d_T 、 α 要调； $\beta = 0.1$ 不保证可迁移
理论保证	1	无收敛证明 / regret bound
维数外推	2	天花板约 10 维；真叶栅 100+ 维时 GP 本身先垮
对 GP 质量依赖	2	$\hat{y}$ 、 σ 若糊，调度全糊

可以攻击的点（保留原文力度）：

1. 超参： α 、 d_T 、 β ； d_T 绝对距离、高维下欧氏距离会"挤成一团"。
2. 无理论保证。

3. 维数天花板 ~10；真叶栅 100+ 维时，"抬 ξ " 救不了 GP 失明。
4. 切换逻辑绑在 GP 质量上。

承前：站在 EGO 的 EI 上，用"调 incumbent"统一审视 GEI（调 σ 权重）、E3I（Thompson 样本最优当 ξ ）、PEI（伪 EI）。

启后（下一集预告）：

- 第 02 讲（Filter-GEI）：值班切换思想，搬进"专家+实习生"多保真并行——反派变成集群空转。
- 第 03-04 讲（GSDE / DA-EGO）：本讲 10 维天花板撞墙后，高维必须换门庭。
- 第 08 讲（GTO）：本讲 GAN 13 维翼型，后面升级为梯度反推的生成式迁移。

可信度刻度使用说明：

4 分机理 = 可以教；2 分超参 = 换题要重调；1 分理论 = 别指望 regret bound。

10 维天花板写在这里，是为了让你读到 03/04 时知道：不是 CR-EI 变笨，是 GP 舞台塌了。

附：三调度口令速查

信号	动作
EI 正常	只采 EI
仍有突破	EI + REI 并行
建议点差于中位数	CEI 守近 + REI 保远

餐厅版：主探路员一进工业区空转，经理立刻换人，远侦察不停。

附：从 CR-EI 走向全书

下一站	你带走的问题
02 Filter-GEI	并行与多保真时，谁配见专家？
03-04	10 维天花板破了怎么办？
05	多保真后期是否开始撒谎？
06+	合法形状与场预测、实验信任

本讲是「下一笔预算砸哪」的第一课；后面所有课都在改场景，不改这个母问题。

母问题回声：读完任何后讲，用一句话回答「下一笔预算砸哪」。答不出，说明开场母问题断了，请回第 01 讲。

附：z 的餐厅速记卡

z	人话	风险
$\gg 0$	很有把握不如冠军	过度开发
≈ 0	边界	需调度
$\ll 0$	几乎只听空白	瞎逛

治：抬 ξ 、近 CEI、远 REI、瞎了换班。

翼型算例的工程读法：均值更好是「平均更香」；标准差下降是「十次里更稳」。对要签字的设计，稳往往比均值多 0.1 更救命。数字与出处以 § 5 表为准 [原文 P01 Table 2] 。

调度树口袋卡：绿 EI；黄 EI+REI；红 CEI+REI。口袋卡贴显示器，公式放深港。

附：开场母问题检查单（全书通用）

读完任意后讲，用 30 秒回答：

1. 本讲的「一次评估」有多贵？
 2. 下一笔预算砸在采样、代理、还是实验？
 3. 失败模式（反派）若赢了，报表会不会仍看起来很绿？
- 答不出第 3 问，说明还在被利用率/云图欺骗。

章末：30 秒复述 · 自测 · 元数据

30 秒复述稿（可朗读）：EI 用 z 在已知好与空白之间折中。 $z \leq 0$ 时约束消失，空白又常是差区，于是瞎逛。CR-EI 不拧 σ 而抬 ξ ，CEI 守近、REI 探远，按是否突破中位数换班。翼型上它均值更好也更稳。

自测（先做再对答案）：

1. 为什么说 σ 大不等于"那里值得去"？
2. CEI 与 REI 的地盘如何用 δ_1 、 δ_2 划分？

3. 三调度里，哪一条专门对付瞎逛？

▼ 点开看参考答案

1. σ 只反映样本稀疏，不反映目标好坏；早期好区被采密后，差区反而更空、 σ 更大。2. $\delta_1=1$ 近处 (CEI)； $\delta_2=1-\delta_1$ 远处 (REI)。3. 第3条： $y(x^*_EI) \geq y_T$ 时改 CEI+REI。本讲元数据（读完再看，不挡故事）

项	值
规范编号	01
原始文献	Structural and Multidisciplinary Optimization, 2021, 64: 3549–3567
DOI	10.1007/s00158-021-03038-3
作者	Zhendong Guo, Yew-Soon Ong, Haitao Liu
本地原文	s00158-021-03038-3.pdf
证据等级	A（本地原文逐句可查）
反派绰号	瞎逛
主比喻	30 天找面馆

动手任务

任务：用 code/optimizer.py 的 cr_ei_step 函数，在 2 维 Branin 函数上跑一次 CR-EI，记录三轮调度模式（EI / EI+REI / CEI+REI）各自被触发了几次。

产出文件：your_notes/experiments/L01_CR_EI_experiment.md

验收标准：文件存在且包含：① 你实际运行的代码片段 ②

三轮调度模式的触发记录 ③ 你对“为什么第 X 轮触发了

CEI+REI”的一句话解释

【AI】做完后：用主动回忆 Prompt 做补漏，再用批判收尾 Prompt 做深度加工。

沉淀清单

学完本讲，你应该产出以下文件：

- your_notes/knowledge_cards/L01_CR_EI.md — 知识卡片（用模板）
- your_notes/experiments/L01_CR_EI_experiment.md — 动手任务记录
- 个人 Prompt 库中新增 ≥ 2 个 Prompt（预习 + 批判收尾）

【第02讲】Filter-GEI：老专家与实习生——多保真并行优化怎样把钱花在刀刃上（论文 02）

【靶】开讲前（5 分钟）：用预习向导 Prompt 让 AI 帮你建立直觉框架，再开始读正文。

本讲开场 90 秒


上讲闪回：上讲（CR-EI）：EI 会瞎逛；治则是改 ξ 、近 CEI 远 REI。值班经理管「下一笔预算砸哪」。

本讲反派：「集群空转」

只要带走 3 句口诀：


1. 实习生（LF）铺路，老专家（HF）拍板
2. 滤波门槛 T 决定谁配见专家
3. 相关高就严进，相关差就放宽

主比喻：设计公司：老专家 vs 实习生



Filter 值班卡：相关高严进、相关差放宽

指读：左列相关高→ ω 严进；右列相关差→放宽；中间门槛 T 分流 HF/LF。



第02讲心智图：Filter-GEI 左多保真建模右并行批滤波（mindmap）

看图三秒：与技术双图同构——左多保真建模（大量 LF × 铺路 + 少量 HF ● 校准）；右并行批滤波（绿点过门槛 T 入选，灰叉被滤除）；底条口诀「实习生铺路、老专家拍板 / T 决定谁进批 / 相关高严进、相关差放宽 / 别让机房空转」。细节曲线见下节 filter_gei_multifidelity_parallel_zh。本讲赌注：没有门槛的并行，只是让专家更快地淹没在平庸图里。

1. 生活与物理直觉引子：老专家与实习生

想象你经营一家设计公司，手下有两类人：

- 老专家：画图精准、结论可靠，但时薪 3000 元，一天只能出 1 张图；
- 实习生：速度快、一天能出 10 张图，时薪 300 元，但图纸常有偏差，只能看个大概趋势。

现在要做一个设计招标。聪明的做法显然不是“所有图都让老专家画”（太贵），也不是“全让实习生画”（不可靠）。你会让实习生先铺开画一批，把大致方向摸出来；老专家只在最关键的几张图上出手。

这就是多保真优化（Multi-Fidelity Optimization, MFO）的全部思想。在叶轮机械里：

- 低保真（LF）= 粗网格 CFD（1.2 万单元）、无粘 Euler、二维简化模型；
- 高保真（HF）= 细网格 RANS（10 万单元）、三维全环、带转捩模型。

本文的工程算例中，LF 与 HF 的成本比是 0.1——也就是说，一次高保真的钱能做十次低保真 [原文 P02 §4.3]。

但这里有个二十年的老问题：每轮迭代里，到底哪些点该让老专家（HF）看，哪些点交给实习生（LF）？这就是本文所说的 sample assignment（样本分配）问题。

把招标周历摊开看一遍（趣味回扣）：

工作日	实习生（LF）	老专家（HF）	经理在想什么
周一	狂出 10 张草图	休息	「先把地形摸出来」
周二	再出 10 张	挑 1 张精修	「只在苗头处砸钱」
.....			若没有滤波，专家会被灌进一堆平庸图

若没有 Filter 那道门槛，并行批次里会混进大量「GEI 看起来花哨、其实不配见专家」的点——机房灯亮着，智慧在空转。这就是反派集群空转。

周历回扣：若无 Filter，并行批会塞满「GEI 花哨但不配见专家」的点——灯亮着，智慧空转。

先猜后揭：若本讲反派「集群空转」赢了，你的下一笔 CFD/实验预算会怎样被浪费？揭晓贯穿 §3-§5。

生活元素	工程元素	符号
主比喻侧	低/高保真	y_{LF}/y_{HF}
主比喻侧	缩放因子	ρ
主比喻侧	差异函数	Z_{DF}
主比喻侧	广义EI/幕次	GEI, g

把「时薪」再算一遍（趣味加长）：


若招标只要 30 张「可信图」，全专家贵、全实习险。混合策略的关键不是拍脑袋比例，而是每一张专家图都对应一个过了门槛的理由——这正是 T 存在的意义。

失败剧本：经理取消滤波器，「GEI 前 10 名全给专家」。两周后专家工位堆满平庸图，实习生反而闲着。机房利用率很高，有效学习率很低。这就是集群空转的生活版。

招标周的正确打开方式：


周一 LF 铺图；门槛决定周二专家看谁；周末对照无滤波是否假快速。周历本身就是算法。

2. 叶轮机机械中的真实工程死穴：串行加点浪费了整个机房



parallel timeline 串行空转 vs 并行批墙钟

指读：上条串行等核；下条 HF+LF 同批；空转是调度病。



串行加点导致集群空转：串行与并行的时间对比（手绘笔记版）

指读：这张图是本讲工程死穴的一张图版本。

传统的多保真 EGO 类算法（如 augmented-EI、VF-EI）有一个共同特征：每轮迭代只加一个样本。

问题在两方面：

1. 贵：一次 CFD
几小时，一个设计周期几百次调用，串行下来是几个月；
2. 浪费：现代计算集群一晚上能同时跑几十个 CFD 作业，单点串行加点意味着大部分核在空转。

同时，已有算法在决定“这个点用 HF 还是 LF”时，往往只看相似性与成本比，没有利用“LF 模型到底靠不靠谱”这一关键信息。本文要解决的，正是这两个痛点：把保真度分配做对，

并且一次分配一批。

现场感：周五下班前组长要数——你面对的不是可以慢慢推的练习题，而是算错一次就不可回收的预算。

串行 vs 并行的时间线（人话）：

串行：HF₁ 完成 → 更新模型 → HF₂ → ... 墙钟 ≈ n × t_{HF}。

并行（本讲）：同一轮抛出 {HF 批, LF 批}，墙钟 ≈ max(t_{HF}, t_{LF})——前提是足够许可证。

软肋里「并行收益绑许可证」不是抬杠，是工程事实。

集群空转的两种形态：

- 1) 算法串行加点，核在等；
- 2) 算法并行但无 Filter，HF 批次塞满假尖子，核在忙，智慧仍空转。第二种更危险，因为利用率报表是绿的，学习曲线却在骗人。


3. 数学公式从 0 到 1 推导

【AI】卡壳？数学推导看不懂时，不要硬啃。把你的困惑发给 AI，用苏格拉底引导 Prompt。先自己想 5 分钟，再让 AI 一步步追问。

先把公式关掉，用主比喻说一遍：


设计公司：老专家 vs 实习生

本讲反派是「集群空转」。下面公式是这句话的展开；每条核心式尽量带回译。知识总量不删——深潜只是阅读路径，不是垃圾桶。



Co-Kriging 多保真建模与 Filter-GEI 的滤波阈值 T（手绘手账版）

Filter-GEI：把钱花在刀刃上（论文 02）



多保真建模与滤波并行加点（filter GEI multifidelity parallel，中文标注版）

上图是本讲全部数学的「一张图版本」：左图是多保真建模——低保真模型（橙虚线）便宜但有偏，用大量低保真样本铺路、少量高保真样本（蓝点）校准；右图是 Filter-GEI 的并行加点——GEI 值超过滤波阈值 T 的候选（绿点）才入选并行批，其余被滤除（灰叉）。正文推导的 ω/T 公式，改的就是右图这道「门槛」。

3B. 本讲符号卡（建议截图留存）

符号	人话	备注
y_{LF}/y_{HF}	低/高保真	成本比≈0.1
ρ	缩放因子	
Z_{DF}	差异函数	修正后还差多少
GEI, g	广义EI/幕次	g 大偏探索
T	滤波门槛	谁配见专家
ω	相关权重	相关高→严进

【引】先认符号再读公式；主文核心式有「回译」，装不下的细节仍在正文完整保留（不删知识）。

3C. 主路径公式与推导（知识全保留）

第一步：多保真代理模型 Co-kriging

把 LF 与 HF 都当成随机过程：〔式〕 $Y_{LF}(x) = \mu_{LF} + Z_{LF}(x)$, $Y_{HF}(x) = \mu_{HF} + Z_{HF}(x)$

回译：上式是主路径构件——先记住它在算法里负责哪一步，再抠每一个符号。

关键假设是 HF 可以写成"LF 的缩放 + 一个差异函数"：〔式〕 $y_{HF}(x) = \rho \cdot y_{LF}(x) + Z_{DF}(x)$

其中 ρ 是缩放因子， Z_{DF} 是差异函数（discrepancy function），专门负责刻画"LF 修正后仍与 HF 差多少"。这样，LF 负责大趋势，DF 负责补差距，两套高斯过程拼成一个联合协方差矩阵（原文式 4-6）。

第二步：基线采集函数 GEI（广义期望改善）

经典 EI 有个毛病：太贪恋当前最优附近。Schonlau（1997）把它推广为带幂次 g 的 GEI：〔式〕 $E[l(x)^g] = s^g g \sum_{k=0}^{g-1} \frac{(-1)^k}{k!} C(g, k) u^{g-k} T_k$, $u = (f_{\min} - \hat{y}(x)) / (s(x))$

〔式〕 $T_0 = \Phi(u)$, $T_1 = -\phi(u)$, $T_k = -u^{k-1} \phi(u) + (k-1) T_{k-2}$

g 越大，越偏向全局探索； $g=1$ 时退化为经典 EI。取若干个不同的 g ，就同时得到一批"有的爱开发、有的爱探索"的候选点——这天然适配并行加点。

第三步：核心创新——给 GEI 装一个"滤波器"（原文式 10-12）

定义一个阈值：〔式〕 $T = \omega \cdot y_{HF-\min} + (1-\omega) \cdot y_{HF-\text{mean}}$

其中 $y_{HF-\min}$ 是当前最优， $y_{HF-\text{mean}}$ 是历史加权平均：〔式〕 $y_{HF-\text{mean}} = (1/(\text{iter}) \sum_{i=0}^{\text{iter}} ((1)/(ni) \sum_{j=1}^n \{y_{HF-i,j}\}))$

而权重 ω 由 HF 与 LF

的相关性自适应决定——这是全文最漂亮的一笔：〔式〕 $\omega = (1)/(1 + (\delta^2_{DF}/\delta^2_{LF})^{0.5})$

物理含义请务必记住：

- 当 LF 与 HF 高度相关时，差异函数 Z_{DF} 的方差 δ^2_{DF} 相对很小 $\rightarrow$ 分母趋近 1 $\rightarrow \omega \rightarrow 1 \rightarrow$ 阈值 T 贴近当前最优值 $y_{HF-\min} \rightarrow$ 只有非常好（优于 T ）的点才配用 HF，采样极度聚焦于局部开发。
- 当 LF 与 HF 相关性差时， δ^2_{DF} 大 $\rightarrow \omega$ 变小 $\rightarrow$ 阈值 T 贴近历史均值 $\rightarrow$ HF 的投放区域被放大，避免在不可信的 LF 引导下钻牛角尖，转而加强全局探索。

第四步：候选点去重叠

不同 g 给出的候选点可能重合，直接一起投进 Co-kriging 会让协方差矩阵病态。本文用层次聚类（逐个合并距离最小的一类，直到类间最小距离大于阈值 d_T ）把重叠点聚掉。

4. 算法控制流

【引】值班手册：先看「什么情况下走哪条分支」，公式是对白速记不是主角。

每轮迭代：

1. 用现有 HF + LF 样本拟合 Co-kriging 代理
2. 用多个不同 g 的 GEI，生成一批候选点（既含开发点，也含探索点）
3. 层次聚类去掉重叠候选点
4. 计算自适应权重 $\omega = 1/(1 + (\sigma^2_{DF}/\sigma^2_{LF})^{0.5})$
5. 计算阈值 $T = \omega \cdot y_{HF-\min} + (1-\omega) \cdot y_{HF-\text{mean}}$
6. 分流：
预测值优于 T 的候选点 $\rightarrow$ 送 HF 仿真（贵，但值得）
其余候选点 $\rightarrow$ 送 LF 仿真（便宜，用于全局探索+降不确定性）
7. 一批 HF 与一批 LF 样本同时提交，并行计算

一句话记住：GEI 负责"去哪儿采"，滤波器负责"花多少钱采"。

主比喻回扣：把上面的分支再翻译成「设计公司：老专家 vs 实习生」——若某步在生活里说不通，多半是符号没对齐。

并行批的现场约束清单：

- 许可证 $\geq$ 批大小？否则自动降批。
- LF/HF 网格与求解器队列是否两条线？
- 相关 ω 是否每轮重算，还是冻结了过期相关？

阈值 T 在许可证不足时仍然值钱：它决定稀缺的 HF 名额给谁。

5. 实验验证与量化突破

「多保真成本账本」		
	HF	LF
样本数量	1,000	100,000
成本比例	0.95	0.05
常数因子	0.1	0.1
Filter 门槛 T		

cost ledger 多保真成本账本 HF/LF 与门槛 T

指读：成本比折算后，多花的 LF 是否换来更好的 HF 最优——读表先问假快速。

先报胜负：

先读结论句与最大那一格，再读全表；表是证据架不是背诵清单。

算例一：5 个基准函数（Forrester1a/1b、Hartman3+MA3、Ackley5+MA5、Hartmann6+MA6，最高 6 维；初始样本 HF=3×维数、LF=6×维数；统一用开源 ooDACE 工具箱）

观察点	结果
HF 样本本消耗	Filter-GEI 在 5 个算例上始终用最少的 HF 样本取得有竞争力的最优解；无滤波的 GEI-MFO 需要"significantly more HF samples"（原文自评用语，未给具体倍数） [原文 P02 § 4.2]
迭代次数	由于每轮并行加多样本，Filter-GEI 与 GEI-MFO 的迭代次数远少于单点的 EI-MFO
成功率	Filter-GEI 5 个算例全部成功；VF-EI 在 5 维 Ackley5 上仅 12/20；augmented-EI 在 6 维 Hartman6 上仅 12/20
稳定性	Filter-GEI 迭代次数波动明显小于 VF-EI 与 augmented-EI

[以上均出自原文 P02 § 4.2 与 Table 4]

算例二：GE-E3 涡轮静子叶片气动优化（工程级）

- 设计变量：7 个几何参数；HF 网格 100,701 单元，LF 网格 12,141 单元；
- 初始样本 42 LF + 21 HF（最近邻采样），终止条件为再消耗 35 个 HF 样本；独立运行 5 次；
- 代理模型交叉验证 CV-R² 全部 > 0.85，多数 > 0.95 [原文 Table 7]，说明 Co-kriging 拟合可信。

算法	达到最优所需迭代数	最优值(%) 均值±标准差	LF 样本消耗
Filter-GEI	13 ± 1	2.720 ± 0.0245	91 ± 10
GEI（无滤波）	8 ± 0	2.760 ± 0.0224	79 ± 2
EI	36 ± 0	2.732 ± 0.0192	77 ± 0
VF-EI	45 ± 3	2.748 ± 0.0239	51 ± 3
augmented-EI	51 ± 6	2.726 ± 0.0358	59 ± 9

[原文 P02 Table 8]

怎么读这张表（很关键，别读错）：

- GEI 只用了 8 次迭代就"收敛"了，但收敛到的是最差的最优值 2.760——没有滤波器时，HF 被挥霍在不太有希望的点上，看似快，实则跑偏。
- Filter-GEI 用 13 次迭代拿到全场最好的 2.720，而且 Min 值 2.70 是全场最低。
- 相比串行的 EI / VF-EI / augmented-EI（36 / 45 / 51 次迭代），Filter-GEI 的迭代次数只有它们的 1/3 左右——这正是并行加点的直接收益。
- 代价是：用了更多 LF 样本（91 vs 79）。但按 0.1 的成本比折算，多花 12 次 LF $\approx$ 1.2 次 HF 的钱，换来最优值从

2.760 降到 2.720，这笔账是划算的。

体感换算：把关键数字换成「工程师的周/月」或「一次签字的风险」——数字才进长期记忆。若原文给了墙钟时间或成本比，优先用原文换算。

账本精读（再钉一次）：

无滤波 GEI：迭代 8，最优 2.760（差）。Filter-GEI：迭代 13，最优 2.720（好）。

慢 5 轮迭代，换的是不跑偏。相对串行 36-51

轮仍是断崖优势。读表先问「快是真快还是假快」。

值班经理对照第 01 讲：01 看是否瞎逛；02 看 LF 还准不准。都是自适应指标，旋钮从 ξ 换成 ω -T。

6. 审稿人批判与承前启后

把软肋放上可信度刻度（0=完全不信，5=可当默认工具）：

维度	打分	人话
机理	4	ω -T 好讲
实验	4	基准+静子
超参	3	d_T/g 集
理论	2	启发式
维数	2	≤ 7 维
成本比入模	2	未进公式

可以攻击的点：

1. "并行"是算法层面的并行，实验是串行模拟的。真拿到工程现场，收益取决于你有多少个 CFD 许可证/核；很多单位恰恰卡在许可证数量上。
2. 成本比没有进入公式。 ω 只用了方差比 $\delta^2_{DF}/\delta^2_{LF}$ ，没有把 LF/HF 的实际成本比纳入。本文工程算例的成本比恰好是 0.1；若 LF 也很贵（成本比接近 1），多投 LF 的滤波策略就不一定划算了。
3. 阈值与权重的启发式本质。T 取"最优值与加权均值的凸组合"缺乏最优性证明； ω 的自适应也只有定性论证。
4. 维数量级有限：基准最高 6 维，工程算例 7 维。真正的多级叶栅是 100+ 维（见论文 07），Co-kriging 在高维下的建模能力本身就是瓶颈。
5. 隐含前提"LF 大体能捕捉 HF 趋势"。一旦这个前提在某块区域失效，滤波器反而会把 HF 集中投到被 LF 误导的区域——这正是论文 13（EMFS / MSFO）要处理的问题。

承前：建立在 Co-kriging（Forrester et al. 2007）与 GEI（Schonlau 1997）之上，思想直接继承自同组前作 论文 01（CR-EI）——"用一个自适应指标来决定这一轮怎么采样"。

启后：- 论文 13（EMFS / MSFO）：正面处理"LF 在某些区域反而误导优化"的场景，用 DBSCAN 找出多保真代理建不准的区域，在那里改建单保真代理；- 论文 07（GSDE）：把优化从"低维多保真+贝叶斯"推进到"126 维+代理辅助进化"；- 论文 11（DA-EGO）：把"自适应分配"从保真度维度迁移到子空间维度。

Table 8 再读（防假快速）：

无滤波 GEI：迭代少、最优差。

Filter-GEI：迭代略多、最优好。

串行基线：迭代是三级级。

读表顺序：最优值 → 是否跑偏 → 迭代 → LF 成本折算 [原文 P02 Table 8] 。

附：Filter 值班卡（可打印）

本轮信号	经理口令	对应公式角色
LF-HF 相关很高	「严进：只有尖子见专家」	$\omega \rightarrow 1$, T 贴 y_{HF-min}
LF-HF 相关崩了	「放宽：专家多看全局」	ω 变小, T 贴均值
候选点扎堆	「层次聚类去重叠」	防协方差病态
集群有空核	「HF 批 + LF 批同时交」	反派集群空转的直接解药

和 CR-EI 的对照表（请钉在显示器边）：

	第 01 讲 CR-EI	第 02 讲 Filter-GEI
反派	瞎逛	集群空转
自适应旋钮	ξ (尺子)	ω -T (门槛)
并行?	近 CEI + 远 REI 可并行	HF 批 + LF 批 并行
多保真?	通常单保真 GP	Co-kriging 标配

成本比 0.1 的心算模板：

多花 Δn_{LF} 次低保真 $\approx 0.1 \cdot \Delta n_{LF}$ 次高保真。

若最优值从 2.760 降到 2.720，问自己：这 0.040 个点，值不值那 1.2 次 HF 的钱？——原文 Table 8 的答案是值 [原文 P02 Table 8] 。

读表口诀：先看最优值，再看迭代数，最后看 LF 消耗。无滤波 GEI「迭代少但最优差」= 假快速。

附：并行加点的许可证现实

算法说「一批 HF + 一批 LF」时，现场常卡在：

- CFD 许可证数 < 批大小；
- 队列策略把并行拆回串行；
- LF 与 HF 网格流程不共享，调度摩擦大。

所以 § 6 软肋不是抬杠：并行收益是「算法可达上限 × 许可证可达上限」的乘积。Filter 仍值得做——即使批变小，门槛 T 依然决定谁配见专家。

附：相关高/低的经理台词

相关	台词	T 行为
高	「只有尖子见专家」	严，贴最优
低	「专家多看全局，防被带沟」	松，贴均值


附：Filter-GEI 上线前 10 分钟检查

1. 成本比是否仍约工程设定量级（本文算例 0.1） [原文 P02 § 4.3] ？
2. ω 是否每轮更新？冻结相关会让门槛过时。
3. 批大小是否超过许可证？超过则降批，不降门槛逻辑。
4. 对照无滤波 GEI：若「更快但更差」，记为假快速案例。
5. 相关崩塌时，HF 批是否自动放大探索——对应 ω 变小。

经理一句话：GEI 找点，Filter 分钱；并行是手段，不跑偏才是目的。

图卡：许可证墙


算法批大小 × 许可证/队列可达 = 实际墙钟收益。批可变小，门槛 T 逻辑不降——Filter 仍决定谁配见专家。



license batch wall：并行上限 = 算法批大小 × 许可证可达

图卡： ω -T 松紧旋钮

ω 高 → T 严（只有尖子见专家）； ω 低 → T 松（专家多看全局防带沟）。GEI 找点，Filter 分钱。



omega T knob: 相关高严进、相关差放宽的 Filter 旋钮

图卡：假快速

迭代少但最优差 =

假快速。读表口令：先看最优值，再看迭代数，最后看 LF 消耗；无滤波 GEI 常栽在这里。



false fast: 迭代少但最优差的无滤波假快速

章末：30 秒复述 · 自测 · 元数据

30 秒复述稿（可朗读）：多保真是实习生铺路、专家拍板。Filter-GEI 用多 g 的 GEI 出一批点，门槛 T 分流 HF/LF； ω 听相关——高严进、差放宽。静子上它比无滤波更不跑偏，比串行少大量轮次。反派是集群空转。

自测（先做再对答案）：

1. 成本比 0.1 意味？多 12 次 LF $\approx$ 几次 HF？
2. T 变严 HF 怎样？谁拧松紧？
3. 相关差为何放宽 T？

▼ 点开看参考答案

1. 一次 HF $\approx$ 十次 LF；12 次 LF $\approx$ 1.2 次 HF。2. 更少点见专家； $\omega \rightarrow 1$ 时 T 贴最优。3. LF 不可信时严进会被假尖子骗；放宽让 HF 看全局。本讲元数据（读完再看，不挡故事）| 项 | 值 | :--- | :--- | 规范编号 | 02 | 原始文献 | Structural and Multidisciplinary Optimization, 2021, 64: 1457–1468 | DOI | 10.1007/s00158-021-02931-1 | 作者 | Zhendong Guo, Qineng

Wang, Liming Song, Jun Li（西安交通大学）|| 本地原文 | s00158-021-02931-1.pdf || 证据等级 | A（本地原文逐句可查）|| 反派绰号 | 集群空转 || 主比喻 | 设计公司：老专家 vs 实习生 |

动手任务

任务：用 code/multifidelity.py 的 filter_gei_threshold 函数，分别计算 $\sigma^2_{DF} = 0.01$ 、0.1、1.0、10.0 时的 ω 和 T 值（固定 $\sigma^2_{LF} = 1.0$ 、 $y_{HF-min} = 2.0$ 、 $y_{HF-mean} = 5.0$ ），观察 ω 和 T 的变化趋势。

产出文件：your_notes/experiments/L02_Filter_GEI_threshold.md

验收标准：文件存在且包含：① 4 组 (σ^2_{DF} , ω , T) 的计算结果表格 ② 你对“为什么 σ^2_{DF} 越大 T 越靠近均值”的一句话解释

【AI】做完后：用主动回忆 Prompt 做补漏，再用批判收尾 Prompt 做深度加工。

沉淀清单

学完本讲，你应该产出以下文件：

- □ your_notes/knowledge_cards/L02_Filter_GEI.md — 知识卡片（用模板）
- □ your_notes/experiments/L02_Filter_GEI_threshold.md — 动手任务记录
- □ 个人 Prompt 库中新增 ≥ 2 个 Prompt

第二阶段：从第 03 讲开始，先学会看问题

这一页是本科生第一遍阅读的主路。第 03–20 讲的原稿仍保留，标为“论文深读”；第一遍不要把它们当教材正文逐字啃。

阅读规则

从第 03 讲开始，每一讲只完成四件事：

1. 说清楚工程上要花什么钱、要预测什么东西；
2. 找到本讲的失败模式；
3. 说清楚新方法改变了哪一个动作；
4. 用一句话解释实验结果，而不是背算法缩写。

看到矩阵、损失函数、网络结构或推导时，先问：“它在流程里负责什么？”答不出来就跳过，不要停在符号上。

先补五个过桥词

后面反复出现的词，先按下面的人话理解，不必追求严格定义：

词	第一遍理解
代理模型	用已有 CFD 结果训练出来的“便宜估分器”
高保真 / 低保真	更接近真实但更贵的计算 / 更快但可能有偏的计算
潜空间	把复杂形状换成少数几个更容易搜索的坐标
负迁移	旧任务经验不适合新任务，搬过来反而变差
神经算子	学习“输入条件 $\rightarrow$ 整个物理场”的快速近似器

本阶段所有算法名都先当作“解决哪一种失败模式的工具名”。第一遍不要求从缩写反推出完整数学定义。

第 03–05 讲：高维与多保真

第 03 讲：变量太多时，别把所有旋钮一起硬算

一台压机不是一个叶片，而是多排叶片互相影响的队伍。把每排的形状都放进设计方案后，旋钮会从十几个涨到一百多个；但 CFD 次数仍然只有几百到几千次。此时每个方向都没有足够样本，原来依赖“哪里不确定”的方法会失灵。

GSDE 的核心不是某个公式，而是换了工作方式：用一个较便宜的近似模型帮进化算法产生候选，再只把少数候选送去做真实 CFD。记住：高维时，代理模型不再负责全局指路，而是负责帮候选队伍少走弯路。

停读检查：为什么不能一排一排优化？因为前排改变会改变后排的来流，单排最优可能在整机里变差。

第 04 讲：分块可以省钱，但分错块更贵

面对一百多个旋钮，可以把它们分成几组轮流改。但有些旋钮互相牵制，必须放在一起；有些旋钮关系弱，可以分开。DA-EGO 做的事情，是根据新数据不断重画分组，而不是一开始拍脑袋分完。

记住：分解的目的不是把问题切碎，而是把真正互相影响的变量留在同一组。分错组会让每个小组都得到一个看似优秀、合起来却互相打架的答案。

停读检查：什么时候“不分组”反而更好？当变量之间的耦合很强、而错误分组会制造大量返工时。

第 05 讲：便宜模型可能会骗人

多保真方法同时使用粗网格和精细网格。粗网格便宜，适合大量试探；精细网格贵，但更接近真实结果。危险在于：粗模型在前期有用，到了后期可能把算法带向错误方向。

EMFS / MSFO 的主问题是“什么时候该相信便宜模型，什么时候必须花钱校验”。记住：低保真不是高保真的缩小版，而是一个可能改变排序的有偏意见。

停读检查：如果粗模型说 A 比 B 好，但精细模型多次说相反，下一笔预算应该投给校准，而不是继续扩大粗模型样本。

第 06–09 讲：把形状变成更容易学习的东西

第 06 讲：一个压缩空间不够，就换几种视角

原始叶片形状的旋钮太多，生成模型尝试把它压缩到一个更短的“设计坐标”。但不同形状规律未必能被同一套坐标表达，所以 GMFoO 同时使用多个潜在空间。第一遍只需理解：降维不是把信息凭空消灭，而是寻找更适合搜索的表达方式。

第 07 讲：把旧型号的经验搬给新型号

新型号往往没有足够样本，完全从零开始很贵。SW-VAE / KT-ASO 先从旧任务学习“哪些形状像好答案”，再把这些经验迁到新任务。迁移不是复制答案，而是复制有用的偏好；如果两个任务差异太大，旧经验也会误导新任务。

第 08 讲：生成模型能造形状，但不一定知道怎么反推

生成模型擅长从坐标生成形状，却不天然擅长从性能目标反推出坐标。GTO 的关键是给生成过程接上可优化的方向，让性能反馈能反过来推动形状变化。第一遍记住：“会生成”与“会优化”是两种能力。

第 09 讲：参数化的第一责任是保证形状合法

端壁形状不能只追求数学上的好分数，还要避免自交、尖角、不可制造和超出物理边界。VAE + NURBS 的价值首先是把搜索限制在较合理的形状集合里，然后才谈性能提升。

第 10–15 讲：从预测一个分数到预测整个物理场

这六讲只抓一个转折：早期方法问“这个形状得多少分”，后面的方法问“整个流场长什么样”。预测流场更难，但一旦预测足够快，就能重复用于优化、分析和设计迭代。

- 第 10 讲：神经算子把一次昂贵场计算变成快速近似预测；
- 第 11 讲：把叠加原理写进模型，减少网络自己摸索物理规律的负担；
- 第 12 讲：把相似原理和宽工况信息放进输入输出，避免模型只会背某一个工况；
- 第 13 讲：用 SHAP 追问“哪些设计变量真正影响结果”，把高维结果翻译成人能检查的因素；
- 第 14 讲：流体和结构会互相影响，不能只优化气动不管变形和受力；
- 第 15 讲：把局部预测扩展到子午面全景，重点是空间覆盖和跨工况泛化。

停读检查：为什么“预测得快”本身不是最终目标？因为快速但不守物理的模型，会把优化器更快地带到错误答案。

第 16–20 讲：回到实验与工程可信度

最后五讲不再追求更炫的算法，而是追问答案能不能在真实流动、真实制造和真实实验中成立。

- 第 16 讲：端壁二次流为什么会损失性能，以及造型和冷气如何共同作用；
 - 第 17 讲：数值优化的端壁方案能否在跨声速风洞里复现；
 - 第 18 讲：叶尖泄漏、摩擦和换热同时发生，单一指标可能掩盖代价；
 - 第 19 讲：制造偏差和来流波动会让标称最优变成脆弱方案；
 - 第 20 讲：冲击冷却和气膜冷却如何组合，以及不同冷却方案怎样比较。
- 这一篇的总问题是：一个漂亮的计算结果，经过工况变化、制造误差和实验测量后，还剩多少？

第一遍读完后的合格标准

不要求会推导、不要求记住缩写、不要求复现论文。只要能画出下面这条路线，并给每一步说出失败风险，就算完成第二阶段：

贵 CFD → 高维优化 → 便宜代理 → 生成/迁移 → 快速场预测 → 实验与不确定性

【书】以下第 03–20 讲原稿为论文深读层。第一遍阅读可跳过公式、实现细节与参数表。

【第 03 讲】GSDE：126 维的奇迹——为什么贝叶斯优化在高维叶栅面前必须让位（论文 07）

【靶】开讲前（5 分钟）：用预习向导 Prompt 让 AI 帮你建立直觉框架，再开始读正文。


本讲开场 90 秒

上讲闪回：Filter-GEI 把便宜评估用起来；维度 100+ 时 GP 先失明。第 01 讲 10 维天花板，本讲正面撞上。

本讲反派：「维数灾难」

只要带走 3 句口诀：

1. 高维别硬上 Kriging
 2. RBF 像橡胶膜，一次解线性系统
 3. 约一成预算换接近 DE 的增益（1500/20000，+1.104%/+1.115%）[原文 P07 Table 3]
- 主比喻：多排叶片是一支必须一起训练的隊伍



第 03 讲心智图：GSDE 高维 RBF 与 DE 紧耦合（mindmap）

看图三秒：中心 GSDE（126 维名义空间）；四支——放弃 GP 换 RBF、DE 紧耦合、7 排一起练（ $18 \times 7 = 126$ ）、预算约 1/13（[原文 P07 Table 3] 1500 vs 20000 次 CFD）；底条反派「维数灾难 + 评估太贵」。本讲赌注：在 126 维上硬上 GP，会先失明再空转；不换路线就只是在调一个看不见的核。

1. 生活与物理直觉引子：为什么不能“一排叶片一排叶片地优化”



team formation 7排叶片必须一起练

指读：排间传球（尾迹/旋流）改了，单排最优作废。

先建立一个物理直觉。压气机不是一个叶片在战斗，而是一支队伍在战斗。

空气从第1排叶片流过时，会在出口留下“尾迹”和“旋流”；第2排叶片吃到的，正是被第1排搅过的气流。如果你把第1排单独优化到极限，第2排的进口条件就变了，它的最优形状也随之改变——反过来又影响第1排。

这就是为什么原文强调：为充分考虑叶片排与级之间的相互作用，两级以上的叶栅必须同时优化 [原文 P07 摘要]。

代价是变量数的爆炸。先把被计数的对象钉死，再谈算法——否则「18维」「126维」只是口号。

① 几何对象 [原文 P07 § Geometry definition / Blade parameterization]

- 一台 3.5 级压气机：进口导叶 S0 + 三个低压级 R1/S1、R2/S2、R3/S3，共 7 排叶片。
- 级 ≠ 排：一对「转子+静子」常称一级；此处 3.5 级 = 1 排导叶 + 3 个完整级，排数跟原文，不靠常识瞎加。
- 优化对象是各排叶片的三维形状（NURBS 截面 + 积叠），7 排同时进同一个设计向量。

② 单排 18 维怎么来？（计数单位 = 优化器接收的独立标量，不是图上的点数） [原文 P07 Blade parameterization; Table 2]

口径警告：控制点是几何操纵对象；设计变量才是维数。一点可以固定（0 维）、只沿法向动（1 维）、或不进优化向量。

块	原文设定	独立标量
截面	根 / 中 / 尖 共 3 个二维截面，蒙皮成三维叶片	—
只动哪面	只调吸力面（压力面不动） [原文]	—
每截面控制点	吸力面 7 点：前缘、尾缘固定；其余 5 点沿拟合曲线法向主动移动；每点 1 标量	$3 \times 5 = 15$
积叠（弯/掠）	中截面周向平移 1 + 尖截面周向平移 1 + 尖截面轴向平移 1	3
单排合计	原文：18 design variables ... each blade	$15 + 3 = 18$

旧讲义曾缩写成「根/中/尖各 5 点 + 周向平移 + 轴向平移」，字面 $5 \times 3 + 1 + 1 = 17 \neq 18$ ——是把 3

个积叠标量收成两个词的转述错误，不是原文少一维。已按 PDF 纠正。

③ 整机 126 维

原文直接写明：7 排 $\times$ 每排 18 = 126

个设计变量（名义输入维） [原文 P07 Blade parameterization / 摘要 126 variables]。

乘法前提（原文均满足）：7 排都优化、每排同构

18、无跨排共享、此处未改报「有效自由度」。

〔式〕 单排 18（标量） $\times$ 7 排 = 126 维名义设计空间 [原文 P07]

而一个设计周期里，你只负担得起几百到几千次 CFD [原文 P07 摘要]。126 维里撒 1000 个点，平均每维约 $1000^{1/126} \approx 1.056$ 份——比「每个方向一分为二」还稀。

这就是所谓高维昂贵黑箱（High-dimensional Expensive Black-box, HEB）问题。

量级感再钉一根钉子：

一次 3.5 级压气机 CFD $\approx$ 1–1.5 小时 [原文 P07]。

DE 要两万次量级，就是两个月量级的墙钟时间；GSDE 用约 1500 次，大约一周。

你不是在省「几次点击」，你是在省工程师的整个季度。

队伍比喻回扣：第 1 排改理想、第 2

排入口就变了——单独优化每一排，在物理上就是做错题。

量级钉：单次 CFD 约 1–1.5 小时。DE 两月，GSDE 约一周——省的是工程师的季度。

先猜后揭：若本讲反派「维数灾难」赢了，你的下一笔 CFD/实验预算会怎样被浪费？揭晓贯穿 §3–§5。

生活元素	工程元素	符号
主比喻侧	维度 126	D
主比喻侧	三次 RBF	$\phi(r)=r^3$
主比喻侧	DE 参数	F, CR
主比喻侧	种群	N

队伍训练的反例：

「先把第 1 排优化到头再冻住」像让前锋单练冲顶却不让中场传球——进口边界一变，单排最优作废。两级以上必须同时优化，是流动耦合硬约束 [原文 P07 摘要]。

126 维体感：想「7 个人各 18

个动作要领，同一套战术」；代理是陪练，CFD 是正式出场次数。

126 维的第二个类比：

不是 126 个独立旋钮，而是 7 排叶片的联合战术板。

改第 1 排出口，第 2 排进口边界条件改写——单独最优是物理错题。

GSDE 用 RBF+DE 紧耦合，是因为 GP 在这个维度上先失明。

队伍战术板（加长）：

7 排叶片像 7 个位置：前锋的冲顶依赖中场传球角度。

你把第 1

排「优化到头」并冻结，等于让前锋在错误传球线路上练一百次——第 2 排进口旋流一变，单排最优当场作废。

原文坚持两级以上必须同时优化，不是方法论偏好，是流动耦合的硬约束 [原文 P07 摘要]。

126 维的第三个体感：

1000 个点摊在 126 维，每个方向约 $1000^{1/126} \approx 1.056$

份——连「一分为二」都做不到。

这时还问 GP「哪里不确定」，答案本身就不可信。

2. 叶轮机械中的真实工程死穴：高斯过程在高维下会“失明”



高斯过程在高维下的四个软肋与 GSDE 的路线选择（kriging blind in high dim, 手绘笔记版）

指读：这张图是本讲工程死穴的一张图版本。

第 01 讲的 CR-EI、第 02 讲的 Filter-GEI 都建立在高斯过程（Kriging）之上。它们很优雅，但有个致命的软肋：

问题	后果
GP 的协方差矩阵随样本数 n 呈 $O(n^3)$ 增长	样本上千就非常慢
高维下核函数的长度尺度难以估计	代理模型拟合失真

问题	后果
高维下“距离”失去区分度（距离集中效应）	“哪里不确定”这件事本身就不确定了
EI 类采集函数需要在整个空间上全局最大化	高维下这个子优化本身就很难

所以本文做了一个路线选择：放弃贝叶斯优化框架，改用进化算法（差分进化 DE）打底，把代理模型作为“局部搜索加速器”嵌入进去。这就是 GSDE（Generalized Surrogate-assisted Differential Evolution）。

现场感：周五下班前组长要数——你面对的不是可以慢慢推的练习题，而是算错一次就不可回收的预算。

为何 GSDE「不时髦也选 RBF」：GP 的 $O(n^3)$ 、高维核长度尺度、距离集中、EI 子优化——四只钉子。RBF 一次解线性系，是工程上的少即是多。

GP 四软肋 → GSDE 四对策（对照表）：

GP 软肋	后果	GSDE 对策
$O(n^3)$ 协方差	样本上千训练炸	局部 RBF，一次解线性系
高维长度尺度难估	拟合失真	不抠核超参，橡胶膜直接铺
距离集中	「不确定在哪」失效	代理嵌入 DE 生成基因，不靠全局 EI 寻峰
EI 子优化也难	采集函数本身卡死	进化 + 有限真 CFD 名额


选 RBF 不是赶时髦，是工程上的少即是多。

3. 数学公式从 0 到 1 推导


【AI】卡壳？数学推导看不懂时，不要硬啃。把你的困惑发给 AI，用苏格拉底引导 Prompt。先自己想 5 分钟，再让 AI 一步步追问。

先把公式关掉，用主比喻说一遍：

多排叶片是一支必须一起训练的队伍
本讲反派是「维数灾难」。下面公式是这句话的展开；每条核心式尽量带回译。知识总量不删——深潜只是阅读路径，不是垃圾桶。



3.5 级压气机 126 维设计空间与 GSDE 的代理辅助流水线（数值见 [原文 P07 Table 3]，手绘笔记版）



GSDE 与 DA-EGO 的高维路线对比 (GSDE and DA-EGO in high dimension, 中文标注版)

上图左半支是本讲 (GSDE) 的路线：放弃贝叶斯、拥抱进化，代理模型直接参与生成子代基因；右半支是第 04 讲 (DA-EGO) 的路线：把高维切成低维子空间，各自优化后再用精英点聚合。两条路线是对同一个

难题的两种回答。

3B. 第二遍符号卡（第一遍跳过）

▼ 展开查看符号卡

| 符号 | 人话 | 备注 | | :--- | :--- | :--- | | D | 维度 126 | 7 排 × 18 | | $\phi(r)=r^3$ | 三次 RBF | 橡胶膜 | | F, CR | DE 参数 | 0.3/0.9 | | N | 种群 | 50 | | x_i^* | 预测父点 | 局部 RBF+PSO | | T=9 | 每轮真 CFD 名额 | | 【引】 | 先认符号再读公式；主文核心式有「回译」，装不下的细节仍在正文完整保留（不删知识）。

3C. 先不用推导：代理模型到底在替谁工作？

这一节只解决一个问题：GSDE 如何用便宜的猜测，减少昂贵的 CFD？

3C-1. 先看一个二维小例子

下面是一个虚构的二维示例：设计只有两个旋钮——叶片角度 x_1 和厚度 x_2 。我们已经做过若干次 CFD，得到几张“成绩单” [示例]：

设计	CFD 结果
A	12
B	9
C	15
D	11
E	8

现在想知道新设计 F 的成绩。最笨的办法是直接跑 CFD；但我们还不知道 F 值不值得跑。

RBF 代理模型做的事情很朴素：离 F 最近的旧设计，对 F 的成绩影响更大；离 F 很远的旧设计，影响更小。它先根据已有 5 张成绩单，画出一张便宜的“估分地图”。

这张地图不是答案，只是筛选器：

已有 CFD 成绩 → 代理模型估分 → 产生很多候选 → 只挑少数候选做真实 CFD

3C-2. RBF 公式只表达“附近的点更有参考价值”

把第 i 个旧设计记作 x_i ，它的 CFD 成绩记作 y_i ，待估的新设计记作 x_0 。RBF 的简化形式可以写成：

$$\hat{y}(x) = \sum_i \lambda_i \cdot \phi(\|x - x_i\|) + p(x)$$

不要先管 λ_i 和 $p(x)$ 。只看三件事：

- x ：我们正在考虑的新设计；
- x_i ：已经做过 CFD 的旧设计；
- $\|x - x_i\|$ ：新旧设计有多远。

GSDE 选用三次 RBF，也就是：

$$\phi(r) = r^3$$

距离 r 越大，影响函数的数值越大，但真正的影响还要由系数 λ_i 共同决定。对本科生来说，最重要的不是手算这些系数，而是知道：RBF 用已有样本拼出一张局部可用的近似地图。

$p(x)$ 是一个很简单的线性趋势项：

$$p(x) = a + \sum V b_v x_v$$

它的作用是允许整张地图有一个整体倾斜趋势。RBF 部分负责“附近的起伏”，线性项负责“整体往哪边走”。

3C-3. 为什么叫“代理”？因为它不能替代裁判

RBF 给出的 $\hat{y}(x)$ 只是预测成绩，不是真实成绩。可以把它想成训练场上的陪练：

角色	做什么	花费
RBF 代理	快速估分、筛候选	便宜
CFD	给最终成绩、纠正代理	昂贵

所以 GSDE 的原则不是“相信 RBF”，而是：先让 RBF 帮忙缩小范围，再用 CFD 负责盖章。

3C-4. GSDE 的三步工作流

第一步：产生候选。

差分进化先用已有好设计和设计差异，拼出一批新方案：

$$v_i = x_{\text{best}} + F \cdot (x_{r1} - x_{r2})$$

这句话的人话是：从当前最好方案出发，加上一段“两个旧方案之间的差异”。F 只是控制这段差异放大多少。

第二步：用代理帮忙改候选。GSDE 不只是用 RBF 给候选排序，还在每个候选附近用 RBF 找一个预测上更好的位置，再把这个位置的一部分坐标混进子代。也就是说，代理模型参与了“造候选”，不只是最后打分。

第三步：只做少数真实 CFD。
一轮里产生很多候选，但原文设置每轮只挑 $T=9$ 个进入真实 CFD；其余候选不消耗高保真预算。新得到的 9 个成绩再回填数据库，下一轮重新建代理。


3C-5. 用一句话读懂 GSDE

历史 CFD → RBF 估分 → 进化产生候选 → 少量 CFD 盖章
这就是 GSDE 的核心。它不是把数学模型变得更神奇，而是把昂贵的 CFD 留给最值得验证的少数方案。126 维时，正因为不可能把所有方向都试遍，这种“代理帮忙造候选、CFD 最后裁决”的分工才有价值。

【深潜 | 第二遍再看】局部 RBF、半径自适应、PSO、交叉概率和线性方程组，都是在回答“候选怎么造得更好”。第一遍只要记住上面的四步工作流即可。

【停】第一遍到这里结束。如果你已经能说出“代理估分、进化造候选、少量 CFD 盖章”，就算读懂本讲主线；下面是论文实现细节。

4. 算法控制流



factory stations GSDE 三工位并行

指读：①局部RBF出预测父点 ②父代优选只送有限真CFD ③最优解附近局部搜索——三路并行。

【引】值班手册：先看「什么情况下走哪条分支」，公式是对白日记不是主角。


初始化：采样 → 建 RBF 代理
每轮迭代（三路并行）：
① 代理引导差分进化
对每个父点 x_i ：
局部 RBF（5D 个最近邻点，半径 r_i 自适应）
PSO 在局部 RBF 上求预测父点 x_i^*
 $best/1$ 变异 $v_i = x_{best} + F(x_{r1} - x_{r2})$
指数交叉 v_i 与 x_i^* → 候选 u_i
② 基于父代的选择
按父代适应度给所有 u_i 排序，只取前 $T=9$ 个送真实 CFD
用这 9 个子代替换父代中最差的 9 个
③ 基于代理的局部搜索（并行）
在 x_{best} 附近建局部 RBF，PSO 求 x^* ，优于 x_{best} 则替换

一句话记住：高维别硬上 Kriging；进阶：RBF 像橡胶膜，一次解线性系统。

主比喻回扣：把上面的分支再翻译成「多排叶片是一支必须一起训练的队伍」——若某步在生活里说不通，多半是符号没对齐。

三工位并行的集群含义：
工位①生成候选基因；工位②只让前 T 个做真 CFD；工位③在精英附近局部挖。
墙钟接近「最慢工位」，而不是三工位串行相加——前提是许可证与队列允许。
回扣：维数灾难的解药不只是数学，也是调度。

5. 实验验证与量化突破



budget 1500 vs 20000: GSDE 与 DE 墙钟 [原文 P07 Table 3]

指读：约 7.5% CFD 预算换约 99% 增益 [原文 P07 Table 3] ——省的是季度。

先报胜负：
先读结论句与最大那一格，再读全表；表是证据架不是背诵清单。
算例一：4 个经典数值函数（50–100 维）
设计空间归一化到 $[0,1]$ ，最大函数调用 1000 次，每算法独立运行 10 次；基线为 DE、GA 与当时的先进代理辅助进化算法 GSGA。结论：GSDE 在 1000 次调用内找到真实最优解，收敛速率远优于对比算法 [原文 P07 摘要与 Performance validation 节]。
算例二：3.5 级压气机，126 维（工程级） [以下设置均出自原文 P07 § Geometry definition / § Numerical method / Table 2]

- 几何：进口导叶 $S0+3$ 个低压压气机级 ($R1/S1$ 、 $R2/S2$ 、 $R3/S3$)，共 7 排叶片；NURBS 参数化，每排 18 独立标量 [原文 P07 Blade parameterization; Table 2]（三截面吸力面各 5 个法向主动点，每截面 7 点中 LE/TE 固定；+ 中周向 + 尖周向 + 尖轴向 共 3 个积叠标量）；型线控制点变化幅度为轴向弦长的 $\pm 0.6\% / \pm 1.2\% / \pm 1.5\% / \pm 1.2\% / \pm 0.6\%$ ，周向平移 $\pm 15\%$ ，轴向平移 $\pm 5\%$ ；
- 求解器：NUMECA FINE/Turbo，三维定常 RANS + Spalart-Allmaras；O4H 六面体结构网格 322 万节点，第一层 0.001 mm 保证 $y^+ < 1$ ；
- 工况：进口总温 288.15 K、总压 101,325 Pa，出口平均静压 164,000 Pa，转速 8297.7 RPM，壁面绝热无滑移；
- 目标与约束：最大化 $\eta_{is}/p(x)$ (p 为罚函数)，约束总压比在基准的 $[0.98, 1.05]$ 倍、流量在基准的 $[0.98, 1.02]$ 倍内。
[以上几何、求解器、工况与约束设置均出自原文 P07 § Geometry definition、§ Numerical method、Table 2 与式 9]

参数	参考设计	GSDE(1000)	GSDE(1500)	DE
等熵总对总效率 η_{is} (%)	85.825	86.867	86.929	86.940
效率增量 (%)	—	+1.042	+1.104	+1.115

参数	参考设计	GSDE(1000)	GSDE(1500)	DE
总压比相对变化 (%)	—	-0.068	-0.074	-5.7×10 ⁻³
流量相对变化 (%)	—	+0.30	+0.33	+0.66
CFD 次数	—	1000	1500	20,000

[原文 P07 Table 3]

怎么读这张表——这里必须诚实，不能夸大：

- DE 的最终效率增量 +1.115% 其实略高于 GSDE 的 +1.104%。所以正确的结论不是"GSDE 结果更好"，而是：GSDE 用 1500/20000 = 7.5% 的 CFD 预算，拿到了 DE 约 99% 的效率增益 (1.104/1.115 ≈ 99.0%)。
- 在硬件上 (双路 AMD EPYC 7502 32 核 + 256 GB 内存的微服务器，单次 CFD 1~1.5 小时，每轮并行 10 个样本)：GSDE 完成 126 维优化约 1 周，DE 完成同等任务超过 2 个月 [原文 P07 Result analysis]。
- 换算成原文的表述：GSDE 的计算开销约为常用进化算法的 1/13。
△ 旧版白皮书把这里写成"GSDE 优于 DE"，是不严谨的。请以本表为准。

气动机理 (后验观察)：优化后 S0 向吸力面倾斜并后掠；其余三级叶片均向压力面倾斜；三个转子 (R1/R2/R3) 前掠、三个静子 (S1/S2/S3) 后掠；除 S0 外，六个叶片的吸力面型线普遍变薄 [原文 P07 § Aerodynamic analysis]。

体感换算：把关键数字换成「工程师的周/月」或「一次签字的风险」——数字才进长期记忆。若原文给了墙钟时间或成本比，优先用原文换算。

口号化 (但诚实)：「用一成预算拿九成九增益」来自 1500/20000 与 1.104/1.115。DE 终值仍略高，话术必须是预算-增益权衡，不是全面碾压。

路线分叉：本讲放弃贝叶斯；下讲 DA-EGO 改造贝叶斯。你是换队伍 (进化) 还是换场地 (子空间)？		
6. 审稿人批判与承前启后		
把软肋放上可信度刻度 (0=完全不信，5=可当默认工具)：		
维度	打分	人话
工程	5	126 维跑通
预算比	5	7.5%≈99% 增益 [原文 P07 Table 3]
超参	2	缺敏感性
多点工况	1	只设计点
局部性	2	5D 近邻存疑

可以攻击的点 (以下为本文方法层面的合理质疑，涉及的设置参数均出自原文 P07 § Proposed algorithm)：

- 只在设计点优化。现代压气机要求在整个工作线 (近失速到近堵塞) 上都达标，单点优化得到的叶片很可能在非设计点恶化——本文未做多点优化。
- 超参数多且缺乏敏感性分析。N=50, F=0.3, CR=0.9, T=9, 5D 训练集、PSO(50×100) 基本都是默认值，原文没有报告它们对结果的影响 [原文 P07 参数设置段：种群规模取 50 以平衡精度与开销，F=0.3、CR=0.9、局部训练集 5D]。
- 局部 RBF 在高维下的"局部性"存疑。取 5D=630 个"最近邻"点，在 126 维空间里，最近邻与最远邻的距离差距会因距离集中效应而急剧缩小，"局部"可能已经不再局部。
- 约束处理用了罚函数，而非更严谨的可行性保持策略；最终方案的总压比相对基准下降 0.074%，虽在约束带内，但确是"贴着下边界"过约束 [原文 P07 Table 3 / § Result analysis]。
- 气动机理是后验解释，没有提炼成可迁移的设计准则 (例如"转子前掠多少度能改善多少")。 [以上第 1-5 点均基于原文 P07 报告的方法设置与结果所作的合理质疑；其中 N=50、F=0.3、CR=0.9、T=9、5D 训练集、PSO(50×100) 等参数出自 § Proposed algorithm]

承前：直接回应了论文 01 (CR-EI) 遗留的天花板——CR-EI 最高只测到 10 维，而 GSDE 把可用维数推到 126 维。路线选择上，它放弃了贝叶斯优化的优雅，换取了工程可用性。

启后：- 论文 11 (DA-EGO)：GSDE 走的是"放弃贝叶斯、拥抱进化"；DA-EGO 反过来问"那能不能改造贝叶斯框架本身来扛高维"，答案是用动态子空间分解；- 论文 08 (SW-VAE) 与论文 17 (GTO)：GSDE 仍需 1500 次 CFD [原文 P07 Table 3；数值另见本讲 § 5 表]，这两篇试图用生成式先验 + 知识迁移把样本量再降一个量级；- 论文 19 (SHAP-Turbine)：126 维优化做完之后，自然会追问"这 126 个变量里到底谁在起决定性作用"——这正是 SHAP 可解释性挖掘的出发点。

墙钟对照 (再读一遍 Table 3)：GSDE 约 1500 次 CFD、约一周；DE 约 20000 次、超过两月 [原文 P07 Table 3 / Result analysis]。

增益 1.104% vs 1.115%——话术必须是预算-增益权衡，不是「全面碾压 DE」。

诚实口号墙：

✓ 「用约一成预算拿约九成九增益」 (1500/20000 与 1.104/1.115) [原文 P07 Table 3]

✗ 「GSDE 全面碾压 DE」——终值 DE 仍略高。

气动机理 (倾斜/掠/变薄) 是后验观察，不要写成可迁移设计准则，除非另有归因因次支撑。

附：高维路线选择卡		
路线	代表	一句话
换队伍	GSDE (本讲)	弃 GP, RBF+DE 紧耦合
换场地	DA-EGO (04)	保贝叶斯，动态子空间
换先验	06-08	生成流形降有效维

维数一爆，先选路线，再调超参。

附：GSDE 超参「先别乱拧」清单		
符号	默认直觉	乱拧风险
N 种群	太大贵、太小多样性差	预算爆炸或早熟
F / CR	缩放与交叉	搜索过猛/过黏
T 真 CFD 名额	每轮送几个	太小学不动、太大变纯 DE
局部邻域 5D	高维「局部」存疑	距离集中下名不副实

原文缺系统性敏感性时，工程上先锁默认，用对照实验小步改一两个旋钮 [原文 P07 § Proposed algorithm]。

附：紧耦合 vs 松耦合 (一句话)

松：代理只筛选已生成的候选。


紧 (GSDE)：代理参与生成子代基因——x*

的某些维直接进入下一代。

高维能打，往往因为紧。

图卡：高维失明与 GSDE 让位


维数 100+ 时经典 GP 协方差「失明」；GSDE 用代理+进化+评估流水线扛 126 维叶栅。贝叶斯优化在高维叶栅面前必须让位——不是理论过时，是尺度换了。



dim curse GSDE: 126 维 GP 失明让位代理进化流水线 [原文 P07 Table 3]

图卡：紧耦合 vs 松耦合

紧耦合把代理-进化-评估咬在同一进程；松耦合用队列把三工位拆开可换可并行。高维叶栅现场常常先松后紧——先跑得动，再咬死精度。



tight vs loose couple: GSDE 紧耦合咬死 vs 松耦合三工位

图卡：超参先别乱拧

早期别乱拧种群/变异/换代理；先对齐预算墙钟、工位并行与 DE 基线对照。能跑稳再微调。



hyperparam freeze GSDE: 超参先别乱拧，先对齐预算与基线

章末：30 秒复述 · 自测 · 元数据

30 秒复述稿（可朗读）：126 维要整队练，不能一排排抠。GP 在高维失明，GSDE 改用 RBF+DE 紧耦合，三工位并行，每轮只送有限真 CFD。约 1500 对 20000 次，增益接近但预算差一个数量级 [原文 P07 Table 3] ——话术是权衡，不是碾压。

自测（先做再对答案）：

1. 为什么「一排排优化」在物理上是错题？
2. GSDE 相对纯 DE，省的是最终精度还是预算？依据哪张表？
3. 三工位里，哪一个直接决定「这轮烧几发真 CFD」？

▼ 点开看参考答案

1. 排间尾迹/旋流耦合，上游改了下游进口就变。2. 主要省预算：1500 vs 20000，增益 1.104% vs 1.115% [原文 P07 Table 3]。3. 父代优选 / T 名额工位。本讲元数据（读完再看，不挡故事）| 项 | 值 | :---| :---| | 规范编号 | 07 | | 原始文献 | Aerospace Science and Technology, 2023, 142: 108675 | | DOI | 10.1016/j.ast.2023.108675 | | 作者 | Zhendong Guo, Zijun Zhang, Yun Chen, Guangjian Ma, Liming Song*, Jun Li, Zhenping Feng | | 本地原文 | 1-s2.0-S1270963823005710-main.pdf | | 证据等级 | A (本地原文逐句可查) | | 反派绰号 | 维数灾难 | | 主比喻 | 多排叶片是一支必须一起训练的队伍 |

动手任务

任务：写一个 Python 脚本，在 126 维空间里撒 1000 个随机点，计算每个维度的平均份数 $1000^{1/126}$ ，并和“每个方向一分为二”（2 份）做对比，直观感受维数灾难。

产出文件：your_notes/experiments/L03_126维体感实验.py + your_notes/experiments/L03_维数灾难.md

验收标准：Python

脚本能运行并输出每个维度的平均份数；Markdown

文件包含你对“为什么 126 维撒 1000

个点连一分为二都做不到”的一句话解释

【AI】做完后：用 主动回忆 Prompt 做补漏，再用 批判收尾 Prompt 做深度加工。

沉淀清单

学完本讲，你应该产出以下文件：

- □ your_notes/knowledge_cards/L03_GSDE.md — 知识卡片（用模板）
- □ your_notes/experiments/L03_126维体感实验.py — 动手任务代码
- □ your_notes/experiments/L03_维数灾难.md — 动手任务记录
- □ 个人 Prompt 库中新增 ≥ 2 个 Prompt

【第04讲】DA-EGO：把 126

维切成小块——动态分解与聚合如何救活贝叶斯优化（论文 11）

【靶】开讲前（5 分钟）：用 预习向导 Prompt 让 AI 帮你建立直觉框架，再开始读正文。

本讲开场 90 秒

上讲闪回：


GSDE 用进化扛 126 维；本讲问：贝叶斯能否靠动态切块重返高维？

本讲反派：「假交互」

只要带走 3 句口诀：


1. 交互变量同屋，可分离才分房
2. 评估越贵分解越值，分错比不分更惨
3. P_C 绑死，P_S 疑似先验

主比喻：超大房子分区装修：水电墙不能拆标段



partition card DA-EGO 分区装修值班卡

指读：水电墙同屋、客房可分房；P_C 绑死、P_S 再验。



第04讲心智图：DA-EGO 分而治之与子空间轮流（mindmap）

看图三秒：大房子分区；红墙强交互；绿门可分离。本讲赌注：分错交互，比不分更浪费——假可分离会制造返工。

1. 生活与物理直觉引子：为什么“分而治之”在优化里这么难

先讲一个生活场景。你要装修一套 126

个房间的超大房子，预算只够请设计师做 1000 次方案评审。

笨办法：每次都让设计师把整套房子从头到尾重新设计一遍。1000 次下来，每个房间平均只被认真推敲过 8 次——大概率烂尾。

聪明办法：把房子按功能分区（客厅区、卧室区、厨卫区……），每次集中精力改一个区，其他区保持现状；改完一个区就把它的最优方案“固化”下来，再改下一个区；改完一轮后重新审视：哪些区之间其实互相影响（比如开放式厨房和客厅必须一起改），把它们合并后重新规划。

这就是 DA-EGO
的核心思路。但这里有个真正的难点，也是本文的贡献所在：

你事先并不知道哪些房间之间互相影响。
在叶轮机械里，这个“影响”是物理上真实存在的：改动第 1 排叶片，会改变第 2 排的进口气流角，于是第 1 排和第 2 排的变量之间存在交互作用（interaction）。把它们拆进不同子空间各自优化，就会得到互相矛盾的结果。

所以 DA-EGO 的关键不是“分解”，而是“动态分解”——每轮迭代都重新判断谁和谁该分在一起。

装修监理的口令：
• 水电墙（强交互）→ 绝不能拆到两个标段；
• 两间不相干的客房（可分离）→ 可以轮流施工；
• 疑似承重墙（P_S）→ 先小范围验证，再决定打不通。
DA-EGO 的「动态」两个字，意思是：标段划分会随着你对新房结构的理解而改，不是一锤子合同。
监理口令：水电墙不拆标段；客房可轮流；疑似承重先验。

先猜后揭：若本讲反派「假交互」赢了，你的下一笔 CFD/实验预算会怎样被浪费？揭晓贯穿 §3-§5。


生活元素	工程元素	符号
主比喻侧	交互分	SPCE _{ij}
主比喻侧	确认/疑似	P_C/P_S
主比喻侧	变量子集	子空间
主比喻侧	精英拼回	聚合

装修事故集：承重墙拆进两个包工队→返工；客房绑死同一工期→浪费并行。交互分数就是给每面墙打「能否拆标段」的分。

假交互的两种事故：
- 把强交互拆进两个包工队 → 返工（假可分离）。
- 把弱交互绑死同一工期 → 浪费并行（假必须同屋）。
交互分数 + P_C/P_S 就是给每面墙打「能否拆标段」的监理报告。

装修监理的一天：
上午：水电墙（强交互）被拆进两个标段，下午返工。
傍晚：客房（弱交互）被绑死同一工期，并行度浪费。
DA-EGO
的交互分数，就是自动出具「这面墙能不能拆标段」的报告；P_C 绑死，P_S 疑似先验。

2. 叶轮机械中的真实工程死穴：GSDE
的代价与贝叶斯框架的“不甘心”



EGO 在低维与高维的取舍，及 DA-EGO 的分解思路（rotor37 divide，手绘笔记版）
指读：这张图是本讲工程死穴的一张图版本。
第 03 讲的 GSDE 用进化算法硬扛 126 维，效果很好，但它放弃了贝叶斯优化（EGO）这套东西。站在贝叶斯阵营看，这是有遗憾的：
• EGO/Kriging 的样本效率在低维问题上其实远高于进化算法——几十次评估就能逼近最优；


• 它失效的地方是高维：Kriging
建模失真、采集函数全局最优化本身变成难题。
于是问题变成：能不能不动 EGO 的骨架，只把“高维”这件事解决掉？
本文给出的答案是：把高维问题分解成若干低维子问题，在每个子问题上用 EGO 好好优化，再把各子空间学到的知识聚合回全空间。
而且——分解方案每轮迭代都要更新。

原文定义的问题规模是 $d \geq 30$ 的高维昂贵黑箱问题 [原文 P11 摘要]。


现场感：周五下班前组长要数——你面对的不是可以慢慢推的练习题，而是算错一次就不可回收的预算。

GSDE 已能扛 126 维，为何还要 DA-EGO？
因为有人仍想保留贝叶斯的不确定度叙事与 EI 族工具。
DA-EGO 的回答：不换队伍，换场地——把高维切成可 EGO 的子空间，再聚合精英。
两条路线不是站队，是工具箱里的两种扳手。


3. 数学公式从 0 到 1 推导
【AI】卡壳？数学推导看不懂时，不要硬啃。把你的困惑发给 AI，用苏格拉底引导 Prompt。先自己想 5 分钟，再让 AI 一步步追问。



interaction score 交互分数分房：红同屋绿分房
指读：高交互绑 P_C；疑似进 P_S 再验；错绑比不分更惨。
先把公式关掉，用主比喻说一遍：
超大房子分区装修：水电墙不能拆标段
本讲反派是「假交互」。下面公式是这句话的展开；每条核心式尽量带回译。知识总量不删——深潜只是阅读路径，不是垃圾桶。



变量交互与可分离性判据，PCE 灵敏度系数打分（da ego loop，手绘账版）



GSDE 与 DA-EGO 的高维路线对比 (GSDE and DA-EGO in high dimension, 中文标注版)

右半支即本讲的 DA-EGO: 分解 → 各子空间独立优化 → 精英点聚合 → 更新交互知识, 且分解方案每轮迭代都要更新。与左半支的 GSDE 对照看, 两条路线的取舍最清楚。

指读: 先把这张图当 §3 地图, 再读公式。

3B. 本讲符号卡 (建议截图留存)

符号	人话	备注
SPCE _{ij}	交互分	高→同屋
P _C /P _S	确认/疑似	
子空间	变量子集	低维EGO
聚合	精英拼回	

【引】先认符号再读公式; 主文核心式有「回译」, 装不下的细节仍在正文完整保留 (不删知识)。

3C. 第一遍主路: 先判断哪些旋钮必须绑在一起

这一讲不要先学 PCE 或 SPCE。只记住: 如果调旋钮 A 会改变旋钮 B 的最佳取值, A 和 B 就有交互, 不能分到两个小组里各自优化。

把目标函数读成一句话:

总效果 = 单个旋钮的作用 + 旋钮之间的联合作用

联合作用很弱的变量可以分开; 联合作用明显的变量必须放在同一组。DA-EGO 的工作流是:

已有样本 → 估计交互 → 分成子空间 → 每组优化 → 拼回整机最好方案 → 重新估计交互

126 个变量两两配对有 $126 \times 125 \div 2 = 7,875$ 对, 所以不能全部用 CFD 检查。算法先用便宜代理模型筛出“确认交互”和“疑似交互”, 疑似交互还要用低维代理复核。

精英点就是当前整机最好方案: 每个子空间改完后, 把局部好结果拼回这个整机方案, 再进入下一轮。动态的意思是分组会随新数据改变, 不是一开始分完就永远不动。

【深潜 | 第二遍再看】下面的 PCE、SPCE、摄动法和搜索范围收缩, 都是在回答“交互分数怎么算”。第一遍只要能解释“为什么分组、为什么重新分组”。

▼ 展开论文数学深潜

[知识] → 构造子任务 (分解方案 + 搜索范围)
↓
各子空间独立做基于代理的优化
↓
子任务数据挖掘 (摄动法 + ANOVA 检测交互)
↓
[知识更新] → 下一轮的分解方案与搜索范围

3C-D. 数学深潜: 交互检测与知识闭环 **第一步: 什么是“变量交互” (interaction) ** 设目标函数 $f(x)$ 。若变量 x_i 的取值会**改变** x_j 对 f 的影响, 则称 x_i 与 x_j 存在交互。用方差分析 (ANOVA) 的语言说: 把 f 分解成主效应项与交互效应项 ** (式) ** $f(x) = f_0 + \sum_i f_i(x_i) + \sum_{i,j} f_{ij}(x_i, x_j) + \dots$ **原文自己给出的警告 (务必记住) **: “由于维数灾难的存在, **高维 PCE 代理的精度有限, 这会导致交互变量对的选取出现误差**。”正因如此, P_S 中的疑似交互还要**再用低维代理模型验证确认**。” **第三步: 精英点 (elite-point) ——子空间与全空间之间的知识桥梁** 取全部已评估样本中的**当前最优样本**作为精英点。各子空间优化得到的最

优解被**组合进精英点**, 再用于全空间的全局搜索。这一步的意义是: 子空间是低维的、好优化的, 但它只是“局部视野”; 精英点把各局部视野的最优解**拼装成一个全局可行解**, 保证子空间优化不会跑偏到全空间的劣解上去。 **第四步: 三类知识构成闭环** 原文把“设计空间的知识”明确定义为三类数据 [原文 P11 §3]: 1. **采样数据**: 所有已评估样本的坐标与函数值; 2. **变量交互关系**: 已发现 (确认/疑似) 的交互变量对; 3. **搜索边界**: 每个变量当前的搜索范围。由此形成闭环: **第五步: 搜索范围收缩** 若此前求解过**相似子任务** (变量相同、精英点不同), 则可依据累积经验缩小子问题的搜索范围, 从而同时提升优化效率与交互分析的精度 [原文 P11 §3.2.2]。 --- 【停】第一遍到这里结束。如果你已经能解释“为什么分组、为什么重新分组”, 就算读懂本讲主线; 下面是论文实现细节。

4. 算法控制流

【引】值班手册: 先看「什么情况下走哪条分支」, 公式是对白速记不是主角。

① 初始化
LHS 采样 50 个点并评估
默认: 任意变量间无交互
默认: 每个变量搜索范围 [0,1]
② 循环直到满足停止条件:
(a) 高维分解
计算所有变量对的 PCE 灵敏度系数 SPCE_{ij}
分为: 确认交互 PC / 疑似交互 PS / 非交互
用低维代理模型验证 PS → 更新 PC
据 PC 把 D 维空间分解为若干低维子空间
取当前最优样本作为 elite-point
若历史上有相似子任务 → 收缩该子问题的搜索范围
(b) 子问题优化与知识挖掘
在每个子空间上用 Kriging + EGO 采集函数优化
用摄动法 + ANOVA 在子空间/全空间中检测变量交互
把新发现的交互关系写回知识库
把各子空间最优解组合进 elite-point

一句话记住: 交互变量同屋, 可分离才分房; 进阶: 评估越贵分解越值, 分错比不分更惨。


主比喻回扣: 把上面的分支再翻译成「超大房子分区装修: 水电墙不能拆标段」——若某步在生活里说不通, 多半是符号没对齐。

分解循环值班:

打分 → 验证疑似 → 子空间 EGO → 精英聚合 → 下一轮重打分。

评估越贵, 分解越值; 样本很便宜时, 管理开销可能反超收益——§6 软肋要当排期条件读。

5. 实验验证与量化突破




rotor score Rotor37 记分牌与约束同读

指读: 效率增量要和压比/流量/强度一起读, 防单指标狂欢。

先报胜负:

先读结论句与最大那一格, 再读全表; 表是证据架不是背诵清单。

转子 37：28 维怎么来的



转子 37 的 28 维参数化与五算法效率对比 (rotor37 scoreboard, 数值见 [原文 P11 Table 3], 手绘笔记版)

算例一：21 个基准函数，30–90 维 [原文 P11 摘要与 § 4]，用于证明算法的效率与鲁棒性。

算例二：NASA Rotor 37 跨声速压气机转子 (28 变量)

- 参数化 (计数单位=独立标量)：5 截面×各 5 吸力面控制点=25；积叠为 中周向 x26 + 中、尖轴向 x27/x28 (与 P07 「中周向+尖周向+尖轴向」不同分配)，共 28 维 [原文 P11 Table 3]；
- 设计条件：转速 17,188.7 rpm，36 个叶片，展弦比 1.19，叶尖间隙 0.356 mm，进口 288.15 K / 101,325 Pa，出口静压 115,000 Pa [原文 Table 4]；
- 网格与求解：约 400 万节点，H-O-I 拓扑 (NUMECA AutoGrid5)，第一层网格 3×10-6 m，SA 湍流模型，NUMECA FINE/Turbo；单样本约 600 秒 (Intel i5-9400F) [原文 § 5.1.2]；
- 约束：流量与压比均限制在基准值的 [0.98, 1.02] 倍内，以罚函数实现；
- 目标：最大化 $\eta_{is}/p(x)$ ，其中 $\eta_{is} = [(p^{T_{outlet}}/p^{T_{inlet}})^{(\gamma-1)/\gamma} - 1] / [T^{T_{outlet}}/T^{T_{inlet}} - 1]$ 。

算法	效率	压比	流量 (kg/s)	效率提升
基准设计	0.8539	2.040	20.62	—
DA-EGO	0.8707	2.055	20.96	+1.65%
GSGA	0.8696	2.051	20.89	+1.57%
GA	0.8673	2.049	20.88	+1.34%
IKA EA	0.8665	2.050	20.88	+1.26%
DE	0.8645	2.049	20.83	+1.06%

[原文 P11 Table 5；每算法独立运行 5 次，每次 1000 次 CFD]

- DA-EGO 相对最强的对手 GSGA 高 0.08 个百分点，相对 DE 高 0.59 个百分点 [由 Table 5 计算]；
- 原文指出：DA-EGO、GA、DE 的 5 次重复运行方差很小，说明受初始样本分布影响小——这对工程应用的可复现性很关键。

气动机理：基准设计的吸力面存在明显的激波-附面层干扰现象，尾缘附近发生严重流动分离，尾缘叶尖处还伴有回流；DA-EGO 优化后分离线形态改变 (原文用语 "highly-optimized separation lines")，分离区面积与回流强度都减小，原文将其归为效率提升的流动根源 [原文 P11 § 5.1.3, Fig. 8]。

算例三：多级轴流压气机 (60 变量)

- 构型：IGV + 2 级 (R1/S1、R2/S2) 共 5 排，IGV 不优化；转子每排 18 (3 截面×5 主动 + 3 弯掠)、静子每排 12 (3 截面×3 主动 + 3 弯掠)，四排 60 维 [原文 P11 § 5.2.1]；
- 网格约 2300 万节点，单样本约 4200 秒 [原文 § 5.2.1]。

算法	效率	压比	流量 (kg/s)	效率提升
基准设计	88.072%	2.4604	53.6465	—
DA-EGO	89.142%	2.4644	53.9005	+1.070%
GSGA	88.973%	2.4630	53.7780	+0.901%
IKA EA	88.905%	2.4623	53.8325	+0.833%
GA	88.804%	2.4634	53.8110	+0.732%
DE	88.495%	2.4575	53.5025	+0.423%

[原文 P11 Table 7；同样 1000 次 CFD 预算]

- 在 60 维这一更接近真实工业规模的算例上，DA-EGO 的优势比 28 维时更明显：相对 DE 的效率提升从 +0.59 个百分点扩大到 +0.647 个百分点 (1.070% vs 0.423%) [由 Table 7 计算]。
- 气动机理：沿叶高看，优化后 90% 叶高以上区域效率变化不大、中段叶高明显提升、近端壁处略有下降；分级看，第一级各叶高均提升约 1%，第二级则是根部 (<10% 叶高) 与顶部 (>85% 叶高) 下降、中 span 提升 "very obvious" (原文定性用语)。熵函数云图显示流道内三个高熵区 (A、B、C) 熵值均 "significant decreases"，其中 A、B 区下降 "most obviously" (以上三处均为原文定性用语，原文未给数值)——原因是叶型改变削弱了转子 R1 通道内的激波；中截面的周向静压分布均匀性提高，也佐证了激波的削弱 (原文定性描述，未给均匀性指标数值) [原文 § 5.2.2]。

体感换算：把关键数字换成「工程师的周/月」或「一次签字的风险」——数字才进长期记忆。若原文给了墙钟时间或成本比，优先用原文换算。

Rotor37 体感：

效率增益达到工程上「型号卖点」那一档时 (具体数见本讲 § 5 记分牌与 [原文] 表)，

与 GSDE：

一个换算法族，一个保算法族改问题结构。两把扳手都要会。

6. 审稿人批判与承前启后

把软肋放上可信度刻度 (0=完全不信，5=可当默认工具)：

维度	打分	人话
问题	5	
Rotor37	5	
PCE成本	2	
理论	2	
维数	4	

可以攻击的点：

- 作者自己承认的时间复杂度问题。原文结论原话：该方法"提高了算法的时间复杂度，导致算法自身消耗更多计算资源。虽然这对昂贵样本问题不构成阻碍，但在样本廉价的场景下会削弱算法性能；样本的主要计算发生在 Kriging 模型构建，可用增强 Kriging 方法加以解决" [原文 § 6 Conclusions]。翻译成成人话：这套方法只在"评估很贵"时才划算——而这恰恰是叶轮机械的场景，所以问题不大，但必须有这个前提意识。
- 交互检测的可靠性是方法的阿喀琉斯之踵。原文明确说高维 PCE 精度有限会导致交互对选取出错。一旦分解错了，子空间优化就是在错误的子空间里做无用功。
- 搜索范围收缩依赖历史经验，且没有回退机制。若早期收缩把最优区域提前排除出去了，原文未说明如何恢复。
- 超参与停止条件未做敏感性分析：初始 50 个 LHS 样本、1000 次 CFD 预算均为设定值。
- 仍是单点工况优化：与 GSDE 相同，只优化设计点，未考虑非设计点性能与失速裕度。
- 维数仍低于 GSDE：本文工程算例最高 60 维，而 GSDE 做到了 126 维。两条路线各有适用范围。

承前：- 直接回应了论文 07 GSDE 所代表的分歧：高维 HEB 到底该"放弃贝叶斯进化"还是"改造贝叶斯扛高维"。DA-EGO 选了后者。- 方法论上继承自 EGO/Kriging 与变量交互分析 (PCE、ANOVA)。

启后：- 论文 19 (SHAP-Turbine)：DA-EGO 里的变量交互分析是为优化服务的副产品；SHAP 那篇把"变量重要性"与交互"本身作为研究目标，做成了可解释的设计知识。- 论文 13 (EMFS/MSFO)：同样关心"代理模型在哪些区域不可信"，但切入点在保真度而非子空间。

Rotor37 记分纪律：

效率增益的量级解读必须回到本讲 § 5 记分牌与 [原文] 表：哪怕看起来只是很小的百分点数，在压气机设计里也可能是型号卖点的级，但必须与压比、流量、强度约束同屏。


单指冠军若贴着约束下沿，签字会要听到「裕度」两个字。

附：假交互识别口令

现象	可能
拆开优化再拼总翻车	真强交互，应 P_C
绑在一起却不联动	假交互，可试分离
分数噪声大	先 P_S 小步验证

图卡：假交互识别口令

真交互红门同屋，假交互绿门可分。分房前先审 PCE 交互分数——看起来相关不等于必须绑死在同一子空间。




fake interaction: 真交互同屋 vs 假交互可分房 (DA-EGO)

图卡：分区装修值班

交互分数 → 分房 → 子空间 EGO →

汇总。真交互同屋、假交互可拆；值班不是一次分完就散场。



partition duty DA-EGO: 交互分数分房后的值班装修

章末：30 秒复述 · 自测 · 元数据

30 秒复述稿（可朗读）：高维别墅翻新。DA-EGO 用交互分数把变量分成确认绑死与疑似再验，子空间跑 EGO 再聚合。分对省预算，分错比不分更惨。与 GSDE 是换场地 vs 换队伍。

自测（先做再对答案）：

1. 可分离？
2. P_S 为何再验？
3. 样本便宜时分解划算吗？

▼ 点开看参考答案

1. 无交叉项可拆；强耦合几何通常不可分。2. 分数有噪声，防假交互绑死。3. 不一定，管理开销可能更高。本讲元数据（读完再看，不挡故事）
| 项 | 值 | | :--- | | 规范编号 | 11 | | 原始文献 | Engineering Optimization, 2025, 57(2): 514-542 (线上发表于 2024-04-18) | | DOI | 10.1080/0305215X.2024.2325651 | | 作者 | Qineng Wang, Zhendong Guo, Yun Chen, Guangjian Ma, Liming Song, Jun Li | | 本地原文 | A dynamic aggregation strategy enhanced efficient global optimization algorithm...pdf | | 开源代码 | https://github.com/zhet1997/DA_EGO_public | | 证据等级 | A (本地原文逐句可查) | | 反派编号 | 假交互 | | 主比喻 | 126 个房间的超大房子装修 |

动手任务

任务：用 code/sampling.py 的 sobol_first_order_indices 函数，在一个 6 维测试函数上估计一阶敏感性指数，找出最重要的 2 个变量。然后思考：如果这是 DA-EGO 的交互分析，你会把最重要的变量和哪些其他变量“绑在一起”？

产出文件：your_notes/experiments/L04_DA_EGO_交互分析.md

验收标准：文件存在且包含：① 敏感性指数排序结果 ②

你对“哪些变量应该绑在一起”的判断及理由

【AI】做完后：用 主动回忆 Prompt 做补漏，再用 批判收尾 Prompt 做深度加工。

沉淀清单

学完本讲，你应该产出以下文件：

- your_notes/knowledge_cards/L04_DA_EGO.md — 知识卡片（用模板）
- your_notes/experiments/L04_DA_EGO_交互分析.md — 动手任务记录
- 个人 Prompt 库中新增 ≥ 2 个 Prompt

【第05讲】EMFS / MSFO：当“便宜的粗网格”开始骗人——多保真优化的暗面（论文 13）

【靶】开讲前（5 分钟）：用 预习向导 Prompt 让 AI 帮你建立直觉框架，再开始读正文。

本讲开场 90 秒

上讲回顾：


Filter问谁配见专家；本讲问：专家看过的区还信不信实习生？

本讲反派：「后期假优」

只要带走 3 句口诀：

1. 多保真不总更好
2. HF扎堆处Z_DF可能失真
3. 失准区DBSCAN局部验尸再融合

主比喻：专家盯过的区，实习生反而开始系统性撒谎



第05讲心智图：EMFS 多保真也会骗人（mindmap）

看图三秒：前期MFS领先，后期SFS反超；DBSCAN圈失准区。本讲赌注：把「MFO 必胜」当宗教，会在后期交叉后继续向假谷冲刺。

1. 生活与物理直觉引子：老专家带的实习生，也会把你带沟里
第 02 讲（Filter-GEI）讲过“老专家 + 实习生”的比喻：实习生（低保真 LF）便宜、出活快，负责摸清大方向；老专家（高保真 HF）贵，只在关键点出手。

但那个比喻里藏着一个没被追问的前提：

实习生的判断，大体上是对的。

如果这个前提不成立呢？想象一下：实习生看图纸有个系统性偏差——他总把某种特定结构画得比实际更结实。在设计早期，这个偏差无所谓，因为大方向是对的；但当设计推进到精细阶段、你已经逼近最优解时，这个系统性偏差会把你往错误的方向一直带。

这时候，继续让实习生参与决策，不但不省钱，反而是负资产——你花的每一分钱都在加固一个错误。

这就是本文的出发点，而且它是反直觉的：

多保真优化（MFO）并不总是优于单保真优化。在优化的后期，随着高保真样本不断积累，低保真样本会产生负面效果，误导优化搜索。[原文 P13 摘要]

后期假优的日常版：

项目前半段，实习生的图确实让方案从「一团糟」变成「像回事」，经理很开心。

后半段要比拼毫厘时，实习生那套「总把某结构画结实」的系统偏差，开始把最优解往歪处拽。

若你还在用「早期真快」当理由继续信他，就会在终点输给「全程只请老专家、虽然慢但没被带沟」的队伍。

原文把这件事说得很干脆：MFO 不总是更好；后期 LF 可能负面 [原文 P13 摘要]。

EMFS 值班口令（对照第 02 讲）：

- 第 02 讲滤波问的是：「这个点配不配见老专家？」
- 本讲集成问的是：「老专家已经看过的区域里，实习生是不是还在撒谎？」

DBSCAN 圈出的是失准区，不是「坏点垃圾箱」。圈里改建局部 SFS，再与全局 MFS

按权重融合——像给惯于撒谎的街道派驻专人复核。

对照 02：一个管分配，一个管失准验尸。

先猜后揭：若本讲反派「后期假优」赢了，你的下一笔 CFD/实验预算会怎样被浪费？揭晓贯穿 § 3-§ 5。

生活元素	工程元素	符号
主比喻侧	多/单保真	MFS/SFS
主比喻侧	差异函数	Z_DF
主比喻侧	集成多保真	EMFS
主比喻侧	圈失准区	DBSCAN

连续翻车故事（加长）：

前 20 轮：LF 带路，曲线好看。第 21-40 轮：HF 在「有希望区」密集加班，Z_DF 过度自信。第 41 轮起：MFS 仍听 LF，可 LF 在这片区开始系统性画错——假最优越跑越稳。SFS 更慢但不自欺。这就是后期假优。

实习生撒谎的时间线（加长到可写进事故报告）：


T0-T1：LF 带路，曲线好看，老板表扬「多保真真香」。

T1-T2：HF

在「有希望区」扎堆，差异函数被局部残差喂胖，过度自信。

T2 后：全局 MFS 仍听 LF，搜索被推进假谷；SFS 更慢但更不自欺。交叉点出现 = 本讲定理的实验指纹，不是噪声。

2. 叶轮机械中的真实工程死穴：一个被“MFO 一定更好”掩盖的问题



多保真的暗面：MFS 早期领先但最终解劣于 SFS (mfs trap, 手绘手账版)

指读：这张图是本讲工程死穴的一张图版本。

多保真方法（Co-kriging、多保真 EGO 等）在 2010 年代后成为叶轮机械优化的主流工具，因为它确实省钱。行业内逐渐形成一种默认认知：“只要能多用多保真，就该用多保真。”

本文要戳破的正是这个默认认知。原文描述的观察是：

基于多保真代理（MFS）的优化，有时只能在优化早期取得更好的收敛速率，但最终解反而比“只用高保真样本的单保真代理（SFS）优化”更差。

[原文 P13 摘要]

为什么会这样？原文给出的机理是：

随着优化过程中 HF 样本的增加，LF 样本会产生负面效果，从而误导优化搜索。[原文 P13 摘要]

用物理语言翻译一遍：优化前期，LF 的“大趋势”信息价值极高，因为 HF 样本太少、全靠 LF 撑着全局形状；但到了后期，HF 样本已经足够刻画局部细节，此时 LF 与 HF 之间的系统性差异（discrepancy）就从“可容忍的噪声”变成了“系统性的偏差”——它会持续把代理模型的最优位置拉偏。

现场感：周五下班前组长要数——你面对的不是可以慢慢推的练习题，而是算错一次就不可回收的预算。

与第 02 讲边界：Filter 假设 LF 大体可用；EMFS 处理 LF 局部有毒。同一公司隐喻，病不同。

「MFO 一定更好」如何成为教条：

论文摘要与综述常强调早期加速；很少把后期交叉当标题。

工程值班却必须问：学习曲线有没有交叉？交叉后你还信谁？

原文立场需要诚实引用：多保真不总更好 [原文 P13 摘要]。


3. 数学公式从 0 到 1 推导

【AI】卡壳？数学推导看不懂时，不要硬啃。把你的困惑发给 AI，用苏格拉底引导 Prompt。先自己想 5 分钟，再让 AI 一步步追问。

先把公式关掉，用主比喻说一遍：


专家盯过的区，实习生反而开始系统性撒谎

本讲反派是「后期假优」。下面公式是这句话的展开；每条核心式尽量带回译。知识总量不删——深潜只是阅读路径，不是垃圾桶。



DBSCAN 聚出失准区、局部 SFS 与全局 MFS 融合为 EMFS (emfs pipeline, 手绘手账版)

EMFS / MSFO：当便宜的粗网格开始骗人（论文 13）



多保真后期陷阱与 EMFS 局部纠偏 (EMFS MSFO late stage trap, 中文标注版)

上图是本讲难点的「一张图版本」：左图是多保真的暗面——MFS（橙虚线）早期收敛快，后期反被低保真样本拖累，最终解比只用高保真样本的 SFS（蓝实线）更差；右图是 MSFO 的解法——用 DBSCAN 聚出 MFS 失准区（红色圈），在该区域局部构建 SFS，再与全局 MFS 按自适应权重融合成 EMFS。

3B. 第二遍符号卡（第一遍跳过）

▼ 展开查看符号卡

|符号|人话|备注||:---|:---|:---||MFS/SFS|多/单保真|||Z_DF|差异函数|||EMFS|集成多保真|||DBSCAN|圈失准区||>【引】先认符号再读公式；主文核心式有「回译」，装不下的细节仍在正文完整保留（不删知识）。3C.
第一遍主路：便宜模型什么时候会骗人？
多保真代理可以先粗略写成：

高保真结果 $\approx \rho \times$ 低保真结果 + 差异修正

低保真模型负责便宜地给趋势，差异修正负责补它的偏差。问题是：如果高保真样本后来都挤在一个小区域，差异修正在真正关心的地方可能反而没学好。

所以本讲的核心不是“永远相信多保真”，而是：

全局趋势用多保真代理；发现它失真的区域，就在那里单独训练高保真代理；最后按可信程度融合。


DBSCAN 在这里不是为了给变量分类，而是为了找出高保真样本密集、可能需要局部修正的区域。EMFS 是融合后的代理模型，MSFO 才是用它进行搜索的优化算法。

【深潜 | 第二遍再看】下面的差异函数、DBSCAN 参数和自适应权重公式，都是在回答“哪里该信谁”。第一遍只要记住：低保真会改变排序，必须用高保真校准。

▼ 展开论文数学深潜

3C-D. 数学深潜：多保真代理与局部融合**第一步：把“多保真为什么失效”写清楚**多保真代理（以 Co-kriging 为例，参见第 02 讲）把 HF 建模为**【式】** $y_{HF}(x) = \rho \cdot y_{LF}(x) + Z_{DF}(x)$ **回译：上式是主路径构件——先记住它在算法里负责哪一步，再抠每一个符号。其中 Z_{DF} 是差异函数（discrepancy function），负责修正 LF 的系统性偏差。问题在于： Z_{DF} 本身也是用有限样本拟合出来的高斯过程**。当 HF 样本在优化后期**高度聚集于当前最优附近**时， Z_{DF} 在“你真正关心的那块区域”里的估计反而可能很不准——因为 LF 在那里从来就没被 HF 校验过。于是出现了本文说的现象：**在 MFS 建不准的那块区域，MFS 反而不如一个纯用 HF 建的单保真代理（SFS）。****第二步：核心思想——不是“全用 MFS”或“全用 SFS”，而是“哪里 MFS 不行，哪里就换 SFS”****本文的做法可以概括成一句话：> 用**DBSCAN 密度聚类**找出“MFS 建不准”的区域，在该区域**局部改建一个单保真代理（local SFS）**，再用**自适应权重**把 MFS 与这个局部 SFS 融合成一个集成代理**EMFS**（Ensemble weighted Multi-Fidelity Surrogate）。【原文 P13 摘要】**第三步：为什么用 DBSCAN 而不是别的聚类？**DBSCAN（Density-Based Spatial Clustering of Applications with Noise）的特点是：- **不需要预先指定簇的个数**——你事先并不知道有几个“失真区”；- **能识别噪声点**——稀疏的离群样本不会被硬塞进某个簇；- **能发现任意形状的簇**——失真区的几何形状未必是凸的。这三点恰好契合“找出代理模型失真区域”这个任务：失真区可能不止一个、形状不规则、且边界处样本稀疏。>【钉】**DBSCAN 的具体参数（邻域半径 ϵ 、最小样本数 MinPts）与自适应权重的具体公式，摘要未给出，原文未获取，本讲不作推测。****第四步：命名规范（旧版白皮书在这里错了，必须纠正）**|名称|全称|指代对象||:---|:---|:---||**EMFS**|Ensemble weighted Multi-Fidelity Surrogate|**代理模型**|**MFS 与局部 SFS 的自适应加权集成体**|**MSFO**|Multi- and Single-fidelity surrogate fused Optimization|**优化算法**：用 EMFS 引导搜索的完整算法|>x 旧版白皮书第 05 讲的标题写作**“EMFS 算法”：DBSCAN 空间聚类识别失真区的多保真局部融合，把**代理模型的名字当成了算法名**。**>✓ 正确表述：**EMFS 是代理模型，MSFO 才是优化算法。****【停】第一遍到这里结束。如果你已经记住“低保真会改变排序，必须用高保真校准”，就算读懂本讲主线；下面是论文实现细节。

4. 算法控制流



EMFS duty 后期假优验尸值班流程

指读：画曲线→找交叉→DBSCAN圈团→团内SFS→融合。与 Filter 串联而非二选一。

【引】值班手册：先看「什么情况走哪条分支」，公式是对白速记不是主角。

依据摘要可确认的流程骨架（细节参数原文未获取）：

每轮迭代：

1. 用现有 HF + LF 样本建立多保真代理 MFS（如 Co-kriging）
2. 用 DBSCAN 对样本/设计空间做密度聚类，侦测出“MFS 在该区域建不准”的区域
3. 在这些失真区域内，仅用 HF 样本建立一个局部单保真代理 local SFS
4. 用自适应权重把 MFS 与 local SFS 融合为集成代理 EMFS
5. 用 EMFS 引导下一轮加点（这就是 MSFO 算法）

一句话记住：不是“多保真 vs 单保真”的二选一，而是“哪里可信就用哪套”的自适应切换。

主比喻回扣：把上面的分支再翻译成「专家盯过的区，实习生反而开始系统性撒谎」——若某步在生活里说不通，多半是符号没对齐。

融合口令：失真区专家说了算（SFS）；其余区仍可 MFS。权重问「这片区最近谁在撒谎」。

EMFS 排班：

全局仍可用 MFS 探路；DBSCAN 圈出的失真团改

SFS；融合权重看「这片区谁在撒谎」。

与 Filter 串联：先分配谁见专家，再验尸专家盯过的区。

EMFS 与 Filter 的串联脚本：


每 10 轮：更新 MFS/SFS 曲线。

发现交叉：启动 DBSCAN 圈失准团。

团内：SFS 说了算；团外：MFS 仍可探路。


融合后再跑，看交叉是否消失；不消失则检查 LF 是否结构性失效（不是聚类能救）。

5. 实验验证与量化突破



MFS SFS cross 学习曲线交叉点指纹

指读：交叉不是噪声，是后期假优的实验指纹。



后期假优：MFS 与 SFS 学习曲线交叉

指读：前期 MFS 领先，后期交叉后 SFS 反超——交叉点是本讲定理的实验指纹。

读后期陷阱实验的正确姿势：

不要只看「谁最终最优」。看学习曲线有没有交叉、交叉出现在第几轮、交叉后 MFS 是否仍假装领先。

交叉 =

本讲定理的实验指纹；没有交叉图，就没有「后期假优」的证据链。

先报胜负：

先读结论句与最大那一格，再读全表；表是证据架不是背诵清单。

可确认的验证算例 [原文 P13 摘要]：

1. GE-E3 叶片优化（与第 02 讲 Filter-GEI 用的是同一个公开标杆几何）；
2. 涡轮端壁气膜孔布局设计（the film cooling layout design of a turbine endwall）。

摘要的原话是："Through tests on GE-E3 blade optimization and the film cooling layout design of a turbine endwall, the effectiveness of proposed MSFO is well demonstrated."

△ 重要提醒：摘要没有给出任何量化对比数字（提升了多少、节省了多少次 CFD、成功率如何）。因此本讲不列出任何性能数字。

【删】旧版白皮书 6.1 矩阵中写的「250 次 CFD」「15D~30D」「消除低保真模型失真误差现象」等条目，均无出处，属填充内容，已在重建版中删除或标注待补。

体感换算：把关键数字换成「工程师的周/月」或「一次签字的风险」——数字才进长期记忆。若原文给了墙钟时间或成本比，优先用原文换算。

盯交叉点：学习曲线上 MFS 前期领先、后期被 SFS 反超——可能是本讲定理的实验版。

进工具箱：多保真是默认选项，不是宗教信仰。后期要会验尸。

6. 审稿人批判与承前启后

把软肋放上可信度刻度（0=完全不信，5=可当默认工具）：

维度	打分	人话
问题	5	打脸MFO必胜
直觉	4	
细节	3	
广度	3	

可以攻击的点：

1. "失真区"的判定标准本身依赖代理模型。用 MFS 去判断"MFS 在哪不准"，存在自我指涉的风险；判定失真时会连锁出错。
2. DBSCAN 的参数敏感性。密度聚类对邻域半径与最小样本数非常敏感，而这两个参数与"代理模型误差阈值"之间并无直接的物理换算关系——调参很大程度上靠试。
3. 局部 SFS 的样本从哪里来？失真区之所以失真，恰恰是因为那里 HF 样本稀少；在 HF 样本稀少的区域建单保真代理，可能同样不可靠。原文未提供此处的处理细节（原文未获取）。
4. 权重的自适应规则缺少理论依据（原文未获取，无法评价）。
5. 仅两个算例，且都为该课题组的常规算例，未在更广泛的基准上验证泛化性。

承前：- 直接修正了第 02 讲（Filter-GEI）的隐含前提。Filter-GEI 假定"LF 大体能捕捉 HF 趋势"，并据此设计滤波阈值；本文则处理这个前提在局部失效的情形。两篇论文构成"多保真方法"的一体两面。- 方法上继承了 Co-kriging 与多保真 EGO 的体系。

启后：- 论文 07（GSDE）与论文 11（DA-EGO）：如果说 EMFS 处理的是"保真度维度上的模型不可信"，那么 GSDE 与 DA-EGO 处理的是"维度灾难带来的模型不可信"。三者共享同一个哲学——先识别代理模型在哪里不可信，再在那里换一种策略。- 论文 19（SHAP-Turbine）：同样是对"模型/数据不可信"的反思，但转向可解释性视角。

【附】如果想把本讲升级为 A 级证据，需要取得 ASME 全文（DOI 10.1115/1.4064228）。届时可在 corpus/facts/P13.md 中补全：DBSCAN 参数、自适应权重公式、Table 中的量化对比结果。

交叉点会议怎么开：

投影学习曲线，用红笔标交叉轮次。

问三句：HF 最密在哪？Z_DF 是否过自信？失真团是否可解释物理？答完再动超参，避免「先调 DBSCAN 碰运气」。

附：读完本讲你应能画的一张因果图

HF 样本在「好区」越来越密
↓
差异函数 Z_DF 被局部残差主导 / 过拟合
↓
全局 MFS 仍信任 LF 趋势
↓
搜索被推进「LF 系统性偏差」的谷
↓
后期 MFS 曲线交叉，SFS 反超 → 后期假优
↓
EMFS：DBSCAN 圈失准区 → 局部 SFS → 融合

经理答辩词（30 秒）：

「我们不是抛弃多保真，而是拒绝在失准区继续听实习生。Filter 解决谁配见专家；EMFS 解决专家盯过的区还信不信实习生。」

与全书地图：02 分配 → 05 验尸 → 若维数再爆棚 03/04；若要生成先验则 06+。

EMFS 值班口令（再压缩）：

1. 先画 MFS vs SFS 学习曲线，找有没有交叉。
2. 有交叉 → 用 DBSCAN（或同类密度方法）在输入空间圈失准团。
3. 团内改 SFS，团外保留 MFS，融合后再跑几轮看交叉是否消失。
4. 若交叉不消失，检查 LF 定义本身是否在该物理机制上结构性失效（不是聚类能救的）。

和 Filter-GEI 联用时的顺序建议：

先 Filter 管「谁见专家」，再 EMFS

管「专家扎堆区还听不听实习」——两道闸，不是二选一。

附：后期假优的「验尸报告」模板

现场记录（建议每 10 轮写一行）：

轮次	MFS 最优	SFS 最优	交叉？	HF 最密的区域（人话）	决策
10	...	...	否	全局散	继续 MFS
30	...	...	苗头	某角区	盯 Z_DF
50	...	...	是	HF 扎堆谷	启动 EMFS

DBSCAN 在本故事里的角色（人话，不推导）：

它不负责「找到最优」，只负责在输入空间里圈出「代理不可信的团」。团内改单保真，团外仍可多保真——像把医院隔离区与普通病房分开。

失败模式点名：

1. 宗教多保真：从不画 MFS/SFS 对照曲线。
2. 只调滤波不验尸：Filter 解决分配，解决不了局部有毒。
3. 失真定义随手定： ϵ 与 MinPts 乱抖，圈出半个设计空间。
4. 融合权重拍脑袋：该信 SFS 的区仍 50/50。

和全书的接口：

02 管「谁见专家」→ 05 管「专家盯过的区还听谁」→ 若维数爆了转 03/04；若要生成先验转 06+。

附：与 02 的双闸门

闸门	问句	工具
Filter (02)	谁配见专家?	ω -T
EMFS (05)	专家盯过的区还信实习生吗?	DBSCAN+局部 SFS

只开一闸，另一类事故仍会来。

附：后期假优的一页纸定义

前期加速 $\neq$ 全程更优。


当 HF 扎堆导致差异函数失真，LF 开始系统性撒谎，MFS 可能输给 SFS。

EMFS = 局部验尸 + 融合，不是抛弃多保真。

图卡：Filter $\times$ EMFS 双闸门

Gate1 Filter: 谁配见专家 (ω -T) ; Gate2

EMFS: 专家盯过的区还信实习生吗 (DBSCAN+局部 SFS)。只开一闸，另一类事故仍会来。



dual gates filter EMFS: 谁见专家 $\times$ 看过的区还信谁

图卡：后期假优验尸日志

每轮记 MFS/SFS 最优与是否交叉；交叉苗头出现就启动

EMFS (DBSCAN 圈失准区)。从不画对照曲线 = 宗教多保真。


轮次	MFS最优	SFS最优	交叉?	决策
1	0.98	0.36	否	继续 SFS
2	0.55	0.37	否	继续 SFS
3	0.65	0.80	否	继续 SFS
...	...	...	...	...
MFS 49	1.62	1.50	否	
50			×	启动 EMFS
51	0.42	0.86	↑	
42	0.18	0.76	↑	

autopsy log EMFS: 后期假优验尸日志与交叉启动

图卡：失准区隔离病房

DBSCAN 画出失准团：团内改局部 SFS，团外仍可 MFS。EMFS

是隔离+融合，不是抛弃多保真。



quarantine zone EMFS: DBSCAN 圈失准区，团内 SFS 团外 MFS

章末：30 秒复述 · 自测 · 元数据

30 秒复述稿（可朗读）：多保真不总更好。HF 扎堆处 Z_DF 可能失真，后期 MFS 会交叉输给 SFS。EMFS 用 DBSCAN 圈失准区，局部改单保真再融合。Filter 管谁见专家，EMFS 管看过的区还信谁。

自测（先做再对答案）：

1. MFO 必胜？
2. 后期 LF 为何负？
3. EMFS 三步？

▼ 点开看参考答案

1. 不；原文：MFO 不总更好 [原文 P13 摘要]。2. HF 密使 Z_DF 失真。
3. 圈失准 $\rightarrow$ 局部 SFS $\rightarrow$ 融合。本讲元数据（读完再看，不挡故事） | 项 | 值 | :--- | :--- | 规范编号 | 13 | 原始文献 | ASME Journal of Turbomachinery, 2024, 146(4): 041011 (10 页) | DOI | 10.1115/1.4064228 | 论文号 | TURBO-23-1281 (线上 2023-12-21) | 作者 | Qineng Wang, Liming Song, Zhendong Guo (通讯), Jun Li, Zhenping Feng | 本地原文 | 无 (ASME 订阅墙) | 证据等级 | B (出版商页面 + 摘要全文) |

△ 本讲的写作边界：本文无本地全文，以下内容仅取自出版商页面的标题/作者/卷期/摘要原文，以及可核验的著录信息。凡摘要未给出的数字（具体提升幅度、样本量、DBSCAN 参数、权重公式），本讲一律不写，并明确标注「原文未获取」。| 反派绰号 | 后期假优 || 主比喻 | 实习生总把某种结构画得更结实 |

动手任务

任务：用 code/multifidelity.py 的 dbscan 函数，在一个模拟的 HF 样本上做密度聚类。构造两组样本：一组“扎堆”在原点附近（模拟后期 HF 密集区），一组均匀分布（模拟早期 HF 散布）。观察 DBSCAN 如何圈出“扎堆区”。

产出文件：your_notes/experiments/L05_EMFS_DBSCAN实验.md

验收标准：文件存在且包含：① 你构造的样本描述 ② DBSCAN 的聚类结果 ③ 你对“为什么 HF 扎堆会导致 Z_DF 失真”的一句话解释

【AI】做完后：用 主动回忆 Prompt 做补漏，再用 批判收尾 Prompt 做深度加工。

沉淀清单

学完本讲，你应该产出以下文件：

- your_notes/knowledge_cards/L05_EMFS.md — 知识卡片（用模板）
- your_notes/experiments/L05_EMFS_DBSCAN实验.md — 动手任务记录
- 个人 Prompt 库中新增 ≥ 2 个 Prompt