

第一篇【贝叶斯优化与高维代理模型篇】

本篇覆盖论文

01、02、07、11、13。这一条主线回答一个问题：当一次 CFD 贵得要命时，下一个点该算在哪里？
从校准采集函数（CR-EI），到多保真并行分配（Filter-GEI），再到 126 维下被迫改换门庭的代理进化（GSDE）与子空间聚合（DA-EGO），最后以「多保真也会骗人」这一反直觉发现（EMFS / MSFO）收尾。

过桥 A · 从第零章到第 01

讲：问题已经清楚，答案从「下一次采样」开始
第零章结束时，你手里只有一个问题，没有算法：

在高维、昂贵、无导数的黑箱里，下一个点该算在哪里？

从现在起，第一篇（第 01-05

讲）给出第一条主线答案：让每一次采样更聪明。

你将依次遇见	它专治的病
第 01 讲 CR-EI	采样「瞎逛」
第 02 讲 Filter-GEI	机房「空转」
第 03 讲 GSDE	高维下 GP「失明」
第 04 讲 DA-EGO	整屋翻修太贵
第 05 讲 EMFS	多保真「后期假优」

阅读纪律（本篇通用）：

1. 先读开场 90 秒的三句口诀；
2. 图看懂了再啃〔式〕；
3. 深潜框可跳，知识不丢；
4. 章末自测做不出来，回到心智图，不要硬背符号。

下一页反派登场，它的名字叫瞎逛。

【第01讲】CR-EI：贝叶斯优化为什么会“瞎逛”——过度探索的发现与校准（论文 01）

【靶】开讲前（5 分钟）：用 预习向导 Prompt 让 AI 帮你建立直觉框架，再开始读正文。

本讲开场 90 秒

上讲闪回（第零章）：叶片设计是 HEB 问题——维数高、每次 CFD 贵、没有导数。全书都在问：下一笔预算该砸哪？

本讲反派：「瞎逛」——采样次数已经很多，算法却在明显很差的空白区打转，不出来。

只要带走 3 句口诀：

1. 病根是 $z \leq 0$ ：不确定度 σ 大的地方，未必是好地方。
2. 治则是改 ξ ，不是改 σ ：前人爱调探索权重；本文抬高“当前最优”这根尺子。
3. 近处 CEI、远处 REI，EI 瞎了再换班：值班经理三规则。

「第01讲心智图：CR-EI 治瞎逛」



病根是 $z \leq 0$ 治则改 ξ 不改 σ 近 CEI 远 REI

第01讲心智图：z、瞎逛与 CR-EI 调度（手绘笔记版）（mindmap）

看图三秒：中间是参数 z ；左边 $z>0$ 是“有希望的街区”；右边 $z \leq 0$ 是工业区瞎逛；底部三条口诀请先刻住，后面只是在证明它们。

本讲赌注：若放任 $z \leq 0$ 的瞎逛，有限 CFD 预算会永久巡逻工业区。

【补】读本讲前，你只需要先知道 3 件事（都出自 第零章 与 第零章 B · 四张补丁卡；忘了就点回去看一眼，不用背）：1. 一次 CFD $\approx$ 一小时，一个设计周期只负担得起几百到几千次（第零章 0.3）2. 标准差 σ 是「不确定带宽」，不是「这里好不好」（卡① B.1.3）3. Φ 与 ϕ 只是正态分布的两个已知函数，不必会算（卡① B.1.4）

1. 生活与物理直觉引子：三种“找最佳餐厅”的策略



restaurant map 口味地图： $z>0$ 好街区 vs $z \leq 0$ 工业区瞎逛

指读：左有希望区、右工业区巡逻；CR-EI 改的是尺子 ξ 与远近分工。

假设你搬到一座新城市，给自己定了死规矩：30 天内，找到全城最好吃的那家面馆。

每一顿饭都要花钱、花时间——这顿饭就是一次昂贵实验。放到叶片设计里，它对应动辄几小时的一次 CFD。

你口袋里的钱，只够吃大约几十顿。于是策略选择，比“爱吃辣还是爱清汤”更要命。



找面馆三策略漫画（restaurant comic，教学比喻）

指读：左格人死守小巷（河对岸的神店永远没机会）；中格人专钻空白工业区（反复确认“这儿难吃”）；右格人手里有一张口味地图——颜色深的是已知好吃，问号是不确定。

策略 A · 纯开发（exploitation）

找到一家还不错的，就天天去，只在附近小巷换着吃。

风险：全市第一在河对岸，你这辈子不会知道。

策略 B · 纯探索（exploration）

专挑地图上空白的地方。

风险：空白区常常是没人去的工业区，你只是在验证“确实难吃”。

策略 C · 聪明折中

维护一张“口味地图”：

- 已知好吃的街区 $\rightarrow$ 猜附近也可能好吃；
- 空白处 $\rightarrow$ 标成“不确定”，不确定越大，越值得去试试。

贝叶斯优化里的期望改善（Expected Improvement, EI），就是策略 C 的数学版。

本讲要讲的，是策略 C 里一个藏了二十年的陷阱：地图用着用着，会把你系统性、持续地推进工业区——而且还可能永远出不来。我们给它起个绰号：瞎逛。

生活元素	工程元素	本讲符号（先混个眼熟）
面馆坐标	设计变量	x
口味得分	性能（如 -L/D、损失）	y
口味地图的“估计均分”	代理模型预测均值	$\hat{y}(x)$

生活元素	工程元素	本讲符号（先混个眼熟）
地图上的"不确定带宽"	预测标准差	$\sigma(x)$
目前吃过的最高分	当前最优（incumbent）	ξ
要不要再去这家的冲动	期望改善	$EI(x)$

先猜后揭：若算法开始专挑"地图上最空白、但也最可能难吃"的点，病在地图（ σ ）还是在尺子（ ξ ）？

揭晓在 §3：主流改 σ ，本文改 ξ 。

策略 C 的藏二十年陷阱（加长）：

口味地图用着用着，会系统性把你推进工业区：好区被采密后 σ 变小，差区反而更空、 σ 更大，EI 听空白的话。


这不像偷懒，像勤奋——所以叫瞎逛更阴。郭振东等指出过度探索与过度开发是一对病，只治贫不够。

2. 叶轮机械中的真实工程死穴：算不起，但停不下

把面馆换成叶片。现场是这样的：

周五下班前，组长丢来一句话——「下个型号的叶型，预算只够再跑几百次 CFD，给我一个比现在更好的外形。」


你面对的不是一道可以慢慢推的数学题，而是一个昂贵黑箱：



昂贵黑箱：设计参数、CFD 求解器与预算三者的关系（手绘笔记版）

指读：左边塞进几何参数 x ，中间黑箱是 CFD，右边吐出一个数 y 。箭头上写着时间与金钱。

- 给一组几何参数 x （厚度分布、安装角、端壁型线……），求解器吐回性能 y ；
- 一次高保真 CFD 可能要几小时到几十小时；
- 一个设计周期能负担的次数往往只有几百到几千次 [原文 P07 §1]；
- 设计变量轻易超过 100 维 [原文 P07 摘要]。



预算沙漏 hourglass：每一次采样都必须值回票价

指读：上半斗是有限次数，每粒沙标着"1小时"；下半斗是高维空间里稀疏的点。红章的意思只有一个——点错一次，就烧一笔不可回收的预算。

在这种现场，EI 成为贝叶斯优化的默认配置，是因为它直接回答：

「这个点，值得再花一次 CFD 吗？」

可 EI 有个久治不愈的毛病：次数已经很多了，结果却卡在次优解上。

此前学界常说：那是过度开发——算法太贪，只在当前最优附近打转。

郭振东等指出：这个解释只对了一半。还有一半叫过度探索，而且更阴险——它长得像"勤奋地探索"，其实是在工业区永久巡逻。这就是本讲反派 瞎逛。

预算沙漏的第二读法：

上半斗是次数，下半斗是维数稀疏。

EI 默认很香，是因为它直接回答「值不值得再花一次」；


但当 z 掉到明显负值，它回答的其实是「空白大不大」，不是「空白处好不好」。

CR-EI

的贡献，是把值班经理请回来：瞎了换班，而不是继续勤奋地错。

3. 数学公式从 0 到 1 推导：一个参数 z ，两种病

【AI】卡壳？数学推导看不懂时，不要硬啃。把你的困惑发给 AI，用苏格拉底引导 Prompt。先自己想 5 分钟，再让 AI 一步步追问。



z pocket card 速记：z 正负与瞎逛换班

指读： $z \gg 0$ 过度开发； $z \ll 0$ 瞎逛；治则抬 ξ 、近 CEI 远 REI。

先把公式关掉。只用餐厅语言说一遍：

你的口味地图在每个位置给出两个量：

估计均分 $\hat{y}$ ，和 不确定带宽 σ 。

你还记得目前吃过的最高分 ξ 。


定义一个无量纲分数 z ，衡量"最高分比估计均分高多少个不确定带宽"。

z 很大 → 地图很有把握地说"这儿不如已经最好的那家" → 你只会已知好区精耕（贪）。


z 很小（很负） → 你几乎只听带宽 σ 的话 → 专往空白处钻；而空白处常常是差区 → 瞎逛。

下面用符号把这话说死。本讲正文只留 3

条核心式；偏导与积分细节在深潜框，不挡路。



一个参数 z 、两种病： $z < -3$ 过度探索与 $z > 3$ 过度开发（手绘手账版）



高斯过程后验与期望改善采集函数（中文标注版）

指读 GP 图：上半幅是后验均值与置信带——样本越密，带子越瘦；下半幅是 EI 曲线，它在“预测更好”与“更不确定”之间拉扯。后面 CEI/REI/GEI 改的都是这张图上的东西。

3B. 本讲符号卡（建议截图留存）

符号	人话	备注
x	设计点（面馆坐标）	向量
$\hat{y}(x)$	地图估计均分	越小/越大取决于问题方向；本文按原文最小化语境理解
$\sigma(x)$	不确定带宽	只反映稀疏，不反映好吃
ξ	目前最优观测	incumbent
z	$(\xi - \hat{y})/\sigma$	全文题眼
Φ, ϕ	标准正态的“累积”与“钟形密度”	可先当两个已知函数
$EI(x)$	去 x 的“期望改善冲动”	
y_{PBS}	当前最优设计点上的值	
$\xi_{\text{Calibrated}}$	被抬高的尺子	CEI 用
δ_1, δ_2	近处/远处地盘开关	互补
y_T	已有样本的中位数	瞎逛预警线
$n_{\text{Breakthrough}}$	连续突破计数	调度用

3C. 主路径只要三条式

核心式 ① — z 的定义

$$[式] \quad z = (\xi - \hat{y}(x)) / (\sigma(x))$$

回译： z 是“比当前最优好（或差）多少个不确定带宽”。

停顿：若 σ 很大，分母大， z

的绝对值容易变小——地图会更听“空白”的话。

核心式 ② — EI 的人话版（结构）

EI 可以写成（原文式 5、式 11）：

$$[式] \quad EI(x) = \sigma(x) \cdot (z \Phi(z) + \phi(z)) = \sigma(x) \cdot EI^*(z)$$

回译：

- 前面的 $\sigma(x)$ 像“冲动的音量”；

- 括号里的 $EI^*(z)$ 像“这首歌好不好听”。

z 决定你唱的是开发调还是探索调。

核心式 ③ — 符号约束（为什么瞎逛不出来）

$$[式] \quad z > 0 \Rightarrow \hat{y}(x^*_{EI}) < \xi \text{（被关在有希望区）}；z \leq 0 \Rightarrow \text{对 } \hat{y} \text{ 无任何约束}$$

回译：

$z > 0$ 时，EI 选出的点，预测值必须优于当前最优——像只在“可能超越冠军”的街区转。

$z \leq 0$ 时，这道门消失。再叠加“ σ 大的地方往往是早期没人去的差区”，算法就会系统性地、持续地冲进工业区。

两种病（看图 L01_s3，不必先啃偏导）：

病名	z 的极端	行为	餐厅版
过度开发	$z > 3$	几乎只跟 $\hat{y}$ 走	死守已经好吃的小巷
过度探索（瞎逛）	$z < -3$	几乎只跟 σ 走	永久巡逻工业区

论文里的触目惊心例子 [原文 P01 §3.1]：

6 维 Hartman6 上，EI 用 LHS 撒 36 个初始点后很快陷入过度探索（ z 在 -5 附近抖， $\sigma^2/\sigma^2_{\text{max}} \approx 1$ ， $\max EI$ 从 10^{-5} 掉到 10^{-20} ）。若按“ $\max EI$ 小于阈值就停”，得到 -2.7890 ，而真全局最优是 -3.0424 。

附带结论（仍属主路径）： $EI(z)$ 在 $z > 0$ 近似线性好优化，在 $z \leq 0$ 指数衰减、极难优化。所以保持 $z > 0$

是明智的*；但简单加阈值停机又会早熟。这就是 CR-EI 要解的死结。

【深潜 | 可跳过】完整解析式、偏导与梯度权重

完整写法（原文式 5）：

$$[式] \quad EI(x) = \int_{-\infty}^{\infty} \xi (\xi - \hat{y}) dF_Y = (\xi - \hat{y}) \Phi(z) + \sigma \phi(z)$$

偏导（用于理解权重，不必会推）：

$$[式] \quad \partial EI / \partial \hat{y} = -\Phi(z), \quad \partial EI / \partial \sigma = \phi(z)$$

负梯度：

$$[式] \quad -\nabla EI(x) = \Phi(z) (\partial \hat{y} / \partial x) - \phi(z) (\partial \sigma / \partial x)$$


- 第一项开发、第二项探索；权重分别是 $\Phi(z)$ 、 $\phi(z)$ 。
 - $z > 3$ 时 $\Phi \gg \phi \rightarrow [式] \quad -\nabla EI|_{\{z>3\}} \approx \Phi(z) (\partial \hat{y} / \partial x) \rightarrow$ 过度开发
 - $z < -3$ 时 $\phi \gg \Phi \rightarrow [式] \quad -\nabla EI|_{\{z<-3\}} \approx -\phi(z) (\partial \sigma / \partial x) \rightarrow$ 过度探索
- 读完可以回到主文 §4，不影响值班手册。

4. 算法控制流：EI / CEI / REI 三兄弟如何轮班

核心思想，一句就够：

别再拧 σ 那个旋钮了（前人都拧过）。改 incumbent 这根尺子 ξ 。

CR-EI：三个采集函数轮流出手



EI / CEI / REI 三者分工与翼型 L/D 对比（cei rei roster，数值见 [原文 P01 Table 2]）

指读：三人分工——EI 主攻、CEI 守近处、REI 侦远处；右侧比分是后文伏笔。

(a) CEI — 校准 EI：治瞎逛，强化近处开发

把尺子从 y_{PBS} 抬高到 $\xi_{\text{Calibrated}} > y_{\text{PBS}}$ ，重算 z ：

$$[式] \quad \tilde{z} = (\xi_{\text{Calibrated}} - \hat{y}(x)) / \sigma(x), \quad CEI(x) = \sigma(x) (\tilde{z} \Phi(\tilde{z}) + \phi(\tilde{z}))$$

回译：许多原来 $z \leq 0$ 的点，被抬尺后变成

$\tilde{z} > 0$ ，重新关回“有希望区”。

再叠加距离窗 δ_1 ：只接受落在当前最优点附近的建议（ $\varepsilon < \|x - x_{\text{PBS}}\| \leq d_T$ 时为 1， ε 常取 0.001 防重复采样）。

(b) REI — 重校准 EI：治死守小巷，强化远处探索


$$[式] \quad REI(x) = CEI(x) \cdot \delta_2 (\|x - x_{\text{PBS}}\|), \quad \delta_2 = 1 - \delta_1$$

回译：REI 只在近处地盘之外取点。 δ_1 与 δ_2

像两块互补的城区规划——CEI 管近，REI 管远。

(c) 值班经理手册 — CR-EI 调度（原文式 17–18）

预警线 y_T = 已有样本目标值的中位数；计数器 $n_{\text{Breakthrough}}$ 看 EI 是否还在“打破纪录”。



CR-EI 值班经理手册三分支决策树 (schedule tree)

指读：从上往下互斥优先。绿：EI 正常只采 EI；黄：有进展则 EI+REI 并行；红：EI 建议点比中位数还差 → 判定瞎逛，改 CEI+REI。

1. $n_Breakthrough = 0$ (EI 正常) → 只采 EI:
〔式〕 $x_new = \{x_EI\}$
2. $n_Breakthrough > 0$ (仍有进展) → EI 与 REI 并行:
〔式〕 $x_new = \{x_EI, x^*_{REI}\}$
3. $y(x_EI) \geq y_T$ (疑似瞎逛) → 改 CEI + REI:
〔式〕 $x_new = \{x_CEI, x_REI\}$

餐厅版回扣：

EI 像主探路员；REI 是派去河对岸的侦察兵；一旦主探路员开始在工业区空转（建议点还不如半数已吃过的店），经理立刻把主探路员换成“只准在冠军店附近精耕”的 CEI，同时保留远侦察。

一句话记住：EI 顺就让它跑，同时派 REI 远眺；EI 一瞎逛，就换成 CEI 收近 + REI 保远。

CEI/REI 餐厅排班表：

| 角色 | 地盘 | 一句话 | | CEI | 冠军店附近 | 抬尺，只精耕有希望区 | | REI | 河对岸 | 保远方选项，防死守小巷 | | EI | 全局默认 | 正常时主攻 | 经理看中位数预警线：建议点还不如半数已吃过的店 → 判定瞎逛换班。

5. 实验验证与量化突破

先报胜负：在 7 个基准和翼型工程题上，CR-EI 相对经典 EI 变体，更快、更稳、更好。

算例一：7 个基准函数（每算法 20 次独立运行；对手 EGO / PEI / GEI / E3I）

函数	EGO	PEI	GEI	E3I	CR-EI
Shekel4 成功率	17/20	20/20	6/20	14/20	20/20
Trid10 成功率	14/20	10/20	13/20	20/20	20/20

原文结论：除 10 维 Trid10 外，CR-EI 在其余 6 个基准上均以更快收敛取得最优 [原文 P01 Table 1 / § 4.3]。

算例二：低速翼型（工程级）

- 参数化：GAN + UIUC 翼型库，13 维；
- 求解器 XFOIL； $Re = 1.8 \times 10^6$ 、 $Ma = 0.01$ 、 $AoA = 0^\circ$ ；
- 目标：最大化升阻比 L/D（实现为最小化 $-L/D$ ）；每组 10 次运行。

指标	EGO	PEI	GEI	E3I	CR-EI
均值 ± 标准差	-239.34 ± 8.60	-240.66 ± 6.41	-240.70 ± 4.57	-242.20 ± 4.48	-246.34 ± 3.56
中位数	-241.44	-242.74	-240.82	-241.92	-248.09

体感换算（只读两格就够）：

- 相对 EGO，平均 L/D 提升 2.92% [由 Table 2: $(246.34 - 239.34) / 239.34$]；
- 标准差 8.60 → 3.56，离散度降 58.6% [由 Table 2] ——不是“平均好看一点”，而是十次里次次更稳。对要签字画押的工程设计，这比均值更救命。

参数敏感性：距离参数 α 、incumbent 参数 β 。Camel6 / Hartman6 扫描显示 $\beta = 0.1$ 综合最优； β

越大越抗瞎逛，但搜索区膨胀，过大则约束作废 [原文 P01 § 4.5]。

翼型工程读法加长：

均值更好：平均 L/D 更香。

标准差下降：十次独立运行更挤在一起——签字要的是可重复，不是一次运气。

$\beta = 0.1$ 是综合甜点：越大越抗瞎逛，过大搜索区膨胀约束作废 [原文 P01 § 4.5]。

6. 审稿人批判与承前启后

把软肋放上可信度刻度（0 = 完全不信，5 = 可当默认工具）：

维度	打分	人话
机理清晰度	4	z 的故事完整、好讲
实验充分度	4	基准 + 翼型，有对照
超参稳健	2	β 、 d_T 、 α 要调； $\beta = 0.1$ 不保证可迁移
理论保证	1	无收敛证明 / regret bound
维数外推	2	天花板约 10 维；真叶栅 100+ 维时 GP 本身先垮
对 GP 质量依赖	2	$\hat{y}$ 、 σ 若糊，调度全糊

可以攻击的点（保留原文力度）：

1. 超参： α 、 d_T 、 β ； d_T 绝对距离、高维下欧氏距离（就是两点之间的直线距离）会「挤成一团」——维度一高，最远点与最近点差不多远，距离这把尺子就钝了。
2. 无理论保证。
3. 维数天花板 ~10；真叶栅 100+ 维时，“抬 ξ ”救不了 GP 失明。
4. 切换逻辑绑在 GP 质量上。

承前：站在 EGO 的 EI 上，用“调 incumbent”统一审视 GEI（调 σ 权重）、E3I（Thompson 样本最优当 ξ ）、PEI（伪 EI）。

启后（下一集预告）：

- 第 02 讲（Filter-GEI）：值班切换思想，搬进“专家+实习生”多保真并行——反派变成集群空转。
- 第 03-04 讲（GSDE / DA-EGO）：本讲 10 维天花板撞墙后，高维必须换门庭。
- 第 08 讲（GTO）：本讲 GAN 13 维翼型，后面升级为梯度反推的生成式迁移。

可信度刻度使用说明：

4 分机理 = 可以教；2 分超参 = 换题要重调；1 分理论 = 别指望 regret bound。

10 维天花板写在这里，是为了让你读到 03/04 时知道：不是 CR-EI 变笨，是 GP 舞台塌了。

附：三调度口令速查

信号	动作
EI 正常	只采 EI
仍有突破	EI + REI 并行
建议点差于中位数	CEI 守近 + REI 保远

餐厅版：主探路员一进工业区空转，经理立刻换人，远侦察不停。

附：从 CR-EI 走向全书

下一站	你带走的问题
02 Filter-GEI	并行与多保真时，谁配见专家？
03-04	10 维天花板破了怎么办？
05	多保真后期是否开始撒谎？
06+	合法形状与场预测、实验信任

本讲是「下一笔预算砸哪」的第一课；后面所有课都在改场景，不改这个母问题。

母问题回声：读完任何后讲，用一句话回答「下一笔预算砸哪」。答不出，说明开场母问题断了，请回第 01 讲。

附：z 的餐厅速记卡

z	人话	风险
$\gg 0$	很有把握不如冠军	过度开发
≈ 0	边界	需调度
$\ll 0$	几乎只听空白	瞎逛

治：抬 ξ 、近 CEI、远 REI、瞎了换班。

翼型算例的工程读法：均值更好是「平均更香」；标准差下降是「十次里更稳」。对要签字的设计，稳往往比均值多 0.1 更救命。数字与出处以 S 5 表为准 [原文 P01 Table 2]。

调度树口袋卡：绿 EI；黄 EI+REI；红 CEI+REI。口袋卡贴显示器，公式放深港。

附：开场母问题检查单（全书通用）

读完任意后讲，用 30 秒回答：

1. 本讲的「一次评估」有多贵？
2. 下一笔预算砸在采样、代理、还是实验？
3. 失败模式（反派）若赢了，报表会不会仍看起来很绿？

答不出第 3 问，说明还在被利用率/云图欺骗。

章末：30 秒复述 · 自测 · 元数据

30 秒复述稿（可朗读）：EI 用 z 在已知好与空白之间折中。 $z \leq 0$ 时约束消失，空白又常是差区，于是瞎逛。CR-EI 不拧 σ 而抬 ξ ，CEI 守近、REI 探远，按是否突破中位数换班。翼型上它均值更好也更稳。

自测（先做再对答案）：

1. 为什么说 σ 大不等于“那里值得去”？
2. CEI 与 REI 的地盘如何用 δ_1 、 δ_2 划分？
3. 三调度里，哪一条专门对付瞎逛？

▼ 点开看参考答案

1. σ 只反映样本稀疏，不反映目标好坏；早期好区被采密后，差区反而更空、 σ 更大。2. $\delta_1=1$ 近处（CEI）； $\delta_2=1-\delta_1$ 远处（REI）。3. 第 3 条： $y(x^*_{EI}) \geq y_T$ 时改 CEI+REI。本讲元数据（读完再看，不挡故事）

项	值
规范编号	01
原始文献	Structural and Multidisciplinary Optimization, 2021, 64: 3549–3567
DOI	10.1007/s00158-021-03038-3
作者	Zhendong Guo, Yew-Soon Ong, Haitao Liu
本地原文	s00158-021-03038-3.pdf
证据等级	A（本地原文逐句可查）
反派绰号	瞎逛
主比喻	30 天找面馆

动手任务

任务：用 code/optimizer.py 的 cr_ei_step 函数，在 2 维 Branin 函数上跑一次 CR-EI，记录三轮调度模式（EI / EI+REI / CEI+REI）各自被触发了几次。

产出文件：your_notes/experiments/L01_CR_EI_experiment.md

验收标准：文件存在且包含：① 你实际运行的代码片段 ② 三轮调度模式的触发记录 ③ 你对“为什么第 X 轮触发了 CEI+REI”的一句话解释

【AI】做完后：用主动回忆 Prompt 做补漏，再用批判收尾 Prompt 做深度加工。

沉淀清单

学完本讲，你应该产出以下文件：

- □ your_notes/knowledge_cards/L01_CR_EI.md — 知识卡片（用模板）

- □ your_notes/experiments/L01_CR_EI_experiment.md — 动手任务记录
- □ 个人 Prompt 库中新增 ≥ 2 个 Prompt（预习 + 批判收尾）

【第02讲】Filter-GEI：老专家与实习生——多保真并行优化怎样把钱花在刀刃上（论文 02）

【靶】开讲前（5 分钟）：用预习向导 Prompt 让 AI 帮你建立直觉框架，再开始读正文。

本讲开场 90 秒


上讲闪回：上讲（CR-EI）：EI 会瞎逛；治则是改 ξ 、近 CEI 远 REI。值班经理管「下一笔预算砸哪」。

本讲反派：「集群空转」

只要带走 3 句口诀：


1. 实习生（LF）铺路，老专家（HF）拍板
2. 滤波门槛 T 决定谁配见专家
3. 相关高就严进，相关差就放宽

主比喻：设计公司：老专家 vs 实习生



Filter 值班卡：相关高严进、相关差放宽

指读：左列相关高→ ω 严进；右列相关差→放宽；中间门槛 T 分流 HF/LF。



第02讲心智图：Filter-GEI 左多保真建模右并行批滤波（mindmap）

看图三秒：与技术双图同构——左多保真建模（大量 LF× 铺路 + 少量 HF● 校准）；右并行批滤波（绿点过门槛 T 入选，灰叉被滤除）；底条口诀「实习生铺路、老专家拍板 / T 决定谁进批 / 相关高严进、相关差放宽 / 别让机房空转」。细节曲线见下节 filter_gei_multifidelity_parallel_zh。本讲赌注：没有门槛的并行，只是让专家更快地淹没在平庸图里。

【补】读本讲前，你只需要先知道 3 件事（都出自 第零章 与 第零章 B · 四张补丁卡；忘了就点回去看一眼，不用背）：1. 高维、昂贵、无导数——HEB 三难（第零章 0.3）2. 多保真就是「粗网格便宜、细网格贵，搭配着用」（第零章 0.2）3. 期望改善 EI 回答的是「这个点值不值得再花一次」（第 01 讲）

1. 生活与物理直觉引子：老专家与实习生

想象你经营一家设计公司，手下有两类人：

- 老专家：画图精准、结论可靠，但时薪 3000 元，一天只能出 1 张图；

- 实习生：速度快、一天能出 10 张图，时薪 300 元，但图纸常有偏差，只能看个大概趋势。

现在要做一个设计招标。聪明的做法显然不是“所有图都让老专家画”（太贵），也不是“全让实习生画”（不可靠）。你会让实习生先铺开画一批，把大致方向摸出来；老专家只在最关键的几张图上出手。

这就是多保真优化（Multi-Fidelity Optimization, MFO）的全部思想。在叶轮机械里：

- 低保真（LF）= 粗网格 CFD（1.2 万单元）、无粘 Euler、二维简化模型；
- 高保真（HF）= 细网格 RANS（10 万单元）、三维全环、带转捩模型。

本文的工程算例中，LF 与 HF 的成本比是 0.1——也就是说，一次高保真的钱能做十次低保真 [原文 P02 §4.3]。

但这里有个二十年的老问题：每轮迭代里，到底哪些点该让老专家（HF）看，哪些点交给实习生（LF）？这就是本文所说的 sample assignment（样本分配）问题。

把招标周历摊开看一遍（趣味回扣）：

工作日	实习生（LF）	老专家（HF）	经理在想什么
周一	狂出 10 张草图	休息	「先把地形摸出来」
周二	再出 10 张	挑 1 张精修	「只在苗头处砸钱」
……	……	……	若没有滤波，专家会被灌进一堆平庸图

若没有 Filter 那道门槛，并行批次里会混进大量「GEI 看起来花哨、其实不配见专家」的点——机房灯亮着，智慧在空转。这就是反派集群空转。

周历回扣：若无 Filter，并行批会塞满「GEI 花哨但不配见专家」的点——灯亮着，智慧空转。

先猜后揭：若本讲反派「集群空转」赢了，你的下一笔 CFD/实验预算会怎样被浪费？揭晓贯穿 §3-§5。

生活元素	工程元素	符号
主比喻侧	低/高保真	y_{LF}/y_{HF}
主比喻侧	缩放因子	ρ
主比喻侧	差异函数	Z_{DF}
主比喻侧	广义 EI/幂次	GEI, g

把「时薪」再算一遍（趣味加长）：


若招标只要 30 张「可信图」，全专家贵、全实习险。混合策略的关键不是拍脑袋比例，而是每一张专家图都对应一个过了门槛的理由——这正是 T 存在的意义。

失败剧本：经理取消滤波器，「GEI 前 10 名全给专家」。两周后专家工位堆满平庸图，实习生反而闲着。机房利用率很高，有效学习率很低。这就是集群空转的生活版。


招标周的正确打开方式：

周一 LF 铺图；门槛决定周二专家看谁；周末对照无滤波是否假快速。周历本身就是算法。

2. 叶轮机械中的真实工程死穴：串行加点浪费了整个机房



指读：上条串行等核；下条 HF+LF 同批；空转是调度病。



串行加点导致集群空转：串行与并行的时间对比（手绘笔记版）

指读：这张图是本讲工程死穴的一张图版本。

传统的多保真 EGO 类算法（如 augmented-EI、VF-EI）有一个共同特征：每轮迭代只加一个样本。

问题在两方面：

1. 贵：一次 CFD 几小时，一个设计周期几百次调用，串行下来是几个月；
2. 浪费：现代计算集群一晚上能同时跑几十个 CFD 作业，单点串行加点意味着大部分核在空转。

同时，已有算法在决定“这个点用 HF 还是 LF”时，往往只看相似性与成本比，没有利用“LF 模型到底靠不靠谱”这一关键信息。本文要解决的，正是这两个痛点：把保真度分配做对，并且一次分配一批。

现场感：周五下班前组长要数——你面对的不是可以慢慢推的练习题，而是算错一次就不可回收的预算。

串行 vs 并行的时间线（人话）：

串行：HF₁ 完成 → 更新模型 → HF₂ → … 墙钟 $\approx n \times t_{LF}$ 。

并行（本讲）：同一轮抛出 {HF 批, LF 批}，墙钟 $\approx \max(t_{HF}, t_{LF})$ ——前提是足够许可证。

软肋里「并行收益绑定许可证」不是抬杠，是工程事实。

集群空转的两种形态：

- 1) 算法串行加点，核在等；
- 2) 算法并行但无 Filter，HF 批次塞满假尖子，核在忙，智慧仍空转。第二种更危险，因为利用率报表是绿的，学习曲线却在骗人。


3. 数学公式从 0 到 1 推导

【AI】卡壳？数学推导看不懂时，不要硬啃。把你的困惑发给 AI，用苏格拉底引导 Prompt。先自己想 5 分钟，再让 AI 一步步追问。

先把公式关掉，用主比喻说一遍：


设计公司：老专家 vs 实习生

本讲反派是「集群空转」。下面公式是这句话的展开；每条核心式尽量带回译。知识总量不删——深潜只是阅读路径，不是垃圾桶。



Co-Kriging 多保真建模与 Filter-GEI 的滤波阈值 T（手绘手账版）

Filter-GEI: 把钱花在刀刃上 (论文 02)



多保真建模与滤波并行加点 (filter GEI multifidelity parallel, 中文标注版)

上图是本讲全部数学的「一张图版本」：左图是多保真建模——低保真模型（橙虚线）便宜但有偏，用大量低保真样本铺路、少量高保真样本（蓝点）校准；右图是 Filter-GEI 的并行加点——GEI 值超过滤波阈值 T 的候选（绿点）才入选并行批，其余被滤除（灰叉）。正文推导的 ω/T 公式，改的就是右图这道「门槛」。

3B. 本讲符号卡 (建议截图留存)

符号	人话	备注
y_{LF}/y_{HF}	低/高保真	成本比 ≈ 0.1
ρ	缩放因子	
Z_{DF}	差异函数	修正后还差多少
GEI, g	广义EI/幂次	g 大偏探索
T	滤波门槛	谁配见专家
ω	相关权重	相关高 $\rightarrow$ 严进

【引】先认符号再读公式；主文核心式有「回译」，装不下的细节仍在正文完整保留（不删知识）。【引】读不动时：本讲 §3 只需抓住核心式+它下面的「回译」；标【深潜|可跳过】的框可整框跳过，直奔 §4 值班手册——不影响你今天会用这套方法。

3C. 主路径公式与推导 (知识全保留)

第一步：多保真代理模型 Co-kriging

把 LF 与 HF 都当成随机过程：〔式〕 $Y_{LF}(x) = \mu_{LF} + Z_{LF}(x), Y_{HF}(x) = \mu_{HF} + Z_{HF}(x)$

回译：把每一条保真度的输出都拆成「一条基准线 μ + 一个围着它起伏的随机偏差 Z 」——这就是高斯过程看世界的方式：先给个大概，再标出哪儿还不确定。这一步负责的是把便宜的和贵的两套数据塞进同一个概率框架，后面才谈得上互相校准。

关键假设是 HF 可以写成 LF 的缩放 + 一个差异函数：〔式〕 $y_{HF}(x) = \rho \cdot y_{LF}(x) + Z_{DF}(x)$

其中 ρ 是缩放因子， Z_{DF} 是差异函数 (discrepancy function)，专门负责刻画 LF 修正后仍与 HF 差多少。这样，LF 负责大趋势，DF 负责补差距，两套高斯过程拼成一个联合协方差矩阵（原文式 4-6）。

第二步：基线采集函数 GEI (广义期望改善)

经典 EI 有个毛病：太贪恋当前最优附近。Schonlau (1997) 把它推广为带幂次 g 的 GEI：

【深潜|可跳过】GEI 的幂次展开与 T_k 递推式（只想知道「 g 大 = 更爱探索」的话，可整框跳过）

〔式〕 $E[(x)^g] = s^g \sum_{k=0}^{\infty} \frac{(-1)^k}{k!} K(g, k) u^{g-k} T_{k, u} = (f_{\min} - \hat{y}(x)) / (s(x))$

〔式〕 $T_0 = \Phi(u), T_1 = -\phi(u), T_k = -u^{k-1} \phi(u) + (k-1) T_{k-2}$

读完可以回到主文 §4 (值班手册)，不影响你今天会用这套方法。

g 越大，越偏向全局探索； $g=1$ 时退化为经典 EI。取若干个不同的 g ，就同时得到一批「有的爱开发、有的爱探索」的候选点——这天然适配并行加点。

第三步：核心创新——给 GEI 装一个「滤波器」(原文式 10-12)

定义一个阈值：〔式〕 $T = \omega \cdot y_{HF-\min} + (1-\omega) \cdot y_{HF-\text{mean}}$

其中 $y_{HF-\min}$ 是当前最优， $y_{HF-\text{mean}}$ 是历史加权平均：〔式〕 $y_{HF-\text{mean}} = (1/\text{iter}) \sum_{i=0}^{\text{iter}} ((1/(n_i)) \sum_{j=1}^n i_{y_{HF}-ij})$

而权重 ω 由 HF 与 LF

的相关性自适应决定——这是全文最漂亮的一笔：〔式〕 $\omega = (1)/(1 + (\delta^2_{DF}/\delta^2_{LF})^{0.5})$

物理含义请务必记住：

- 当 LF 与 HF 高度相关时，差异函数 Z_{DF} 的方差 δ^2_{DF} 相对很小 $\rightarrow$ 分母趋近 1 $\rightarrow \omega \rightarrow 1 \rightarrow$ 阈值 T 贴近当前最优值 $y_{HF-\min} \rightarrow$ 只有非常好（优于 T ）的点才配用 HF，采样极度聚焦于局部开发。
- 当 LF 与 HF 相关性差时， δ^2_{DF} 大 $\rightarrow \omega$ 变小 $\rightarrow$ 阈值 T 贴近历史均值 $\rightarrow$ HF 的投放区域被放大，避免在不可信的 LF 引导下钻牛角尖，转而加强全局探索。

第四步：候选点去重叠

不同 g 给出的候选点可能重合，直接一起投进 Co-kriging 会让协方差矩阵病态。本文用层次聚类（聚类就是把挨得近的样本自动分堆；层次聚类从「每个点各成一堆」出发，每次把最近的两堆并成一堆，直到堆与堆之间都足够远）把重叠点聚掉。

4. 算法控制流

【引】值班手册：先看「什么情况下走哪条分支」，公式是对白速记不是主角。

每轮迭代：

- 用现有 HF + LF 样本拟合 Co-kriging 代理
- 用多个不同 g 的 GEI，生成一批候选点（既含开发点，也含探索点）
- 层次聚类去掉重叠候选点
- 计算自适应权重 $\omega = 1/(1 + (\sigma^2_{DF}/\sigma^2_{LF})^{0.5})$
- 计算阈值 $T = \omega \cdot y_{HF-\min} + (1-\omega) \cdot y_{HF-\text{mean}}$
- 分流：
预测值优于 T 的候选点 $\rightarrow$ 送 HF 仿真（贵，但值得）
其余候选点 $\rightarrow$ 送 LF 仿真（便宜，用于全局探索+降不确定性）
- 一批 HF 与一批 LF 样本同时提交，并行计算

一句话记住：GEI 负责「去哪儿采」，滤波器负责「花多少钱采」。

主比喻回扣：把上面的分支再翻译成「设计公司：老专家 vs 实习生」——若某步在生活里说不通，多半是符号没对齐。

并行批的现场约束清单：

- 许可证 $\geq$ 批大小？否则自动降批。

- LF/HF 网格与求解器队列是否两条线？

- 相关 ω 是否每轮重算，还是冻结了过期相关？

门槛 T 在许可证不足时仍然值钱：它决定稀缺的 HF 名额给谁。

5. 实验验证与量化突破

「多保真成本账本」		
	HF	LF
样本数量	1,000	100,000
成本比例	0.95	0.05
常数因子	0.1	0.1

cost ledger 多保真成本账本 HF/LF 与门槛 T

指读：成本比折算后，多花的 LF 是否换来更好的 HF 最优——读表先问假快速。

先报胜负：

先读结论句与最大那一格，再读全表；表是证据架不是背诵清单。

算例一：5 个基准函数 (Forrester1a/1b、Hartman3+MA3、Ackley5+M A5、Hartmann6+MA6，最高 6 维；初始样本 $HF=3 \times$ 维数、 $LF=6 \times$ 维数；统一用开源 ooDACE 工具箱)

观察点	结果
HF 样本消耗	Filter-GEI 在 5 个算例上始终用最少的 HF 样本取得有竞争力的最优解；无滤波的 GEI-MFO 需要 "significantly more HF samples" (原文自评用语，未给具体倍数) [原文 P02 §4.2]

观察点	结果
迭代次数	由于每轮并行加多样本，Filter-GEI 与 GEI-MFO 的迭代次数远少于单点的 EI-MFO
成功率	Filter-GEI 5 个算例全部成功；VF-EI 在 5 维 Ackley5 上仅 12/20；augmented-EI 在 6 维 Hartman6 上仅 12/20
稳定性	Filter-GEI 迭代次数波动明显小于 VF-EI 与 augmented-EI

[以上均出自原文 P02 § 4.2 与 Table 4]

算例二：GE-E3 涡轮静子叶片气动优化（工程级）

- 设计变量：7 个几何参数；HF 网格 100,701 单元，LF 网格 12,141 单元；
- 初始样本 42 LF + 21 HF（最近邻采样），终止条件为再消耗 35 个 HF 样本；独立运行 5 次；
- 代理模型交叉验证 CV-R² 全部 > 0.85，多数 > 0.95 [原文 Table 7]，说明 Co-kriging 拟合可信。

算法	达到最优所需迭代数	最优值(%) 均值±标准差	LF 样本消耗
Filter-GEI	13 ± 1	2.720 ± 0.0245	91 ± 10
GEI（无滤波）	8 ± 0	2.760 ± 0.0224	79 ± 2
EI	36 ± 0	2.732 ± 0.0192	77 ± 0
VF-EI	45 ± 3	2.748 ± 0.0239	51 ± 3
augmented-EI	51 ± 6	2.726 ± 0.0358	59 ± 9

[原文 P02 Table 8]

怎么读这张表（很关键，别读错）：

- GEI 只用了 8 次迭代就“收敛”了，但收敛到的是最差的最优值 2.760——没有滤波器时，HF 被挥霍在不太有希望的点上，看似快，实则跑偏。
- Filter-GEI 用 13 次迭代拿到全场最好的 2.720，而且 Min 值 2.70 是全场最低。
- 相比串行的 EI / VF-EI / augmented-EI（36 / 45 / 51 次迭代），Filter-GEI 的迭代次数只有它们的 1/3 左右——这正是并行加点的直接收益。
- 代价是：用了更多 LF 样本（91 vs 79）。但按 0.1 的成本比折算，多花 12 次 LF ≈ 1.2 次 HF 的钱，换来最优值从 2.760 降到 2.720，这笔账是划算的。

体感换算：把关键数字换成「工程师的周/月」或「一次签字的风险」——数字才进长期记忆。若原文给了墙钟时间或成本比，优先用原文换算。

账本精读（再钉一次）：
无滤波 GEI：迭代 8，最优 2.760（差）。Filter-GEI：迭代 13，最优 2.720（好）。
慢 5 轮迭代，换的是不跑偏。相对串行 36–51 轮仍是断崖优势。读表先问「快是真快还是假快」。

值班经理对照第 01 讲：01 看是否瞎逛；02 看 LF 还准不准。都是自适应指标，旋钮从 ξ 换成 $\omega-T$ 。

6. 审稿人批判与承前启后
把软肋放上可信度刻度（0=完全不信，5=可当默认工具）：

维度	打分	人话
机理	4	$\omega-T$ 好讲
实验	4	基准+静子
超参	3	d _T /g 集
理论	2	启发式
维数	2	≤7 维
成本比入模	2	未进公式

可以攻击的点：

- "并行"是算法层面的并行，实验是串行模拟的。真拿到工程现场，收益取决于你有多少个 CFD 许可证/核；很多单位恰恰卡在许可证数量上。
- 成本比没有进入公式。 ω 只用了方差比 $\delta^2_{DF}/\delta^2_{LF}$ ，没有把 LF/HF 的实际成本比纳入。本文工程算例的成本比恰好是 0.1；若 LF 也很贵（成本比接近 1），多投 LF 的滤波策略就不一定划算了。
- 阈值与权重的启发式本质。T 取"最优值与加权均值的凸组合"缺乏最优性证明； ω 的自适应也只有定性论证。
- 维数量级有限：基准最高 6 维，工程算例 7 维。真正的多级叶栅是 100+ 维（见论文 07），Co-kriging 在高维下的建模能力本身就是瓶颈。
- 隐含前提"LF 大体能捕捉 HF 趋势"。一旦这个前提在某块区域失效，滤波器反而会把 HF 集中投到被 LF 误导的区域——这正是论文 13（EMFS / MSFO）要处理的问题。

承前：建立在 Co-kriging（Forrester et al. 2007）与 GEI（Schonlau 1997）之上，思想直接继承自同组前作 论文 01（CR-EI）——"用一个自适应指标来决定这一轮怎么采样"。

启后：- 论文 13（EMFS / MSFO）：正面处理"LF 在某些区域反而误导优化"的场景，用 DBSCAN 找出多保真代理建不准的区域，在那里改建单保真代理；- 论文 07（GSDE）：把优化从"低维多保真 + 贝叶斯"推进到"126 维 + 代理辅助进化"；- 论文 11（DA-EGO）：把"自适应分配"从保真度维度迁移到子空间维度。

Table 8 再读（防假快速）：
无滤波 GEI：迭代少、最优差。
Filter-GEI：迭代略多、最优好。
串行基线：迭代是三倍级。
读表顺序：最优值 → 是否跑偏 → 迭代 → LF 成本折算 [原文 P02 Table 8]。

附：Filter 值班卡（可打印）

本轮信号	经理口令	对应公式角色
LF-HF 相关很高	「严进：只有尖子见专家」	$\omega \rightarrow 1$ ，T 贴 y _{HF-min}
LF-HF 相关崩了	「放宽：专家多看全局」	ω 变小，T 贴均值
候选点扎堆	「层次聚类去重叠」	防协方差病态
集群有空核	「HF 批 + LF 批同时交」	反派集群空转的直接解药

和 CR-EI 的对照表（请钉在显示器边）：

	第 01 讲 CR-EI	第 02 讲 Filter-GEI
反派	瞎逛	集群空转
自适应旋钮	ξ （尺子）	$\omega-T$ （门槛）
并行？	近 CEI + 远 REI 可并行	HF 批 + LF 批 并行
多保真？	通常单保真 GP	Co-kriging 标配

成本比 0.1 的心算模板：
多花 Δn_{LF} 次低保真 $\approx 0.1 \cdot \Delta n_{LF}$ 次高保真。
若最优值从 2.760 降到 2.720，问自己：这 0.040 个点，值不值那 1.2 次 HF 的钱？——原文 Table 8 的答案是值 [原文 P02 Table 8]。
读表口诀：先看最优值，再看迭代数，最后看 LF 消耗。无滤波 GEI「迭代少但最优差」= 假快速。

附：并行加点的许可证现实
算法说「一批 HF + 一批 LF」时，现场常卡在：

- CFD 许可证数 < 批大小；
- 队列策略把并行拆回串行；
- LF 与 HF 网格流程不共享，调度摩擦大。

所以 § 6 软肋不是抬杠：并行收益是「算法可达上限 × 许可证可达上限」的乘积。Filter 仍值得做——即使批变小，门槛 T 依然决定谁能见专家。

附：相关高/低的经理台词

相关	台词	T 行为
高	「只有尖子见专家」	严，贴最优
低	「专家多看全局，防被带沟」	松，贴均值


附：Filter-GEI 上线前 10 分钟检查

1. 成本比是否仍约工程设定量级（本文算例 0.1） [原文 P02 §4.3] ？
2. ω 是否每轮更新？冻结相关会让门槛过时。
3. 批大小是否超过许可证？超过则降批，不降门槛逻辑。
4. 对照无滤波 GEI：若「更快但更差」，记为假快速案例。
5. 相关崩塌时，HF 批是否自动放大探索——对应 ω 变小。

经理一句话：GEI 找点，Filter 分钱；并行是手段，不跑偏才是目的。

图卡：许可证墙


算法批大小 $\times$ 许可证/队列可达 = 实际墙钟收益。批可变小，门槛 T 逻辑不降——Filter 仍决定谁配见专家。



license batch wall: 并行上限 = 算法批大小 $\times$ 许可证可达

图卡： ω -T 松紧旋钮

ω 高 $\rightarrow$ T 严（只有尖子见专家）； ω 低 $\rightarrow$ T 松（专家多看全局防带沟）。GEI 找点，Filter 分钱。



omega T knob: 相关高严进、相关差放宽的 Filter 旋钮

图卡：假快速

迭代少但最优差 =

假快速。读表口令：先看最优值，再看迭代数，最后看 LF 消耗；无滤波 GEI 常栽在这里。



false fast: 迭代少但最优差的无滤波假快速

章末：30 秒复述 · 自测 · 元数据

30 秒复述稿（可朗读）：多保真是实习生铺路、专家拍板。Filter-GEI 用多 g 的 GEI 出一批点，门槛 T 分流 HF/LF； ω 听相关——高严进、差放宽。静子上它比无滤波更不跑偏，比串行少大量轮次。反派是集群空转。

自测（先做再对答案）：

1. 成本比 0.1 意味？多 12 次 LF $\approx$ 几次 HF？
2. T 变严 HF 怎样？谁拧松紧？
3. 相关差为何放宽 T？

▼ 点开看参考答案

1. 一次 HF $\approx$ 10 次 LF；12 次 LF $\approx$ 1.2 次 HF。
2. 更少点见专家； $\omega \rightarrow 1$ 时 T 贴最优。
3. LF 不可信时严进会被假尖子骗；放宽让 HF 看全局。本讲元数据（读完再看，不挡故事） | 项 | 值 | :--- | :--- | 规范编号 | 02 | 原始文献 | Structural and Multidisciplinary Optimization, 2021, 64: 1457–1468 | | DOI | 10.1007/s00158-021-02931-1 | | 作者 | Zhendong Guo, Qineng Wang, Liming Song, Jun Li (西安交通大学) | | 本地原文 | s00158-021-02931-1.pdf | | 证据等级 | A (本地原文逐句可查) | | 反派绰号 | 集群空转 | | 主比喻 | 设计公司：老专家 vs 实习生 |

动手任务

任务：用 code/multifidelity.py 的 filter_gei_threshold 函数，分别计算 $\sigma^2_{DF} = 0.01, 0.1, 1.0, 10.0$ 时的 ω 和 T 值（固定 $\sigma^2_{LF} = 1.0, y_{HF-min} = 2.0, y_{HF-mean} = 5.0$ ），观察 ω 和 T 的变化趋势。

产出文件：your_notes/experiments/L02_Filter_GEI_threshold.md

验收标准：文件存在且包含：① 4 组 (σ^2_{DF}, ω, T) 的计算结果表格 ② 你对“为什么 σ^2_{DF} 越大 T 越靠近均值”的一句话解释

【AI】做完后：用主动回忆 Prompt 做补漏，再用批判收尾 Prompt 做深度加工。

沉淀清单

学完本讲，你应该产出以下文件：

- ☐ your_notes/knowledge_cards/L02_Filter_GEI.md — 知识卡片（用模板）

- your_notes/experiments/L02_Filter_GEI_threshold.md — 动手任务记录
- 个人 Prompt 库中新增 ≥ 2 个 Prompt

【第03讲】GSDE：126 维的奇迹——为什么贝叶斯优化在高维叶栅面前必须让位（论文 07）

【靶】开讲前（5 分钟）：用预习向导 Prompt 让 AI 帮你建立直觉框架，再开始读正文。

本讲开场 90 秒

上讲闪回：Filter-GEI 把便宜评估用起来；维度 100+ 时 GP 先失明。第 01 讲 10 维天花板，本讲正面撞上。

本讲反派：「维数灾难」

只要带走 3 句口诀：

1. 高维别硬上 Kriging
 2. RBF 像橡胶膜，一次解线性系统
 3. 约一成预算换接近 DE 的增益（1500/20000，+1.104%/+1.115%） [原文 P07 Table 3]
- 主比喻：多排叶片是一支必须一起训练的隊伍

第03讲心智图：GSDE 扛 126 维



第03讲心智图：GSDE 高维 RBF 与 DE 紧耦合（mindmap）

看图三秒：中心 GSDE（126 维名义空间）；四支——放弃 GP 换 RBF、DE 紧耦合、7 排一起练（ $18 \times 7 = 126$ ）、预算约 $1/13$ （[原文 P07 Table 3] 1500 vs 20000 次 CFD）；底条反派「维数灾难 + 评估太贵」。本讲赌注：在 126 维上硬上 GP，会先失明再空转；不换路线就只是在调一个看不见的核。

【补】读本讲前，你只需要先知道 3 件事（都出自 第零章 与 第零章 B · 四张补丁卡；忘了就点回去看一眼，不用背）：1. 126 维里撒 1000 个点，平均每维只能分成 1.056 份（第零章 0.3）2. 没有导数可用，所以只能用无导数 / 进化类方法（第零章 0.3）3. 端壁、叶栅、中弧线这类几何名词（卡③ B.3）

1. 生活与物理直觉引子：为什么不能“一排叶片一排叶片地优化”



team formation 7 排叶片必须一起练

指读：排间传球（尾迹/旋流）改了，单排最优作废。

先建立一个物理直觉。压气机不是一个叶片在战斗，而是一支队伍在战斗。

空气从第 1 排叶片流过时，会在出口留下“尾迹”和“旋流”；第 2 排叶片吃到的，正是被第 1 排搅过的气流。如果你把第 1 排单独优化到极限，第 2

排的进口条件就变了，它的最优形状也随之改变——反过来又影响第 1 排。

这就是为什么原文强调：为充分考虑叶片排与级之间的相互作用，两级以上的叶栅必须同时优化 [原文 P07 摘要]。

代价是变量数的爆炸。先把被计数的对象钉死，再谈算法——否则「18 维」「126 维」只是口号。

① 几何对象 [原文 P07 § Geometry definition / Blade parameterization]

- 一台 3.5 级压气机：进口导叶 S0 + 三个低压级 R1/S1、R2/S2、R3/S3，共 7 排叶片。
- 级 $\neq$ 排：一对「转子+静子」常称一级；此处 3.5 级 = 1 排导叶 + 3 个完整级，排数跟原文，不靠常识瞎加。
- 优化对象是各排叶片的三维形状（NURBS 截面 + 积叠；NURBS 就是工业界通用的曲线曲面表达方式，只用少量控制点就能画出光顺形状），7 排同时进同一个设计向量。

② 单排 18 维怎么来？（计数单位 = 优化器接收的独立标量，不是图上的点数） [原文 P07 Blade parameterization; Table 2]

口径警告：控制点是几何操纵对象；设计变量才是维数。一点可以固定（0 维）、只沿法向动（1 维）、或不进优化向量。

块	原文设定	独立标量
截面	根 / 中 / 尖 共 3 个二维截面，蒙皮成三维叶片	—
只动哪面	只调吸力面（压力面不动） [原文]	—
每截面控制点	吸力面 7 点：前缘、尾缘固定；其余 5 点沿拟合曲线法向主动移动；每点 1 标量	$3 \times 5 = 15$
积叠（弯/掠）	中截面周向平移 1 + 尖截面周向平移 1 + 尖截面轴向平移 1	3
单排合计	原文：18 design variables ... each blade	$15 + 3 = 18$

旧讲义曾缩写成「根/中/尖各 5 点 + 周向平移 + 轴向平移」，字面 $5 \times 3 + 1 + 1 = 17 \neq 18$ ——是把 3 个积叠标量收成两个词的转述错误，不是原文少一维。已按 PDF 纠正。

③ 整机 126 维

原文直接写明：7 排 $\times$ 每排 18 = 126

个设计变量（名义输入维） [原文 P07 Blade parameterization / 摘要 126 variables]。

乘法前提（原文均满足）：7 排都优化、每排同构

18、无跨排共享、此处未改报「有效自由度」。

〔式〕 单排 18（标量） $\times$ 7 排 = 126 维名义设计空间 [原文 P07]

而一个设计周期里，你只负担得起几百到几千次 CFD [原文 P07 摘要]。126 维里撒 1000 个点，平均每维约 $1000^{1/(126)} \approx 1.056$ 份——比「每个方向一分为二」还稀。

这就是所谓高维昂贵黑箱（High-dimensional Expensive Black-box, HEB）问题。

量级感再钉一根钉子：

一次 3.5 级压气机 CFD ≈ 1 –1.5 小时 [原文 P07]。

DE 要两万次量级，就是两个月量级的墙钟时间；GSDE 用约 1500 次，大约一周。

你不是在省「几次点击」，你是在省工程师的整个季度。

队伍比喻回扣：第 1 排改理想、第 2

排入口就变了——单独优化每一排，在物理上就是做错题。

量级钉：单次 CFD 约 1–1.5 小时。DE 两月，GSDE 约一周——省的是工程师的季度。

先猜后揭：若本讲反派「维数灾难」赢了，你的下一笔 CFD/实验预算会怎样被浪费？揭晓贯穿 §3–§5。

生活元素	工程元素	符号
主比喻侧	维度 126	D
主比喻侧	三次 RBF	$\phi(r)=r^3$
主比喻侧	DE 参数	F, CR

生活元素	工程元素	符号
主比喻侧	种群	N

队伍训练的反例：

「先把第1排优化到头再冻住」像让前锋单练冲顶却不让中场传球——进口边界一变，单排最优作废。两级以上必须同时优化，是流动耦合硬约束 [原文 P07 摘要] 。

126 维体感：想「7 个人各 18

个动作要领，同一套战术」；代理是陪练，CFD 是正式出场次数。

126 维的第二个类比：

不是 126 个独立旋钮，而是 7 排叶片的联合战术板。

改第 1 排出口，第 2 排进口边界条件改写——单独最优是物理错题。

GSDE 用 RBF+DE 紧耦合，是因为 GP 在这个维度上先失明。

队伍战术板（加长）：

7 排叶片像 7 个位置：前锋的冲顶依赖中场传球角度。

你把第 1

排「优化到头」并冻结，等于让前锋在错误传球线路上练一百次——第 2 排进口旋流一变，单排最优当场作废。

原文坚持两级以上必须同时优化，不是方法论偏好，是流动耦合的硬约束 [原文 P07 摘要] 。


126 维的第三个体感：

1000 个点摊在 126 维，每个方向约 $1000^{1/126} \approx 1.056$

份——连「一分为二」都做不到。

这时还问 GP「哪里不确定」，答案本身就不可信。

2. 叶轮机械中的真实工程死穴：高斯过程在高维下会“失明”



高斯过程在高维下的四个软肋与 GSDE 的路线选择 (kriging blind in high dim, 手绘笔记版)

指读：这张图是本讲工程死穴的一张图版本。

第 01 讲的 CR-EI、第 02 讲的 Filter-GEI 都建立在高斯过程 (Kriging) 之上。它们很优雅，但有个致命的软肋：

问题	后果
GP 的协方差矩阵随样本数 n 呈 $O(n^3)$ 增长	样本上千就非常慢
高维下核函数的长度尺度难以估计	代理模型拟合失真
高维下“距离”失去区分度 (距离集中效应)	“哪里不确定”这件事本身就不确定了
EI 类采集函数需要在整个空间上全局最大化	高维下这个子优化本身就很难

所以本文做了一个路线选择：放弃贝叶斯优化框架，改用进化算法（差分进化 DE）打底，把代理模型作为“局部搜索加速器”嵌入进去。这就是 GSDE (Generalized Surrogate-assisted Differential Evolution) 。

现场感：周五下班前组长要数——你面对的不是可以慢慢推的练习题，而是算错一次就不可回收的预算。

为何 GSDE「不时髦也选 RBF」：GP 的

$O(n^3)$ 、高维核长度尺度、距离集中、EI 子优化——四只钉子。RBF 一次解线性系，是工程上的少即是多。

GP 四软肋 → GSDE 四对策（对照表）：

GP 软肋	后果	GSDE 对策
$O(n^3)$ 协方差	样本上千训练炸	局部 RBF，一次解线性系
高维长度尺度难估	拟合失真	不抠核超参，橡胶膜直接铺

GP 软肋	后果	GSDE 对策
距离集中	「不确定在哪」失效	代理嵌入 DE 生成基因，不靠全局 EI 寻峰
EI 子优化也难	采集函数本身卡死	进化 + 有限真 CFD 名额

选 RBF 不是赶时髦，是工程上的少即是多。


3. 数学公式从 0 到 1 推导

【AI】卡壳？数学推导看不懂时，不要硬啃。把你的困惑发给 AI，用苏格拉底引导 Prompt。先自己想 5 分钟，再让 AI 一步步追问。


先把公式关掉，用主比喻说一遍：

多排叶片是一支必须一起训练的队伍

本讲反派是「维数灾难」。下面公式是这句话的展开；每条核心式尽量带回译。知识总量不删——深潜只是阅读路径，不是垃圾桶。



3.5 级压气机 126 维设计空间与 GSDE 的代理辅助流水线（数值见 [原文 P07 Table 3]，手绘笔记版）



GSDE 与 DA-EGO 的高维路线对比 (GSDE and DA-EGO in high dimension, 中文标注版)

上图左半支是本讲 (GSDE) 的路线：放弃贝叶斯、拥抱进化，代理模型直接参与生成子代基因；右半支是第 04 讲 (DA-EGO) 的路线：把高维切成低维子空间，各自优化后再用精英点聚合。两条路线是对同一个难题的两种回答。

3B. 本讲符号卡（建议截图留存）

符号	人话	备注
D	维度 126	7 排 × 18
$\phi(r)=r^3$	三次 RBF	橡胶膜
F, CR	DE 参数	0.3/0.9
N	种群	50
x_i^*	预测父点	局部 RBF+PSO
T=9	每轮真 CFD 名额	

【引】先认符号再读公式；主文核心式有「回译」，装不下的细节仍在正文完整保留（不删知识）。【引】读不动时：本讲 §3 只需抓住核心式 + 它下面的「回译」；标【深潜 | 可跳过】的框可整框跳过，直奔 §4 值班手册——不影响你今天会用这套方法。

3C. 主路径公式与推导（知识全保留）

第一步：为什么代理模型换成 RBF

原文指出：在高维设计空间，RBF 的预测精度强于其他常见代理，且训练时间随变量数增长仍可接受。GSDE 采用三次 RBF + 线性多项式余项：〔式〕 $\hat{f}(x_{\text{new}}) = \sum_{i=1}^n \lambda_i \phi(\|x_{\text{new}} - x_i\|) + p(x_{\text{new}})$

回译：新点的预测值=每个已知样本按「离它多远」投出的一票（近的票重、远的票轻），再叠上一条全局的多项式趋势线。这一步负责的是用 RBF

织一张穿过所有已知样本的橡胶膜——它替代高斯过程，成为 126 维下还算撑得住的代理。

【深潜 | 可跳过】RBF 核函数与待定系数的一次性解出（实现细节；只需知道「一张穿过所有样本的橡胶膜，不用迭代调参」）

〔式〕 $\phi(r) = r^3, p(x) = \sum_{i=1}^D b_i x_i + a$

待定系数共 $n+D+1$ 个 $(\lambda_1 \cdots \lambda_n, b_1 \cdots b_D, a)$ ，由一个线性方程组一次性解出（不需要迭代优化超参数，这正是 RBF 在高维工程场景的实用之处）：

分块线性系统 $\Phi \lambda + P c = F, P^T \lambda = 0$ ，其中核矩阵 $\Phi_{ij} = \phi(\|x_i - x_j\|)$ ， P 为多项式基矩阵， λ 与 c 为待定系数。

读完可以回到主文 §4（值班手册），不影响你今天会用这套方法。

第二步：策略——代理引导的差分进化（GSDE 的核心）

经典 DE 的 best/1 变异是：〔式〕 $v_i = x_{\text{best}} + F(x_{r1} - x_{r2})$ ， $N = 50, F = 0.3$ （默认）

GSDE 的关键改动是给每个父代点 x_i 建一个局部 RBF：

- 训练点取距 x_i 最近的 $5 \times D$ 个样本（126 维时即 630 个）；
- 局部区域半径自适应：

〔式〕 $r_i = 0.5 D_{i,\max} \sqrt{D}$

其中 $D_{i,\max}$ 是 x_i 到其他父代点的最大距离——维数 D

越高，这个根式越接近 1，半径越大，这正是对高维稀疏性的补偿；- 用 PSO（种群 50、迭代 100 次）在这个局部 RBF 上找出预测父点 x_i^* 。

然后做指数交叉，把变异点与预测父点缝合成候选个体：

二项式交叉（默认 $CR=0.9$ ）：从随机维 j_{rand} 起，若 $\text{rand}[0,1] \leq CR$ 则取试验分量 $v_{i,j}$ ，否则保留预测父点分量 $x_{i,j}$ ，记作〔式〕 $u_i = \text{Crossover}(v_i, x_i; CR = 0.9)$

请特别注意这里的设计哲学：在传统“DE + 代理”的松散耦合里，代理模型只用来筛选已经生成的候选点；而在 GSDE 里，代理模型直接参与生成子代的基因—— x_i^* 的某些维度会直接进入下一代。原文说得很明确：这种“紧耦合（tight form）”正是 GSDE 在高维下仍能表现良好的特殊之处 [原文 P07 § Proposed algorithm]。

第三步：策略二——基于父代的选择（省下真金白银）

每轮生成的候选点如果全做 CFD，开销受不了。GSDE 的办法是：按父代适应度给候选点排序，只挑前 $T=9$ 个去做真实 CFD。理由是“优秀父代产生的子代更可能携带好基因”。这 9 个子代随后替换父代中最差的 9 个点。

第四步：策略三——基于代理的局部搜索（并行进行）

在当前最优点 x_{best} 附近再建一个局部 RBF，用 PSO 找局部最优：


〔式〕 $x^* = \arg\min \hat{f}_{\text{RBF}}(x), x \in [x_{\text{best}} - \Delta, x_{\text{best}} + \Delta] \cap [lb, ub]$

其中 Δ 取“ x_{best} 到训练点中适应度最差者距离”的一半。若 x^* 优于 x_{best} 就替换它。

这三条策略是并行执行的——这是 GSDE

适配真实计算集群的工程设计。

4. 算法控制流



factory stations GSDE 三工位并行

指读：①局部RBF出预测父点 ②父代优选只送有限真CFD ③最优父点附近局部搜索——三路并行。

【引】值班手册：先看「什么情况下走哪条分支」，公式是对白速记不是主角。

初始化：采样 → 建 RBF 代理

每轮迭代（三路并行）：

① 代理引导差分进化

对每个父点 x_i ：

局部 RBF（5D 个最近邻点，半径 r_i 自适应）

PSO 在局部 RBF 上求预测父点 x_i^*

best/1 变异 $v_i = x_{\text{best}} + F(x_{r1} - x_{r2})$

指数交叉 v_i 与 $x_i^* \rightarrow$ 候选 u_i

② 基于父代的选择

按父代适应度给所有 u_i 排序，只取前 $T=9$ 个送真实 CFD

用这 9 个子代替换父代中最差的 9 个

③ 基于代理的局部搜索（并行）

在 x_{best} 附近建局部 RBF，PSO 求 x^* ，优于 x_{best} 则替换

一句话记住：高维别硬上 Kriging；进阶：RBF 像橡胶膜，一次解线性系统。

主比喻回扣：把上面的分支再翻译成「多排叶片是一支必须一起训练的队伍」——若某步在生活里说不通，多半是符号没对齐。

三工位并行的集群含义：


工位①生成候选基因；工位②只让前 T 个做真

CFD；工位③在精英附近局部挖。

墙钟接近「最慢工位」，而不是三工位串行相加——前提是许可证与队列允许。

回扣：维数灾难的解药不只是数学，也是调度。

5. 实验验证与量化突破



budget 1500 vs 20000: GSDE 与 DE 墙钟 [原文 P07 Table 3]

指读：约 7.5% CFD 预算换约 99% 增益 [原文 P07 Table 3] ——省的是季度。

先报胜负：

先读结论句与最大那一格，再读全表；表是证据架不是背诵清单。

算例一：4 个经典数值函数（50–100 维）

设计空间归一化到 [0,1]，最大函数调用 1000 次，每算法独立运行 10 次；基线为 DE、GA 与当时的先进代理辅助进化算法

GSGA。结论：GSDE 在 1000

次调用内找到真实最优解，收敛速率远优于对比算法 [原文 P07 摘要与 Performance validation 节]。

算例二：3.5 级压气机，126 维（工程级） [以下设置均出自原文 P07 § Geometry definition / § Numerical method / Table 2]

- 几何：进口导叶 S0 + 3 个低压压气机级（R1/S1、R2/S2、R3/S3），共 7 排叶片；NURBS 参数化，每排 18 独立标量 [原文 P07 Blade parameterization; Table 2]（三截面吸力面各 5 个法向主动点，每截面 7 点中 LE/TE 固定；+ 中周向 + 尖周向 + 尖轴向 共 3 个积叠标量）；型线控制点变化幅度为轴向弦长的 $\pm 0.6\%$ / $\pm 1.2\%$ / $\pm 1.5\%$ / $\pm 1.2\%$ / $\pm 0.6\%$ ，周向平移 $\pm 15\%$ ，轴向平移 $\pm 5\%$ ；
- 求解器：NUMECA FINE/Turbo，三维定常 RANS + Spalart-Allmaras；O4H 六面体结构网格 322 万节点，第一层 0.001 mm 保证 $y^+ < 1$ ；
- 工况：进口总温 288.15 K、总压 101,325 Pa，出口平均静压 164,000 Pa，转速 8297.7 RPM，壁面绝热无滑移；
- 目标与约束：最大化 $\eta_{is}/p(x)$ （ p 为罚函数：约束处理最简单的一种做法就是罚函数——违反约束就扣分，把带约束的问题变成不带约束的问题），约束总压比在基准的 [0.98, 1.05] 倍、流量在基准的 [0.98, 1.02] 倍内。

[以上几何、求解器、工况与约束设置均出自原文 P07 § Geometry definition、§ Numerical method、Table 2 与式 9]

参数	参考设计	GSDE(1000)	GSDE(1500)	DE
等熵总对总效率 η_{is} (%)	85.825	86.867	86.929	86.940

参数	参考设计	GSDE(1000)	GSDE(1500)	DE
效率增量 (%)	—	+1.042	+1.104	+1.115
总压比相对变化 (%)	—	-0.068	-0.074	-5.7×10^{-3}
流量相对变化 (%)	—	+0.30	+0.33	+0.66
CFD 次数	—	1000	1500	20,000

[原文 P07 Table 3]

怎么读这张表——这里必须诚实，不能夸大：

- DE 的最终效率增量 +1.115% 其实略高于 GSDE 的 +1.104%。所以正确的结论不是“GSDE 结果更好”，而是：GSDE 用 1500/20000 = 7.5% 的 CFD 预算，拿到了 DE 约 99% 的效率增益 ($1.104/1.115 \approx 99.0\%$)。
- 在硬件上（双路 AMD EPYC 7502 32 核 + 256 GB 内存的微服务器，单次 CFD 1~1.5 小时，每轮并行 10 个样本）：GSDE 完成 126 维优化约 1 周，DE 完成同等任务超过 2 个月 [原文 P07 Result analysis]。
- 换算成原文的表述：GSDE 的计算开销约为常用进化算法的 1/13。

△旧版白皮书把这里写成“GSDE 优于 DE”，是不严谨的。请以本表为准。
气动机理（后验观察）：优化后 S0 向吸力面倾斜并后掠；其余三级叶片均向压力面倾斜；三个转子（R1/R2/R3）前掠、三个静子（S1/S2/S3）后掠；除 S0 外，六个叶片的吸力面型线普遍变薄 [原文 P07 § Aerodynamic analysis]。

体感换算：把关键数字换成「工程师的周/月」或「一次签字的风险」——数字才进长期记忆。若原文给了墙钟时间或成本比，优先用原文换算。

口号化（但诚实）：「用一成预算拿九成九增益」来自 1500/20000 与 1.104/1.115。DE

终值仍略高，话术必须是预算-增益权衡，不是全面碾压。

路线分叉：本讲放弃贝叶斯；下讲 DA-EGO

改造贝叶斯。你是换队伍（进化）还是换场地（子空间）？

6. 审稿人批判与承前启后

把软肋放上可信度刻度（0=完全不信，5=可当默认工具）：

维度	打分	人话
工程	5	126维跑通
预算比	5	7.5%≈99%增益 [原文 P07 Table 3]
超参	2	缺敏感性
多点工况	1	只设计点
局部性	2	5D近邻存疑

可以攻击的点（以下为本文方法层面的合理质疑，涉及的设置参数均出自原文 P07 § Proposed algorithm）：

- 只在设计点优化。现代压气机要求在整个工作线（近失速到近堵塞）上都达标，单点优化得到的叶片很可能在非设计点恶化——本文未做多点优化。
- 超参数多且缺乏敏感性分析。N=50, F=0.3, CR=0.9, T=9, 5D 训练集、PSO(50×100) 基本都是默认值，原文没有报告它们对结果的影响 [原文 P07 参数设置段：种群规模取 50 以平衡精度与开销，F=0.3、CR=0.9、局部训练集 5D]。
- 局部 RBF 在高维下的“局部性”存疑。取 5D=630 个“最近邻”点，在 126 维空间里，最近邻与最远邻的距离差距会因距离集中效应而急剧缩小，“局部”可能已经不再局部。
- 约束处理用了罚函数，而非更严谨的可行性保持策略；最终方案的总压比相对基准下降 0.074%，虽在约束带内，但确是“贴着下边界”过约束 [原文 P07 Table 3 / § Result analysis]。
- 气动机理是后验解释，没有提炼成可迁移的设计准则（例如“转子前掠多少度能改善多少”）。[以上第 1–5 点均基于原文 P07 报告的方法设置与结果所作的合理质疑；其中 N=50、F=0.3、CR=0.9、T=9、5D 训练集、PSO(50×100) 等参数出自 § Proposed algorithm]

承前：直接回应了论文 01 (CR-EI) 遗留的天花板——CR-EI 最高只测到 10 维，而 GSDE 把可用维数推到 126 维。路线选择上，它放弃了贝叶斯优化的优雅，换取了工程可用性。

启后：- 论文 11 (DA-EGO)：GSDE 走的是“放弃贝叶斯、拥抱进化”；DA-EGO 反过来问“那能不能改造贝叶斯框架本身来扛高维”，答案是用动态子空间分解；- 论文 08 (SW-VAE) 与论文 17 (GTO)：GSDE 仍需 1500 次 CFD [原文 P07 Table 3；数值另见本讲 § 5 表]，这两篇试图用生成式先验 + 知识迁移把样本量再降一个量级；- 论文 19 (SHAP-Turbine)：126 维优化做完之后，自然会追问“这 126 个变量里到底谁在起决定性作用”——这正是 SHAP 可解释性挖掘的出发点 (SHAP 就是一套给每个设计变量打「贡献分」的可解释性工具，用来回答「这 126 维里到底谁说了算」；详见第 13 讲)。

墙钟对照 (再读一遍 Table 3)：GSDE 约 1500 次 CFD、约一周；DE 约 20000 次、超过两月 [原文 P07 Table 3 / Result analysis]。增益 1.104% vs 1.115%——话术必须是预算-增益权衡，不是「全面碾压 DE」。诚实口号墙：
✓ 「用约一成预算拿约九成九增益」(1500/20000 与 1.104/1.115) [原文 P07 Table 3]
✗ 「GSDE 全面碾压 DE」——终值 DE 仍略高。
气动机理 (倾斜/掠/变薄) 是后验观察，不要写成可迁移设计准则，除非另有归因讲次支撑。

附：高维路线选择卡

路线	代表	一句话
换队伍	GSDE (本讲)	弃 GP, RBF+DE 紧耦合
换场地	DA-EGO (04)	保贝叶斯, 动态子空间
换先验	06-08	生成流形降有效维

维数一爆，先选路线，再调超参。

附：GSDE 超参「先别乱拧」清单

符号	默认直觉	乱拧风险
N 种群	太大贵、太小多样性差	预算爆炸或早熟
F / CR	缩放与交叉	搜索过猛/过粘
T 真 CFD 名额	每轮送几个	太小学不动、太大变纯 DE
局部邻域 5D	高维「局部」存疑	距离集中下名不副实

原文缺系统性敏感性时，工程上先锁默认，用对照实验小步改一两个旋钮 [原文 P07 § Proposed algorithm]。

附：紧耦合 vs 松耦合 (一句话)


松：代理只筛选已生成的候选。

紧 (GSDE)：代理参与生成子代基因——x* 的某些维直接进入下一代。

高维能打，往往因为紧。

图卡：高维失明与 GSDE 让位


维数 100+ 时经典 GP 协方差「失明」；GSDE 用代理+进化+评估流水线扛 126 维叶栅。贝叶斯优化在高维叶栅面前必须让位——不是理论过时，是尺度换了。



dim curse GSDE: 126 维 GP 失明让位代理进化流水线 [原文 P07 Table 3]

图卡：紧耦合 vs 松耦合

紧耦合把代理-进化-评估咬在同一进程；松耦合用队列把三工位拆开可换可并行。高维叶栅现场常常先松后紧——先跑得动，再咬死精度。



tight vs loose couple: GSDE 紧耦合咬死 vs 松耦合三工位

图卡：超参先别乱拧

早期别乱拧种群/变异/换代理；先对齐预算墙钟、工位并行与 DE 基线对照。能跑稳再微调。



hyperparam freeze GSDE: 超参先别乱拧，先对齐预算与基线

章末：30 秒复述 · 自测 · 元数据

30 秒复述稿 (可朗读)：126 维要整队练，不能一排排抠。GP 在高维失明，GSDE 改用 RBF+DE 紧耦合，三工位并行，每轮只送有限真 CFD。约 1500 对 20000 次，增益接近但预算差一个数量级 [原文 P07 Table 3] ——话术是权衡，不是碾压。

自测 (先做再对答案)：

1. 为什么「一排排优化」在物理上是错题？
2. GSDE 相对纯 DE，省的是最终精度还是预算？依据哪张表？
3. 三工位里，哪一个直接决定「这轮烧几发真 CFD」？

▼ 点开看参考答案

1. 排间尾迹/旋流耦合，上游改了下游进口就变。2. 主要省预算：1500 vs 20000，增益 1.104% vs 1.115% [原文 P07 Table 3]。3. 父代优选 / T 名额工位。本讲元数据 (读完再看，不挡故事) | 项 | 值 | :--- | :--- || 规范编号 | 07 || 原始文献 | Aerospace Science and Technology, 2023, 142: 108675 || DOI | 10.1016/j.ast.2023.108675 || 作者 | Zhendong Guo,

动手任务

任务：写一个 Python 脚本，在 126 维空间里撒 1000 个随机点，计算每个维度的平均份数 $1000^{1/(126)}$ ，并和“每个方向一分为二”（2 份）做对比，直观感受维数灾难。

产出文件：your_notes/experiments/L03_126维体感实验.py + your_notes/experiments/L03_维数灾难.md

验收标准：Python

脚本能运行并输出每个维度的平均份数；Markdown 文件包含你对“为什么 126 维撒 1000 个点连一分为二都做不到”的一句话解释

【AI】做完后：用主动回忆 Prompt 做补漏，再用批判收尾 Prompt 做深度加工。

沉淀清单

学完本讲，你应该产出以下文件：

- your_notes/knowledge_cards/L03_GSDE.md — 知识卡片（用模板）
- your_notes/experiments/L03_126维体感实验.py — 动手任务代码
- your_notes/experiments/L03_维数灾难.md — 动手任务记录
- 个人 Prompt 库中新增 ≥ 2 个 Prompt

【第04讲】DA-EGO：把 126

维切成小块——动态分解与聚合如何救活贝叶斯优化（论文 11）

【靶】开讲前（5 分钟）：用预习向导 Prompt 让 AI 帮你建立直觉框架，再开始读正文。

本讲开场 90 秒

上讲闪回：


GSDE用进化扛126维；本讲问：贝叶斯能否靠动态切块重返高维？

本讲反派：「假交互」

只要带走 3 句口诀：


1. 交互变量同屋，可分离才分房
2. 评估越贵分解越值，分错比不分更惨
3. P_C绑死，P_S疑似先验

主比喻：超大房子分区装修：水电墙不能拆标段



partition card DA-EGO 分区装修值班卡

指读：水电墙同屋、客房可分房；P_C 绑死、P_S 再验。



第04讲心智图：DA-EGO 分而治之与子空间轮流（mindmap）

看图三秒：大房子分区；红墙强交互；绿门可分离。本讲赌注：分错交互，比不分更浪费——假可分离会制造返工。

【补】读本讲前，你只需要先知道 3 件事（都出自 第零章 与 第零章 B · 四张补丁卡；忘了就点回去看一眼，不用背）：1. 高维要靠「分组」降维：把 126 维切成几个子空间分别优化（第 03 讲）2. 「变量交互」= 一个变量的取值，会改变另一个变量对结果的影响 3. 「子空间」就是一个变量子集，在低维里做 EGO

1. 生活与物理直觉引子：为什么“分而治之”在优化里这么难

先讲一个生活场景。你要装修一套 126

个房间的超大房子，预算只够请设计师做 1000 次方案评审。

笨办法：每次都让设计师把整套房子从头到尾重新设计一遍。1000 次下来，每个房间平均只被认真推敲过 8 次——大概率烂尾。

聪明办法：把房子按功能分区（客厅区、卧室区、厨卫区……），每次集中精力改一个区，其他区保持现状；改完一个区就把它的最优方案“固化”下来，再改下一个区；改完一轮后重新审视：哪些区之间其实互相影响（比如开放式厨房和客厅必须一起改），把它们合并后重新规划。

这就是 DA-EGO

的核心思路。但这里有个真正的难点，也是本文的贡献所在：

你事先并不知道哪些房间之间互相影响。

在叶轮机械里，这个“影响”是物理上真实存在的：改动第 1 排叶片，会改变第 2 排的进口气流角，于是第 1 排和第 2 排的变量之间存在交互作用（interaction）。把它们拆进不同子空间各自优化，就会得到互相矛盾的结果。

所以 DA-EGO 的关键不是“分解”，而是“动态分解”——每轮迭代都重新判断谁和谁该分在一起。

装修监理的口令：

- 水电墙（强交互）→ 绝不能拆到两个标段；
- 两间不相干的客房（可分离）→ 可以轮流施工；
- 疑似承重墙（P_S）→ 先小范围验证，再决定打不打通。

DA-EGO 的「动态」两个字，意思是：标段划分会随着你对新房结构的理解而改，不是一锤子合同。

监理口令：水电墙不拆标段；客房可轮流；疑似承重先验。

先猜后揭：若本讲反派「假交互」赢了，你的下一笔 CFD/实验预算会怎样被浪费？揭晓贯穿 § 3–§ 5。

生活元素	工程元素	符号
主比喻侧	交互分	SPCE _{ij}
主比喻侧	确认/疑似	P_C/P_S
主比喻侧	变量子集	子空间
主比喻侧	精英拼回	聚合

装修事故集：承重墙拆进两个包工队→返工；客房绑死同一工期→浪费并行。交互分数就是给每面墙打「能否拆标段」的分。

假交互的两种事故：


- 把强交互拆进两个包工队 → 返工（假可分离）。

- 把弱交互绑死同一工期 → 浪费并行（假必须同屋）。

交互分数 + P_C/P_S 就是给每面墙打「能否拆标段」的监理报告。

装修监理的一天：
上午：水电墙（强交互）被拆进两个标段，下午返工。
傍晚：客房（弱交互）被绑死同一工期，并行度浪费。
DA-EGO
的交互分数，就是自动出具「这面墙能不能拆标段」的报告；P_C
绑死，P_S 疑似先验。

2. 叶轮机械中的真实工程死穴：GSDE
的代价与贝叶斯框架的"不甘心"



EGO 在低维与高维的取舍，及 DA-EGO 的分解思路 (rotor37 divide, 手绘笔记版)

指读：这张图是本讲工程死穴的一张图版本。
第 03 讲的 GSDE 用进化算法硬扛 126 维，效果很好，但它放弃了贝叶斯优化（EGO）这套东西。站在贝叶斯阵营看，这是有遗憾的：

- EGO/Kriging 的样本效率在低维问题上其实远高于进化算法——几十次评估就能逼近最优；
- 它失效的地方是高维：Kriging 建模失真、采集函数全局最优优化本身变成难题。

于是问题变成：能不能不动 EGO 的骨架，只把"高维"这件事解决掉？
本文给出的答案是：把高维问题分解成若干低维子问题，在每个子问题上用 EGO 好好优化，再把各子空间学到的知识聚合回全空间。
而且——分解方案每轮迭代都要更新。


原文定义的问题规模是 $d \geq 30$ 的高维昂贵黑箱问题 [原文 P11 摘要]。

现场感：周五下班前组长要数——你面对的不是可以慢慢推的练习题，而是算错一次就不可回收的预算。

GSDE 已能扛 126 维，为何还要 DA-EGO？
因为有人仍想保留贝叶斯的不确定度叙事与 EI 族工具。
DA-EGO 的回答：不换队伍，换场地——把高维切成可 EGO 的子空间，再聚合精英。
两条路线不是站队，是工具箱里的两种扳手。

3. 数学公式从 0 到 1 推导


【AI】卡壳？数学推导看不懂时，不要硬啃。把你的困惑发给 AI，用苏格拉底引导 Prompt。先自己想 5 分钟，再让 AI 一步步追问。




interaction score 交互分数分房：红同屋绿分房

指读：高交互绑 P_C；疑似进 P_S 再验；分错比不分更惨。
先把公式关掉，用主比喻说一遍：
超大房子分区装修：水电墙不能拆标段
本讲反派是「假交互」。下面公式是这句话的展开；每条核心式尽量带

回译。知识总量不删——深潜只是阅读路径，不是垃圾桶。



变量交互与可分离性判据，PCE 灵敏度系数打分 (da ego loop, 手绘手账版)



GSDE 与 DA-EGO 的高维路线对比 (GSDE and DA-EGO in high dimension, 中文标注版)

右半支即本讲的 DA-EGO：分解 → 各子空间独立优化 → 精英点聚合 → 更新交互知识，且分解方案每轮迭代都要更新。与左半支的 GSDE 对照看，两条路线的取舍最清楚。

指读：先把这张图当 §3 地图，再读公式。

3B. 本讲符号卡（建议截图留存）

符号	人话	备注
SPCE_ij	交互分	高→同屋
P_C/P_S	确认/疑似	
子空间	变量子集	低维EGO
聚合	精英拼回	

【引】先认符号再读公式；主文核心式有「回译」，装不下的细节仍在正文完整保留（不删知识）。【引】读不动时：本讲 §3 只需抓住核心式 + 它下面的「回译」；标【深潜 | 可跳过】的框可整框跳过，直奔 §4 值班手册——不影响你今天会用这套方法。

3C. 主路径公式与推导（知识全保留）

第一步：什么是“变量交互”（interaction）
设目标函数 $f(x)$ 。若变量 x_i 的取值会改变 x_j 对 f 的影响，则称 x_i 与 x_j 存在交互。

用方差分析（ANOVA）的语言说：把 f 分解成主效应项与交互效应项
〔式〕 $f(x) = f_0 + \sum_i f_i(x_i) + \sum_{i < j} f_{ij}(x_i, x_j) + \dots$

回译：把目标函数拆成一摞零件：一个常数底噪 + 每个变量的「单干」贡献 + 每两个变量的「配合」贡献。这一步负责的是给「变量之间到底有没有互相影响」算出一个可比较的分数——只有 f_{ij} 不为零的那两口子，才必须关进同一个子空间。

若 $f_{ij} \equiv 0$ ，则 x_i 与 x_j 可分离，可以安全地分进不同子空间；反之必须放在同一个子空间里一起优化。

第二步：怎么在只有稀疏样本时判断交互？——PCE 灵敏度系数
本文用多项式混沌展开（PCE）的灵敏度系数 $SPCE_{ij}$ 给每一对变量 (x_i, x_j) 打分。D 个变量共有

〔式〕 $(D(D-1))/(2)$

个变量对（126 维时是 7875 对）。DA-EGO 把它们分成三类 [原文 P11 §3.2.1]：

类别	记号	含义
确认交互	P_C	已由低维代理模型验证确认有交互的 t 对
疑似交互	P_S	在剩余变量对中 SPCE_ij 最高的一批，待验证
非交互	—	其余（可能交互很弱）

原文自己给出的警告（务必记住）："由于维数灾难的存在，高维 PCE 代理的精度有限，这会导致交互变量对的选取出现误差。" 正因如此，P_S 中的疑似交互还要再用低维代理模型验证确认。

第三步：精英点（elite-point）——子空间与全空间之间的知识桥梁
取全部已评估样本中的当前最优样本作为精英点。各子空间优化得到的最优解被组合进精英点，再用于全空间的全局搜索。

这一步的意义是：子空间是低维的、好优化的，但它只是“局部视野”；精英点把各局部视野的最优解拼装成一个全局可行解，保证子空间优化不会跑偏到全空间的劣解上去。

第四步：三类知识构成闭环

原文把"设计空间的知识"明确定义为三类数据 [原文 P11 §3]：

1. 采样数据：所有已评估样本的坐标与函数值；
2. 变量交互关系：已发现（确认/疑似）的交互变量对；
3. 搜索边界：每个变量当前的搜索范围。

由此形成闭环：

[知识] → 构造子任务（分解方案 + 搜索范围）
↓
各子空间独立做基于代理的优化
↓
子任务数据挖掘（摄动法 + ANOVA 检测交互）
↓
[知识更新] → 下一轮的分解方案与搜索范围

第五步：搜索范围收缩

若此前求解过相似子任务（变量相同、精英点不同），则可依据累积经验缩小子问题的搜索范围，从而同时提升优化效率与交互分析的精度 [原文 P11 §3.2.2]。

4. 算法控制流

【引】值班手册：先看「什么情况下走哪条分支」，公式是对白速记不是主角。

① 初始化 LHS 采样 50 个点并评估 默认：任意变量间无交互 默认：每个变量搜索范围 [0,1]
② 循环直到满足停止条件： (a) 高维分解 计算所有变量对的 PCE 灵敏度系数 SPCE _{ij} 分为：确认交互 PC / 疑似交互 PS / 非交互 用低维代理模型验证 PS → 更新 PC 据 PC 把 D 维空间分解为若干低维子空间 取当前最优样本作为 elite-point 若历史上有相似子任务 → 收缩该子问题的搜索范围 (b) 子问题优化与知识挖掘 在每个子空间上用 Kriging + EGO 采集函数优化 用摄动法 + ANOVA 在子空间/全空间中检测变量交互 把新发现的交互关系写回知识库 把各子空间最优解组合进 elite-point


一句话记住：交互变量同屋，可分离才分房；进阶：评估越贵分解越值，分错比不分更惨。

主比喻回扣：把上面的分支再翻译成「超大房子分区装修：水电墙不能拆标段」——若某步在生活里说不通，多半是符号没对齐。

分解循环值班：


打分 → 验证疑似 → 子空间 EGO → 精英聚合 → 下一轮重打分。
评估越贵，分解越值；样本很便宜时，管理开销可能反超收益——§6 软肋要当排期条件读。

5. 实验验证与量化突破



rotor score Rotor37 记分牌与约束同读

指读：效率增量要和压比/流量/强度一起读，防单指标狂欢。
先报胜负：
先读结论句与最大那一格，再读全表；表是证据架不是背诵清单。



转子 37 的 28 维参数化与五算法效率对比 (rotor37 scoreboard, 数值见 [原文 P11 Table 3]，手绘笔记版)

算例一：21 个基准函数，30–90 维 [原文 P11 摘要与 §4]，用于证明算法的效率与鲁棒性。

算例二：NASA Rotor 37 跨声速压气机转子（28 变量）

- 参数化（计数单位=独立标量）：5 截面 × 各 5 吸力面控制点=25；积叠为 中周向 x26 + 中、尖轴向 x27/x28（与 P07「中周向+尖周向+尖轴向」不同分配），共 28 维 [原文 P11 Table 3]；
- 设计条件：转速 17,188.7 rpm，36 个叶片，展弦比 1.19，叶尖间隙 0.356 mm，进口 288.15 K / 101,325 Pa，出口静压 115,000 Pa [原文 Table 4]；
- 网格与求解：约 400 万节点，H–O–I 拓扑（NUMECA AutoGrid5），第一层网格 3 × 10⁻⁶ m，SA 湍流模型，NUMECA FINE/Turbo；单样本约 600 秒（Intel i5-9400F） [原文 §5.1.2]；
- 约束：流量与压比均限制在基准值的 [0.98, 1.02] 倍内，以罚函数实现；
- 目标：最大化 $\eta_{is}/p(x)$ ，其中 $\eta_{is} = [(p^{AT}_{outlet}/p^{AT}_{inlet})^{(\gamma-1)/\gamma} - 1] / [T^{AT}_{outlet}/T^{AT}_{inlet} - 1]$ 。

算法	效率	压比	流量 (kg/s)	效率提升
基准设计	0.8539	2.040	20.62	—
DA-EGO	0.8707	2.055	20.96	+1.65%
GSQA	0.8696	2.051	20.89	+1.57%
GA	0.8673	2.049	20.88	+1.34%
IKAEA	0.8665	2.050	20.88	+1.26%
DE	0.8645	2.049	20.83	+1.06%

[原文 P11 Table 5；每算法独立运行 5 次，每次 1000 次 CFD]

- DA-EGO 相对最强的对手 GSQA 高 0.08 个百分点，相对 DE 高 0.59 个百分点 [由 Table 5 计算]；
- 原文指出：DA-EGO、GA、DE 的 5 次重复运行方差很小，说明受初始样本分布影响小——这对工程应用的可复现性很关键。

气动机理：基准设计的吸力面存在明显的激波-附面层干扰现象，尾缘附近发生严重流动分离，尾缘叶尖处还伴有回流；DA-EGO

优化后分离线形态改变（原文用语 "highly-optimized separation lines"），分离区面积与回流强度都减小，原文将其归为效率提升的流动根源 [原文 P11 § 5.1.3, Fig. 8]。

算例三：多级轴流压气机（60 变量）

- 构型：IGV + 2 级（R1/S1、R2/S2）共 5 排，IGV 不优化；转子每排 18（3 截面×5 主动 + 3 弯掠）、静子每排 12（3 截面×3 主动 + 3 弯掠），四排 60 维 [原文 P11 § 5.2.1]；
- 网格约 2300 万节点，单样本约 4200 秒 [原文 § 5.2.1]。

算法	效率	压比	流量 (kg/s)	效率提升
基准设计	88.072%	2.4604	53.6465	—
DA-EGO	89.142%	2.4644	53.9005	+1.070%
GSGA	88.973%	2.4630	53.7780	+0.901%
IKAEA	88.905%	2.4623	53.8325	+0.833%
GA	88.804%	2.4634	53.8110	+0.732%
DE	88.495%	2.4575	53.5025	+0.423%

[原文 P11 Table 7；同样 1000 次 CFD 预算]

- 在 60 维这一更接近真实工业规模的算例上，DA-EGO 的优势比 28 维时更明显：相对 DE 的效率提升从 +0.59 个百分点扩大到 +0.647 个百分点（1.070% vs 0.423%） [由 Table 7 计算]。
 - 气动机理：沿叶高看，优化后 90% 叶高以上区域效率变化不大、中段叶高明显提升、近端壁处略有下降；分级看，第一级各叶高均提升约 1%，第二级则是根部（<10% 叶高）与顶部（>85% 叶高）下降、中 span 提升 "very obvious"（原文定性用语）。熵函数云图显示流道内三个高熵区（A、B、C）熵值均 "significant decreases"，其中 A、B 区下降 "most obviously"（以上三处均为原文定性用语，原文未给数值）——原因是叶型改变削弱了转子 R1 通道内的激波；中截面的周向静压分布均匀性提高，也佐证了激波的削弱（原文定性描述，未给均匀性指标数值） [原文 § 5.2.2]。
- 体感换算：把关键数字换成「工程师的周/月」或「一次签字的风险」——数字才进长期记忆。若原文给了墙钟时间或成本比，优先用原文换算。

Rotor37 体感：

效率增益达到工程上「型号卖点」那一档时（具体数见本讲 § 5 记分牌与 [原文] 表），

与 GSDE：

一个换算法族，一个保算法族改问题结构。两把扳手都要会。

6. 审稿人批判与承前启后

把软肋放上可信度刻度（0=完全不信，5=可当默认工具）：

维度	打分	人话
问题	5	
Rotor37	5	
PCE成本	2	
理论	2	
维数	4	

可以攻击的点：

1. 作者自己承认的时间复杂度问题。原文结论原话：该方法"提高了算法的时间复杂度，导致算法自身消耗更多计算资源。虽然这对昂贵样本问题不构成阻碍，但在样本廉价的场景下会削弱算法性能；样本的主要计算发生在 Kriging 模型构建，可用增强 Kriging 方法加以解决" [原文 § 6 Conclusions]。翻译成人话：这套方法只在"评估很贵"时才划算——而这恰恰是叶轮机械的场景，所以问题不大，但必须有这个前提意识。
2. 交互检测的可靠性是方法的阿喀琉斯之踵。原文明确说高维 PCE 精度有限会导致交互对选取出错。一旦分解错了，子空间优化就是在错误的子空间里做无用功。
3. 搜索范围收缩依赖历史经验，且没有回退机制。若早期收缩把最优区域提前排除出去了，原文未说明如何恢复。
4. 超参与停止条件未做敏感性分析：初始 50 个 LHS 样本、1000 次 CFD 预算均为设定值。

5. 仍是单点工况优化：与 GSDE

相同，只优化设计点，未考虑非设计点性能与失速裕度。

6. 维数仍低于 GSDE：本文工程算例最高 60 维，而 GSDE 做到了 126 维。两条路线各有适用范围。

承前：- 直接回应了论文 07 GSDE 所代表的分歧：高维 HEB 到底该"放弃贝叶斯走进化"还是"改造贝叶斯扛高维"。DA-EGO 选了后者。- 方法论上继承自 EGO/Kriging 与变量交互分析（PCE、ANOVA）。

启后：- 论文 19（SHAP-Turbine）：DA-EGO 里的变量交互分析是为优化服务的副产品；SHAP 那篇把"变量重要性"与交互"本身作为研究目标，做成了可解释的设计知识。- 论文 13（EMFS/MSFO）：同样关心"代理模型在哪些区域不可信"，但切入点在保真度而非子空间。

Rotor37 记分纪律：

效率增益的量级解读必须回到本讲 § 5 记分牌与 [原文] 表：哪怕看起来只是很小的百分点数，在压气机设计里也可能是型号卖点点，但必须与压比、流量、强度约束同屏。


单指标冠军若贴着约束下沿，签字会要听到「裕度」两个字。

附：假交互识别口令

现象	可能
拆开优化再拼总翻车	真强交互，应 P_C
绑在一起却不联动	假交互，可试分离
分数噪声大	先 P_S 小步验证

图卡：假交互识别口令

真交互红门同屋，假交互绿门可分。分房前先审 PCE 交互分数——看起来相关不等于必须绑死在同一子空间。




fake interaction：真交互同屋 vs 假交互可分房（DA-EGO）

图卡：分区装修值班

交互分数 → 分房 → 子空间 EGO →

汇总。真交互同屋、假交互可拆；值班不是一次分完就散场。



partition duty DA-EGO：交互分数分房后的值班装修

章末：30 秒复述 · 自测 · 元数据

30 秒复述稿（可朗读）：高维别整屋翻修。DA-EGO 用交互分数把变量分成确认绑死与疑似再验，子空间跑 EGO 再聚合。分对省预算，分错比不分更惨。与 GSDE 是换场地 vs 换队伍。

自测（先做再对答案）：

1. 可分离？
2. P_S为何再验？
3. 样本便宜时分解划算吗？

▼ 点开看参考答案

1. 无交叉项可拆；强耦合几何通常不可分。2. 分数有噪声，防假交互绑定。3. 不一定，管理开销可能更高。本讲元数据（读完再看，不挡故事）
| 项 | 值 | :--- | :--- | | 规范编号 | 11 | | 原始文献 | Engineering Optimization, 2025, 57(2): 514-542（线上发表于 2024-04-18） | | DOI | 10.1080/0305215X.2024.2325651 | | 作者 | Qineng Wang, Zhendong Guo, Yun Chen, Guangjian Ma, Liming Song, Jun Li | | 本地原文 | A dynamic aggregation strategy enhanced efficient global optimization algorithm...pdf | | 开源代码 | https://github.com/zhet1997/DA_EGO_publication | | 证据等级 | A（本地原文逐句可查） | | 反派绰号 | 假交互 | | 主比喻 | 126 个房间的超大房子装修 |

动手任务

任务：用 code/sampling.py 的 sobol_first_order_indices 函数，在一个 6 维测试函数上估计一阶敏感性指数，找出最重要的 2 个变量。然后思考：如果这是 DA-EGO 的交互分析，你会把最重要的变量和哪些其他变量“绑在一起”？

产出文件：your_notes/experiments/L04_DA_EGO_交互分析.md

验收标准：文件存在且包含：① 敏感性指数排序结果 ② 你对“哪些变量应该绑在一起”的判断及理由

【AI】做完后：用主动回忆 Prompt 做补漏，再用批判收尾 Prompt 做深度加工。

沉淀清单

学完本讲，你应该产出以下文件：

- □ your_notes/knowledge_cards/L04_DA_EGO.md — 知识卡片（用模板）
- □ your_notes/experiments/L04_DA_EGO_交互分析.md — 动手任务记录
- □ 个人 Prompt 库中新增 ≥ 2 个 Prompt

【第05讲】EMFS / MSFO：当“便宜的粗网格”开始骗人——多保真优化的暗面（论文 13）

【靶】开讲前（5 分钟）：用预习向导 Prompt 让 AI 帮你建立直觉框架，再开始读正文。

本讲开场 90 秒

上讲闪回：


Filter问谁配见专家；本讲问：专家看过的区还信不信实习生？

本讲反派：「后期假优」

只要带走 3 句口诀：

1. 多保真不总更好
2. HF扎堆处Z_DF可能失真
3. 失准区DBSCAN局部验尸再融合

主比喻：专家盯过的区，实习生反而开始系统性撒谎



第05讲心智图：EMFS 多保真也会骗人（mindmap）

看图三秒：前期MFS领先，后期SFS反超；DBSCAN圈失准区。本讲赌注：把「MFO 必胜」当宗教，会在后期交叉后继续向假谷冲刺。

【补】读本讲前，你只需要先知道 3 件事（都出自 第零章 与 第零章 B · 四张补丁卡；忘了就点回去看一眼，不用背）：1. 多保真建模：贵的真值 = 便宜的乘个系数 + 一个差异函数（第 02 讲）2. 差异函数 Z_DF 自己也是用有限样本猜出来的——这是多保真的软肋 3. 聚类就是把样本按密度自动分堆，不必事先分清分几堆（卡② B.2）

1. 生活与物理直觉引子：老专家带的实习生，也会把你带沟里
第 02 讲（Filter-GEI）讲过“老专家 + 实习生”的比喻：实习生（低保真 LF）便宜、出活快，负责摸清大方向；老专家（高保真 HF）贵，只在关键点出手。

但那个比喻里藏着一个没被追问的前提：

实习生的判断，大体上是对的。

如果这个前提不成立呢？想象一下：实习生看图纸有个系统性偏差——他总把某种特定结构画得比实际更结实。在设计的前期，这个偏差无所谓，因为大方向是对的；但当设计推进到精细阶段，你已经逼近最优解时，这个系统性偏差会把你往错误的方向一直带。

这时候，继续让实习生参与决策，不但不省钱，反而是负资产——你花的每一分钱都在加固一个错误。

这就是本文的出发点，而且它是反直觉的：

多保真优化（MFO）并不总是优于单保真优化。在优化的后期，随着高保真样本不断积累，低保真样本会产生负面效果，误导优化搜索。[原文 P13 摘要]

后期假优的日常版：

项目前半段，实习生的图确实让方案从「一团糟」变成「像回事」，经理很开心。

后半段要比拼毫厘时，实习生那套「总把某结构画结实」的系统偏差，开始把最优解往歪处拽。

若你还在用「早期真快」当理由继续信他，就会在终点输给「全程只请老专家、虽然慢但没被带沟」的队伍。

原文把这件事说得很干脆：MFO 不总是更好；后期 LF 可能负面 [原文 P13 摘要]。

EMFS 值班口令（对照第 02 讲）：

- 第 02 讲滤波问的是：「这个点配不配见老专家？」
- 本讲集成问的是：「老专家已经看过的区域里，实习生是不是还在撒谎？」

DBSCAN 圈出的是失准区，不是「坏点垃圾箱」。圈里改建局部 SFS，再与全局 MFS

按权重融合——像给惯于撒谎的街道派驻专人复核。

对照 02：一个管分配，一个管失准验尸。

先猜后揭：若本讲反派「后期假优」赢了，你的下一笔 CFD/实验预算会怎样被浪费？揭晓贯穿 §3-§5。

生活元素	工程元素	符号
主比喻侧	多/单保真	MFS/SFS
主比喻侧	差异函数	Z_DF
主比喻侧	集成多保真	EMFS
主比喻侧	圈失准区	DBSCAN

连续翻车故事（加长）：

前 20 轮：LF 带路，曲线好看。第 21-40 轮：HF 在「有希望区」密集加班，Z_DF 过度自信。第 41 轮起：MFS 仍听 LF，可 LF 在这片区开始系统性画错——假最优越跑越稳。SFS 更慢但不自欺。这就是后期假优。

实习生撒谎的时间线（加长到可写进事故报告）：

T0-T1：LF 带路，曲线好看，老板表扬「多保真真香」。


T1-T2：HF

在「有希望区」扎堆，差异函数被局部残差喂胖，过度自信。

T2 后：全局 MFS 仍听 LF，搜索被推进假谷；SFS 更慢但更不自欺。

交叉点出现 = 本讲定理的实验指纹，不是噪声。

2. 叶轮机械中的真实工程死穴：一个被“MFO 一定更好”掩盖的问题



多保真的暗面：MFS 早期领先但最终解劣于 SFS (mfs trap, 手绘手账版)

指读：这张图是本讲工程死穴的一张图版本。

多保真方法 (Co-kriging、多保真 EGO 等) 在 2010 年代后成为叶轮机械优化的主流工具，因为它确实省钱。行业内逐渐形成一种默认认知：“只要能多用多保真，就该用多保真。”

本文要戳破的正是这个默认认知。原文描述的观察是：

基于多保真代理 (MFS) 的优化，有时只能在优化早期取得更好的收敛速率，但最终解反而比“只用高保真样本的单保真代理 (SFS) 优化”更差。 [原文 P13 摘要]

为什么会这样？原文给出的机理是：

随着优化过程中 HF 样本的增加，LF 样本会产生负面效果，从而误导优化搜索。 [原文 P13 摘要]

用物理语言翻译一遍：优化前期，LF 的“大趋势”信息价值极高，因为 HF 样本太少、全靠 LF 撑着全局形状；但到了后期，HF 样本已经足够刻画局部细节，此时 LF 与 HF 之间的系统性差异 (discrepancy) 就从“可容忍的噪声”变成了“系统性的偏差”——它会持续把代理模型的最优位置拉偏。

现场感：周五下班前组长要数——你面对的不是可以慢慢推的练习题，而是算错一次就不可回收的预算。

与第 02 讲边界：Filter 假设 LF 大体可用；EMFS 处理 LF 局部有毒。同一公司隐喻，病不同。


「MFO 一定更好」如何成为教条：论文摘要与综述常强调早期加速；很少把后期交叉当标题。工程值班却必须问：学习曲线有没有交叉？交叉后你还信谁？原文立场需要诚实引用：多保真不总更好 [原文 P13 摘要]。

3. 数学公式从 0 到 1 推导

【AI】卡壳？数学推导看不懂时，不要硬啃。把你的困惑发给 AI，用苏格拉底引导 Prompt。先自己想 5 分钟，再让 AI 一步步追问。


先把公式关掉，用主比喻说一遍：

专家盯过的区，实习生反而开始系统性撒谎
本讲反派是「后期假优」。下面公式是这句话的展开；每条核心式尽量带回译。知识总量不删——深潜只是阅读路径，不是垃圾桶。



DBSCAN 聚出失真区、局部 SFS 与全局 MFS 融合为 EMFS (emfs pipeline, 手绘手账版)

EMFS / MSFO：当便宜的粗网格开始骗人（论文 13）



多保真后期陷阱与 EMFS 局部纠偏 (EMFS MSFO late stage trap, 中文标注版)

上图是本讲难点的「一张图版本」：左图是多保真的暗面——MFS (橙虚线) 早期收敛快，后期反被低保真样本拖累，最终解比只用高保真样本的 SFS (蓝实线) 更差；右图是 MSFO 的解法——用 DBSCAN 聚出 MFS 失真区 (红色圈)，在该区域局部构建 SFS，再与全局 MFS 按自适应权重融合成 EMFS。

3B. 本讲符号卡（建议截图留存）

符号	人话	备注
MFS/SFS	多/单保真	
Z_DF	差异函数	
EMFS	集成多保真	
DBSCAN	圈失真区	

【引】先认符号再读公式；主文核心式有「回译」，装不下的细节仍在正文完整保留（不删知识）。【引】读不动时：本讲 §3 只需抓住核心式+它下面的「回译」；标【深潜 | 可跳过】的框可整框跳过，直奔 §4 值班手册——不影响你今天会用这套方法。

3C. 主路径公式与推导（知识全保留）

第一步：把“多保真为什么失效”写清楚

多保真代理（以 Co-kriging 为例，参见第 02 讲）把 HF 建模为

(式) $y_{HF}(x) = \rho \cdot y_{LF}(x) + Z_{DF}(x)$

回译：贵的那条真值 = 便宜那条乘一个缩放系数 ρ ，再补一个差异函数 Z_{DF} 去填「便宜模型系统性差了多少」。这一步负责的是让大量便宜样本铺路、少量昂贵样本校准；而本讲的全部风险也都押在 Z_{DF} 上——它自己也是用有限样本猜出来的。

其中 Z_{DF} 是差异函数 (discrepancy function)，负责修正 LF 的系统性偏差。

问题在于： Z_{DF} 本身也是用有限样本拟合出来的高斯过程。当 HF 样本在优化后期高度聚集于当前最优附近时， Z_{DF} 在“你真正关心的那块区域”里的估计反而可能很不准——因为 LF 在那里从来就没被 HF 校验过。

于是出现了本文说的现象：在 MFS 建不准的那块区域，MFS 反而不如一个纯用 HF 建的单保真代理 (SFS)。

第二步：核心思想——不是“全用 MFS”或“全用 SFS”，而是“哪里 MFS 不行，哪里就换 SFS”

本文的做法可以概括成一句话：

用 DBSCAN 密度聚类找出“MFS 建不准”的区域，在该区域局部改建一个单保真代理 (local SFS)，再用自适应权重把 MFS 与这个局部 SFS 融合成一个集成代理 EMFS (Ensemble weighted Multi-Fidelity Surrogate)。 [原文 P13 摘要]

第三步：为什么用 DBSCAN 而不是别的聚类？

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) 的特点是：

- 不需要预先指定簇的个数——你事先并不知道有几个“失真区”；
- 能识别噪声点——稀疏的离群样本不会被硬塞进某个簇；
- 能发现任意形状的簇——失真区的几何形状未必是凸的。

这三点恰好契合“找出代理模型失真区域”这个任务：失真区可能不止一个、形状不规则、且边界处样本稀疏。


【钉】 DBSCAN 的具体参数（邻域半径 ϵ 、最小样本数 MinPts）与自适应权重具体公式，摘要未给出，原文未获取，本讲不作推测。

第四步：命名规范（旧版白皮书在这里错了，必须纠正）

名称	全称	指代对象
EMFS	Ensemble weighted Multi-Fidelity Surrogate	代理模型：MFS 与局部 SFS 的自适应加权集成体
MSFO	Multi- and Single-fidelity surrogate fused Optimization	优化算法：用 EMFS 引导搜索的完整算法

✗ 旧版白皮书第 05 讲的标题写作“EMFS 算法：DBSCAN 空间聚类识别失真区的多保真局部融合”，把代理模型的名字当成了算法名。✓ 正确表述：EMFS 是代理模型，MSFO 才是优化算法。

4. 算法控制流



EMFS duty 后期假优验尸值班流程

指读：画曲线→找交叉→DBSCAN圈团→团内SFS→融合。与 Filter 串联而非二选一。

【引】值班手册：先看「什么情况下走哪条分支」，公式是对白速记不是主角。

依据摘要可确认的流程骨架（细节参数原文未获取）：

每轮迭代：

1. 用现有 HF + LF 样本建立多保真代理 MFS（如 Co-kriging）
2. 用 DBSCAN 对样本/设计空间做密度聚类，侦测出“MFS 在该区域建不准”的区域
3. 在这些失真区域内，仅用 HF 样本建立一个局部单保真代理 local SFS
4. 用自适应权重把 MFS 与 local SFS 融合为集成代理 EMFS
5. 用 EMFS 引导下一轮加点（这就是 MSFO 算法）

一句话记住：不是“多保真 vs 单保真”的二选一，而是“哪里可信就用哪套”的自适应切换。

主比喻回扣：把上面的分支再翻译成「专家盯过的区，实习生反而开始系统性撒谎」——若某步在生活里说不通，多半是符号没对齐。

融合口令：失真区专家说了算（SFS）；其余区仍可 MFS。权重问「这片区最近谁在撒谎」。

EMFS 排班：

全局仍可用 MFS 探路；DBSCAN 圈出的失真团改 SFS；融合权重看「这片区谁在撒谎」。

与 Filter 串联：先分配谁见专家，再验尸专家盯过的区。

EMFS 与 Filter 的串联脚本：


每 10 轮：更新 MFS/SFS 曲线。

发现交叉：启动 DBSCAN 圈失真团。

团内：SFS 说了算；团外：MFS 仍可探路。


融合后再跑，看交叉是否消失；不消失则检查 LF 是否结构性失效（不是聚类能救）。

5. 实验验证与量化突破



MFS SFS cross 学习曲线交叉点指纹

指读：交叉不是噪声，是后期假优的实验指纹。



后期假优：MFS 与 SFS 学习曲线交叉

指读：前期 MFS 领先，后期交叉后 SFS 反超——交叉点是本讲定理的实验指纹。

读后期陷阱实验的正确姿势：

不要只看「谁最终最优」。看学习曲线有没有交叉、交叉出现在第几轮、交叉后 MFS 是否仍假装领先。

交叉 =

本讲定理的实验指纹；没有交叉图，就没有「后期假优」的证据链。

先报胜负：

先读结论句与最大那一格，再读全表；表是证据架不是背诵清单。

可确认的验证算例 [原文 P13 摘要]：

1. GE-E3 叶片优化（与第 02 讲 Filter-GEI 用的是同一个公开标杆几何）；
2. 涡轮端壁气膜孔布局设计（the film cooling layout design of a turbine endwall）。

摘要的原话是：“Through tests on GE-E3 blade optimization and the film cooling layout design of a turbine endwall, the effectiveness of proposed MSFO is well demonstrated.”

△ 重要提醒：摘要没有给出任何量化对比数字（提升了多少、节省了多少次 CFD、成功率如何）。因此本讲不列出任何性能数字。

【删】旧版白皮书 6.1 矩阵中写的「250 次 CFD」「15D~30D」「消除低保真模型失真误导现象」等条目，均无出处，属填充内容，已在重建版中删除或标注待补。

体感换算：把关键数字换成「工程师的周/月」或「一次签字的风险」——数字才进长期记忆。若原文给了墙钟时间或成本比，优先用原文换算。

盯交叉点：学习曲线上 MFS 前期领先、后期被 SFS 反超——可能是本讲定理的实验版。

进工具箱：多保真是默认选项，不是宗教信仰。后期要会验尸。

6. 审稿人批判与承前启后

把软肋放上可信度刻度（0=完全不信，5=可当默认工具）：

维度	打分	人话
问题	5	打脸MFO必胜
直觉	4	
细节	3	

维度	打分	人话
广度	3	

可以攻击的点：

1. "失真区"的判定标准本身依赖代理模型。用 MFS 去判断"MFS 在哪不准"，存在自我指涉的风险；判定失准时会连锁出错。
2. DBSCAN 的参数敏感性。密度聚类对邻域半径与最小样本数非常敏感，而这两个参数与"代理模型误差阈值"之间并无直接的物理换算关系——调参很大程度上靠试。
3. 局部 SFS 的样本从哪里来？失真区之所以失真，恰恰是因为那里 HF 样本稀少；在 HF 样本稀少的区域建单保真代理，可能同样不可靠。原文未提供此处的处理细节（原文未获取）。
4. 权重的自适应规则缺少理论依据（原文未获取，无法评价）。
5. 仅两个算例，且都为该课题组的常规算例，未在更广泛的基准上验证泛化性。

承前：- 直接修正了第 02 讲（Filter-GEI）的隐含前提。Filter-GEI 假定"LF 大体能捕捉 HF 趋势"，并据此设计滤波阈值；本文则处理这个前提在局部失效的情形。两篇论文构成"多保真方法"的一体两面。- 方法上继承了 Co-kriging 与多保真 EGO 的体系。

启后：- 论文 07（GSDE）与论文 11（DA-EGO）：如果说 EMFS 处理的是"保真度维度上的模型不可信"，那么 GSDE 与 DA-EGO 处理的是"维度灾难带来的模型不可信"。三者共享同一个哲学——先识别代理模型在哪里不可信，再在那里换一种策略。- 论文 19（SHAP-Turbine）：同样是对"模型/数据不可信"的反思，但转向可解释性视角。


【附】 如果想把本讲升级为 A 级证据，需要取得 ASME 全文（DOI 10.1115/1.4064228）。届时可在 corpus/facts/P13.md 中补全：DBSCAN 参数、自适应权重公式、Table 中的量化对比结果。

交叉点会议怎么开：

投影学习曲线，用红笔标交叉轮次。

问三句：HF 最密在哪？Z_DF 是否过自信？失真团是否可解释物理？答完再动超参，避免「先调 DBSCAN 碰运气」。

附：读完本讲你能画的一张因果图



经理答辩词（30 秒）：

「我们不是抛弃多保真，而是拒绝在失准区继续听实习生。Filter 解决谁配见专家；EMFS 解决专家盯过的区还信不信实习生。」

与全书地图：02 分配 -> 05 验尸 -> 若维数再爆棚 03/04；若要生成先验则 06+。

EMFS 值班口令（再压缩）：

1. 先画 MFS vs SFS 学习曲线，找有没有交叉。
2. 有交叉 -> 用 DBSCAN（或同类密度方法）在输入空间圈失真团。
3. 团内改 SFS，团外保留 MFS，融合后再跑几轮看交叉是否消失。
4. 若交叉不消失，检查 LF

定义本身是否在该物理机制上结构性失效（不是聚类能救的）。

和 Filter-GEI 联用时的顺序建议：

先 Filter 管「谁见专家」，再 EMFS

管「专家扎堆区还听不听实习」——两道闸，不是二选一。

附：后期假优的「验尸报告」模板

现场记录（建议每 10 轮写一行）：

轮次	MFS 最优	SFS 最优	交叉？	HF 最密的区域（人话）	决策
10	...	...	否	全局散	继续 MFS
30	...	...	苗头	某角区	盯 Z_DF
50	...	...	是	HF 扎堆谷	启动 EMFS

DBSCAN 在本故事里的角色（人话，不推导）：

它不负责「找到最优」，只负责在输入空间里圈出「代理不可信的团」。团内改单保真，团外仍可多保真——像把医院隔离区与普通病房分开。

失败模式点名：

1. 宗教多保真：从不画 MFS/SFS 对照曲线。
2. 只调滤波不验尸：Filter 解决分配，解决不了局部有毒。
3. 失真定义随手定： ϵ 与 MinPts 乱抖，圈出半个设计空间。
4. 融合权重拍脑袋：该信 SFS 的区仍 50/50。

和全书的接口：

02 管「谁见专家」 -> 05 管「专家盯过的区还听谁」 -> 若维数爆了转 03/04；若要生成先验转 06+。

附：与 02 的双闸门

闸门	问句	工具
Filter (02)	谁配见专家？	ω -T
EMFS (05)	专家盯过的区还信实习生吗？	DBSCAN+局部 SFS

只开一闸，另一类事故仍会来。

附：后期假优的一页纸定义

前期加速 $\neq$ 全程更优。


当 HF 扎堆导致差异函数失真，LF 开始系统性撒谎，MFS 可能输给 SFS。

EMFS = 局部验尸 + 融合，不是抛弃多保真。

图卡：Filter $\times$ EMFS 双闸门

Gate1 Filter: 谁配见专家 (ω -T) ; Gate2

EMFS: 专家盯过的区还信实习生吗 (DBSCAN+局部 SFS)。只开一闸，另一类事故仍会来。




dual gates filter EMFS: 谁见专家 $\times$ 看过的区还信谁

图卡：后期假优验尸日志

每轮记 MFS/SFS 最优与是否交叉；交叉苗头出现就启动


EMFS（DBSCAN 圈失准区）。从不画对照曲线 = 宗教多保真。



autopsy log EMFS: 后期假优验尸日志与交叉启动

图卡：失真区隔离病房

DBSCAN 画出失真团：团内改局部 SFS，团外仍可 MFS。EMFS 是隔离+融合，不是抛弃多保真。



quarantine zone EMFS: DBSCAN 圈失准区, 团内 SFS 团外 MFS

章末: 30 秒复述 · 自测 · 元数据

30 秒复述稿 (可朗读): 多保真不总更好。HF 扎堆处 Z_DF

可能失真, 后期 MFS 会交叉输给 SFS。EMFS 用 DBSCAN

圈失准区, 局部改单保真再融合。Filter 管谁见专家, EMFS

管看过的区还信谁。

自测 (先做再对答案):

1. MFO 必胜?
2. 后期 LF 为何负?
3. EMFS 三步?

▼ 点开看参考答案

1. 不; 原文: MFO 不总更好 [原文 P13 摘要]。2. HF 密使 Z_DF 失真。
3. 圈失准 → 局部 SFS → 融合。本讲元数据 (读完再看, 不挡故事) | 项 | 值 | :--- | :--- | 规范编号 | 13 | 原始文献 | ASME Journal of Turbomachinery, 2024, 146(4): 041011 (10 页) | DOI | 10.1115/1.4064228 | 论文号 | TURBO-23-1281 (线上 2023-12-21) | 作者 | Qineng Wang, Liming Song, Zhendong Guo (通讯), Jun Li, Zhenping Feng | 本地原文 | 无 (ASME 订阅墙) | 证据等级 | B (出版商页面 + 摘要全文) |

△ 本讲的写作边界: 本文无本地全文, 以下内容仅取自出版商页面的标题/作者/卷期/摘要原文, 以及可核验的著录信息。凡摘要未给出的数字 (具体提升幅度、样本量、DBSCAN 参数、权重公式), 本讲一律不写, 并明确标注「原文未获取」。| 反派绰号 | 后期假优 | 主比喻 | 实习生总把某种结构画得更结实 |

动手任务

任务: 用 code/multifidelity.py 的 dbscan 函数, 在一个模拟的 HF 样本上做密度聚类。构造两组样本: 一组 "扎堆" 在原点附近 (模拟后期 HF 密集区), 一组均匀分布 (模拟早期 HF 散布)。观察 DBSCAN 如何圈出 "扎堆区"。

产出文件: your_notes/experiments/L05_EMFS_DBSCAN 实验.md

验收标准: 文件存在且包含: ① 你构造的样本描述 ② DBSCAN 的聚类结果 ③ 你对 "为什么 HF 扎堆会导致 Z_DF 失真" 的一句话解释

【AI】做完后: 用 主动回忆 Prompt 做补漏, 再用 批判收尾 Prompt 做深度加工。

沉淀清单

学完本讲, 你应该产出以下文件:

- ☐ your_notes/knowledge_cards/L05_EMFS.md — 知识卡片 (用模板)
- ☐ your_notes/experiments/L05_EMFS_DBSCAN 实验.md — 动手任务记录
- ☐ 个人 Prompt 库中新增 ≥ 2 个 Prompt