

第二篇 【生成式模型与跨任务知识迁移篇】

本篇覆盖论文

06、08、17、14。核心追问是：能不能不每次都从零开始设计？把叶型、端壁这类高维几何压进一个低维潜空间（GMFoO、GAN 参数化），再把上一个型号学到的设计知识迁移到新型号（SW-VAE、GTO），从而把昂贵的优化样本量再降一个量级。

过桥 B ·

从「采样」到「换空间」：为什么第二篇开始捏潜变量

第一篇默认：设计变量是一串可以加减的实数，难点在怎么挑下一个 x_0 。

真实叶型/端壁还有另一层痛：

绝大多数随机坐标组合根本不是合法几何——自交、开叉、刀轨走不出来。

所以第二篇（第 06–09 讲）换问题：

能不能先把「合法形状」压缩进一个低维潜空间，再在里面优化，并把旧型号的经验搬过来？

讲	一句话
06 GMFoO	一个潜空间不够，高低维搭配
07 SW-VAE	迁移要加权，否则旧经验淹没新任务
08 GTO	没有编码器，就用梯度把 z^* 反推出来
09 VAE-NURBS	端壁更挑光顺，解码器里嵌 NURBS

若你还在用第一篇的 EI 直觉，这里请先换脑子：搜索空间本身被重写了。

【第06讲】GMFoO：一个潜空间不够，那就同时用好几个（论文 06）

【靶】开讲前（5 分钟）：用 预习向导 Prompt 让 AI 帮你建立直觉框架，再开始读正文。

本讲开场 90 秒

上讲闪回：

前五讲在变量空间采样；本讲起生成式：先合法形状再优化。

本讲反派：「潜维两难」

只要带走 3 句口诀：

1. 形状在流形不在欧氏方盒
2. Z 细 C 粗双潜分工
3. 知识库 $\mathcal{M}(t)$ 跨层传话

主比喻：合法叶型挤在瘦流形毯子上



第06讲心智图：双潜空间与潜维两难

看图三秒：Z 细、C 粗、知识库传话；反派是潜维两难。本讲赌注：在欧氏方盒里优化叶型，预算会先葬在自交与非法形。

【补】读本讲前，你只需要先知道 3 件事（都出自 第零章 与 第零章 B · 四张补丁卡；忘了就点回去看一眼，不用背）：1. 潜空间 = 合法形状的压缩包，在里面怎么挪都还是个叶型（卡② B.2.4）2. GAN 就是「造假者与抓假者」对着干，越打越真（卡② B.2.5）3. 后验均值 $\hat{y}$ 与不确

1. 生活与物理直觉引子：描述“形状”，比描述“数字”难得多

前面几讲处理的设计变量，本质上都是一串数字：叶型控制点的偏移量、叶片的周向平移量……变量再多，改变一个变量，形状就“连续地”变一点点。数学上这叫欧氏空间。

但真实工程里有一大类问题不是这样。比如：

- 一个翼型，用 192 个点离散描述，每点 2 坐标 $\rightarrow$ 384 个坐标标量（结构化输入空间维，不是潜维）[原文 P06: 192 points $\rightarrow$ 384 design variables]。你随便挪动其中一个点，大概率得到一个锯齿状、根本飞不起来的怪物形状。
- 一个分子结构、一段程序代码、一个拓扑结构——这些是离散空间或非欧空间。

这类空间有两个特点：① 维度极高；②

变量之间高度耦合（原文用词是 highly interacted），必须“成组地”改变才有意义。在这上面直接做贝叶斯优化，几乎必然失败——高斯过程会认为“每个点都可以独立乱动”。

生成模型（GAN / VAE）给出的解法：先学一个从“低维潜空间”到“合法形状”的映射。潜空间里每个点都对应一个看起来像真翼型的形状，于是在潜空间里优化就安全多了。这套两阶段流程叫做 GMO（Generative Model-based Optimization）。

流形直觉：

在 384 维坐标里随机撒点，得到的「翼型」十有八九自交、开叉、像事故现场。

真正合法的叶型，挤在一张弯曲的「瘦毯子」（流形）上。

生成模型的工作，就是别再网格世界里乱跑，而在毯子上走路。

先猜后揭：若本讲反派「潜维两难」赢了，你的下一笔 CFD/实验预算会怎样被浪费？揭晓贯穿 §3–§5。

生活元素	工程元素	符号
主比喻侧	高维潜空间	Z
主比喻侧	低维潜空间	C
主比喻侧	生成器	G
主比喻侧	知识库	$\mathcal{M}(t)$

384 坐标的诅咒：大多数挪法得到自交与鬼形。欧氏方盒里优化，预算先浪费在非法形。生成模型把搜索关进合法毯子。

欧氏盒子的诅咒（加长）：

384 个坐标每个都能动，大多数挪法得到自交与不可铣形。

优化预算先浪费在非法区，是「还没开始就输了」。

生成模型的价值：把搜索关进合法毯子；双潜是毯子上的粗路与细路。

方盒子优化的一日流水：

早上：随机扰动坐标。

中午：一半样本自交/尖角，CFD 预处理报错。

下午：活下来的样本里仍有「合法但垃圾」的形。

晚上：优化器报告「探索充分」——其实预算葬在非法区。


流形路线把「探索充分」重新定义为：在毯子上走得充分。

毯子上的交通规则：

先合法，再优化；先粗路（C），再细路（Z）；用相册（知识库）避免绕圈。


交通规则破坏时，加算力无用。

2. 叶轮机械中的真实工程死穴：潜空间维度，选大还是选小？



manifold blanket 欧氏盒子 vs 瘦流形毯子

指读：左：384维乱挪自交；右：合法形挤在毯子上，Z细C粗在毯子上走。



潜空间维度的两难：精度与收敛速率的冲突（latent dim dilemma, 手绘笔记本版）

指读：这张图是本讲工程死穴的一张图版本。

GMO 好用，但有一个绕不开的抉择：潜空间取多少维？

这是一个两难：

潜空间维度	优点	缺点
低维（主设定 C=3；对照 GMO-Low 曾用 4）	搜索空间小，收敛极快	表达能力不足，好形状可能表示不出 → 终解精度差
高维（主设定 Z=13；对照把潜维拉到 23）	表达能力强，终解更准	搜索空间大，贝叶斯优化收敛慢

原文把这个矛盾概括为：潜空间维度难以确定，会引发“解的精度（solution accuracy）”与“收敛速率（convergence rate）”之间的冲突 [原文 P06 摘要]。

而且这个冲突在叶轮机械上格外要命：因为每次评估是 CFD，“收敛慢”直接等于“多烧几个月的机时”。

本文的答案很巧妙：既然选大选小都有道理，那就同时用几个不同维度的潜空间，让它们互相帮忙。

现场感：周五下班前组长要数——你面对的不是可以慢慢推的练习题，而是算错一次就不可回收的预算。

潜维两难的量化直觉（不编造具体最优值）：

太大：搜索浪费、样本不够填满。

太小：表达能力不够，最优被挤扁。

双潜是工程折中：C 快速定向，Z 精修细节；知识库负责交班。


3. 数学公式从 0 到 1 推导

【AI】卡壳？数学推导看不懂时，不要硬啃。把你的困惑发给 AI，用苏格拉底引导 Prompt。先自己想 5 分钟，再让 AI 一步步追问。

先把公式关掉，用主比喻说一遍：

合法叶型挤在瘦流形毯子上

本讲反派是「潜维两难」。下面公式是这句话的展开；每条核心式尽量带回译。知识总量不删——深潜只是阅读路径，不是垃圾桶。



高维潜空间 Z 与低维潜空间 C 经知识库协同（gmfoo two latents, 手绘手账版）

指读：先把这张图当 §3 地图，再读公式。

3B. 本讲符号卡（建议截图留存）

符号	人话	备注
Z	高维潜空间	细
C	低维潜空间	粗
G	生成器	
$\mathcal{M}(t)$	知识库	

【引】先认符号再读公式；主文核心式有「回译」，装不下的细节仍在正文完整保留（不删知识）。【引】读不动时：本讲 §3 只需抓住核心式+它下面的「回译」；标【深潜 | 可跳过】的框可整框跳过，直奔 §4 值班手册——不影响你今天会用这套方法。

3C. 主路径公式与推导（知识全保留）

第一步：把“多空间协同”写成优化框架〔式〕 $\min_{\mathbf{x}} \in \mathbf{X} f(\mathbf{x}) = \min\{T_0, T_1, \dots, T_m | \mathcal{M}(t)\}$

回译：本来要在 384 维坐标空间里直接找最优，现在改成：在好几个潜空间里各开一家「分店」（ T_0 在大潜空间、 T_i 在小潜空间）同时优化，并用一个知识库 $\mathcal{M}(t)$ 让分店之间交换情报。这一步负责的是把「一个潜空间选大还是选小」的两难，换成「几个空间互相帮忙」。

- $\mathbf{X}$ ：结构化的原始输入空间（384 维翼型坐标）；
- T_0 ：在高维潜空间 Z 上做的优化子任务；
- T_i ：在低维潜空间 C_i 上做的优化子任务；
- $\mathcal{M}(t)$ ：知识库，负责在子任务之间交换信息。

拆开写就是：〔式〕 $T_0 = \min_{\mathbf{z} \in \mathbf{Z}} y_0(\mathbf{z}), T_i = \min_{\mathbf{c}_i \in \mathbf{C}_i} y_i(\mathbf{c}_i), i = 1, \dots, m$

第二步：关键设计——让潜空间之间“正相关”

【深潜 | 可跳过】互信息与变分下界（信息论细节；只需相信「逼着 C 去复述 Z，两个空间就正相关了」）

如果各个潜空间彼此独立，那“同时优化”就退化成“各自乱跑”。本文借 InfoGAN 的思路，在 GAN 的训练损失里加入最大化互信息的正则项：

〔式〕 $\min_G \max_{D, V, M} (D, G) = V(D, G) - \sum_{i=1}^m \lambda_i I(\mathbf{c}_i; G(\mathbf{z}))$

互信息 $I(\mathbf{c}_i; G(\mathbf{z})) = H(\mathbf{c}_i) - H(\mathbf{c}_i | G(\mathbf{z}))$ 不可直接算，用因子化高斯 $Q(\mathbf{c}_i)$ 做变分近似，得到下界：

〔式〕 $\mathcal{L}_i(\mathbf{c}_i; G(\mathbf{z})) = -\sum_{j=1}^J \lambda_i [I(\mathbf{c}_{ij} | \mu_j) / (2\sigma_j^2) + \log(\sigma_j \sqrt{2\pi})] + H(\mathbf{c}_i)$

训练时令 $\mu_j = \mathbf{c}_j^*$ ，把 $H(\mathbf{c}_i)$ 视为常数，于是优化目标变为最小化 $\mathbf{c}$ 与逆推断 $\mathbf{c}^*$ 之间的差距：〔式〕 $\min_{\mathbf{c}} \mathcal{L}_i \approx \min_{\mathbf{c}} \sum_{j=1}^J \lambda_i [I(\mathbf{c}_{ij} | \mathbf{c}_j^*) / (2\sigma_j^2) + \log(\sigma_j \sqrt{2\pi})]$

读完可以回到主文 §4（值班手册），不影响你今天会用这套方法。

物理含义：逼着低维潜空间 C 去“复述”高维潜空间 Z

生成出来的物体样貌。这样一来，C 的每一维都对上了物体的某个主要变化特征，两个空间就正相关了——知识才能在它们之间传递。

这个生成模型被命名为 MFOo-GAN。

第三步：两个方向上的样本交换

- 低维 → 高维（ C 到 Z ）：把 $\mathbf{z} = [\mathbf{c}, \mathbf{z}]$ 里的“剩余变量” $\mathbf{z}$ 固定为常数（例如置零）。三个好处：① 搜索优先沿物体的主要变化方向推进；② 避免 $\mathbf{z}$ 随机化引入噪声，使 C 中的样本在下一轮可以复用*；③ 从 C 到 Z

的变换变得非常简单。

- 高维 $\rightarrow$ 低维 (Zto C) : 走判别器的逆推断结构, 取后验 $Q(c'|x)$ 的均值 c' 。相比作为先验的 c , c' 通过 σ_z^2 把 z 带来的变化也计入了, 逆推断更稳健*。

第四步: 以贝叶斯优化实例化时的两个策略

策略一: 用低维空间的最优解, 去收窄高维空间的搜索范围

低维空间 C 捕捉的是物体的主要变化, 因此它的当前最优解 $c_{\min}$ 很可能就落在真实最优解附近。于是用 $c_{\min}$ 在高维空间 Z 里划出一块收窄区域集中搜索, 区域大小由参数 Δ 控制 (默认 0.15) [原文 P06 § III-B-1、§ IV-B]。

这一步的直觉: 低维潜空间先粗定方位, 高维潜空间再精修。

本文主设定: MFOO-GAN 的高维潜空间 $Z=13$ 、低维潜空间 $C=3$ [原文 P06: high- and low-dimensional latent spaces ... set to be 13 and 3]。

另有对照实验把单潜空间拉到 23 维 (GMO-High) 与 4 维 (GMO-Low) 以展示「维数 $\uparrow$ 更准但更慢」 [原文 P06 Fig.9 一带] ——不要把 23/4 与 13/3 混成同一套旋钮。

策略二: 把“跨空间变换来的样本”当低保真样本, 用多保真 GP 消化

从 Z 变换到 C、或从 C 变换到 Z 的样本, 都伴随精度损失 (毕竟经过了压缩/逆推断)。本文的处理很聪明: 不丢掉它们, 而是把它们当作低保真样本, 构建多保真高斯过程 (MFGP), 用协方差矩阵作为知识库 $\mathcal{M}(t)$: [式] $k_M(c, c^*) = [\rho_{11}k(c, C), \rho_{12}k(c, C^*)]$

多保真核的分块形式: $K_M(C)$ 的对角块为 $\rho_{11}K(C)$ 与 $\rho_{22}K(C^*)$, 交叉块为 $\rho_{12}K(C, C^*)$ 与 $\rho_{21}K(C^*, C)$, 再加噪声对角 D。写作 [式] $K_M(C) = \text{Block}(\rho_{ab}K(C_a, C_b))_{a,b \in \{1,2\}} + D$

其中 ρ_{ij} 建模高保真与低保真样本的相关性, D 为噪声对角阵。

这一步与第 02 讲 (Filter-GEI) 的多保真思路一脉相承, 但“低保真”的来源从粗网格 CFD 变成了跨潜空间的变换——这是个很漂亮的迁移。

流形一句话考试:

合法叶型的集合更像瘦毯子, 不像 384 维实心立方体。

生成模型若学到毯子, 优化就在毯子上走; 否则你在立方体里撞墙。

4. 算法控制流 (原文 Algorithm 3)



ZC camera 双潜摄影: C 构图 Z 对焦 相册传话

指读: 粗搜与细修分工; 知识库避免重复拍烂构图。

【引】值班手册: 先看「什么情况下走哪条分支」, 公式是对白速记不是主角。

输入: 目标优化问题、结构化输入空间的数据集 X

1. 训练 MFOO-GAN, 得到高维潜空间 Z 与若干个正相关的低维潜空间 C
2. 用 LHS 在各潜空间生成初始样本并评估, 得到 $\{Z, Y(Z)\}$ 、 $\{C, Y(C)\}$
3. while 未满足终止条件:
4. for 每个潜空间 $Z_i \in Z$: C_i :
5. 建立/更新多保真 GP 代理 (MFGP)
6. 用 EI 采集函数选出下一个查询点 z^* $i = \arg \max E(I(z^*))$
7. 评估新样本的真实目标值, 更新该空间的训练集
8. end for
9. 高维空间的强化开发:
- a. 用低维空间当前最优 $c_{\min}$ 更新 Z 的收窄区域 (尺寸参数 Δ)
- b. 在收窄区域内用 EI 继续搜索
- c. 在 Z 与 C 之间做样本交换 (图 3 的两个方向)
10. end while

一句话记住: 形状在流形不在欧氏方盒; 进阶: Z 细 C 粗双潜分工。

主比喻回扣: 把上面的分支再翻译成「合法叶型挤在瘦流形毯子上」——若某步在生活里说不通, 多半是符号没对齐。

双潜像摄影: C 变焦定构图, Z

对焦调纹理; 知识库是相册, 记录好构图。

双潜 + 知识库的值班隐喻:

C: 变焦定构图 (粗语义快速定向)。

Z: 对焦调纹理 (细结构精修)。

$\mathcal{M}(t)$: 相册, 避免重复拍烂构图。

缺相册时, 两层会各搜各的, 像两个实习生不交班。

5. 实验验证与量化突破

先报胜负:

先读结论句与最大那一格, 再读全表; 表是证据架不是背诵清单。

算例一: 低速翼型优化

- 原始空间: 192 个点 $\rightarrow$ 384 个设计变量, 变量高度耦合;
- 目标: 最大化升阻比 L/D , 用 XFOIL 计算; $Re=1.8 \times 10^6$ 、 $Ma_{\infty}=0.01$ 、 $AoA=0^\circ$;
- MFOO-GAN: 高维潜空间 $Z=13$, 低维潜空间 $C=3$ [原文 P06 明确 set to be 13 and 3]; SVD (就是线代里「把一个矩阵拆成三个矩阵」的标准手法, 学名奇异值分解; 这里用它把一批形状压到 13 个主要变化方向上) 基线潜空间维度同为 13;
- 每组实验重复 10 次 [原文 P06 § IV-C-1]。

算例二: 亚声速翼型优化

- 工况改为 $Ma_{\infty}=0.45$ (其余同低速算例);
- MFOO-GAN: $Z=23$, $C=4$; SVD 潜空间维度 23 [原文 P06 § IV-C-2]。

算例三: corbel (牛腿结构) 设计; 算例四: 面积最大化问题 [原文 P06 摘要]。

基线共六类 [原文 P06 § IV-A]: GMO-High、GMO-Low (单潜空间 + 标准 BO)、GMO-NashEGO (多形式 BO, 交替子空间随机生成)、SVD-BO (SVD 线性降维 + BO)、GMO-CMAES、GMO-IKEA。

核心结论 (原文明确表述, 均为定性结论):

1. GMFOO 的收敛速率与最终解都优于 SVD-BO。原因: SVD 本质上是线性降维模型, 其潜空间的解精度不如 MFOO-GAN 这类非线性深度模型 [原文 § IV-C]。
2. GMO-Low 收敛最快、但最终解较差; GMO-High 最终解更好、但收敛更慢——这正是第 2 节说的两难。原文原话: 在 23 维设计空间中的 GMO-High, 其收敛速率明显慢于在 4 维空间中的 GMO-Low [原文 § IV-C]。
3. GMFOO 同时在两个潜空间上优化、互相补足, 因而既拿到最好的解, 又有更快的收敛速率。
4. 一个重要的反例: 同样做“多形式优化”的 GMO-NashEGO 反而差于单潜空间的 GMO-High / GMO-Low。原因是它的交替子空间是随机生成的, 缺少 GMFOO 那种“正相关”设计来保证知识有效传递 [原文 § IV-C]。

【钉】这条反例特别有价值: 它证明“多空间并行”本身不带来收益, 真正带来收益的是“空间之间建立了可用 correspondence (对应关系)”。

△ 数字说明: 原文以收敛曲线图 (10 次运行的阴影区) 与最终解箱线图呈现结果, 摘要与正文未给出统一的数值表格。本讲因此不引用任何具体提升百分比——凡原文未给出的数字, 本讲不写。

体感换算: 把关键数字换成「工程师的周/月」或「一次签字的风险」——数字才进长期记忆。若原文给了墙钟时间或成本比, 优先用原文换算。

下游: 07 迁移、08 反推, 都站在「先有合法流形」上。

6. 审稿人批判与承前启后

把软肋放上可信度刻度 (0=完全不信, 5=可当默认工具):

维度	打分	人话
问题	5	
双潜	4	
实现	3	
工程	3	

可以攻击的点：

1. 核心问题只被缓解、未被根除。本文的动机是“潜空间维度难定”，解法是“高低搭配”，但高维维度（13 / 23）仍是按算例人为给定，低维维度 d_L 仍要在 [3,5] 区间里试。
2. 新增两个超参：收窄尺寸 Δ （默认 0.15）与低维维度 d_L 。原文做了敏感性分析（§ IV-F），但默认值仍是经验值。
3. 算例的“昂贵”程度有限：翼型用 XFOIL（准二维、秒级求解），并非真实的三维 RANS 叶栅。本文没有在叶轮机械的昂贵 CFD 场景上验证——这一点必须诚实，因为“昂贵黑箱”的全部前提在本文算例中是被弱化的。
4. 生成模型依赖训练数据分布：MFoO-GAN 在 UIUC 翼型数据库上训练；若目标形状明显偏离训练集（本讲的推论，非原文断言）（例如全新的超临界叶型、涡轮端壁），潜空间的表达能力会打折。
5. 工程链路复杂：Python（GAN）+ MATLAB（BO）+ PERL（胶水脚本）三语言串联，复现与部署成本高。

承前：- 直接延续论文 01（CR-EI）：CR-EI 用 GAN 做翼型参数化（13 维），本文则把“潜空间维度该怎么定”本身变成研究问题。- 方法论上继承 GMO 两阶段框架、InfoGAN、贝叶斯优化与多保真 GP。

启后：- 论文 08（SW-VAE）：把“多潜空间 + 知识迁移”从同一任务内的并行推进到跨任务迁移——上一个型号学到的设计知识，迁移到新型号上；- 论文 17（GTO）：进一步引入梯度重参数化，让生成式潜空间能直接支撑梯度式迁移优化；- 论文 14（VAE-NURBS 端壁参数化）：把“生成模型学潜空间再优化”的思路从翼型推广到非轴对称端壁，但用的是 VAE + NURBS 层而非 GAN [出版商页面摘要，论文 14]。

附：潜维两难的选型尺

症状	可能病因	动作
大量自交/尖角	在欧氏坐标硬优	先生成流形
潜维很大仍表达差	流形没学好 / 数据脏	查数据与解码器
潜维很小优化假收敛	表达能力不够	增维或双潜（Z 细 C 粗）
两层各搜各的	缺知识库传话	加 $\mathcal{M}(t)$ 或精英迁移

摄影比喻复盘：C 定构图，Z 调纹理；相册（知识库）避免重复拍烂构图。

附：从「坐标优化」到「流形优化」的切换令

切换前症状：大量 CFD 浪费在自交/尖角；优化器在非法区空转。

切换令：停止在 384

维盒子里挪点；先训练/借用生成模型，把搜索关进合法毯子。

双潜何时上：单潜要么太大（浪费）要么太小（表达不够）——Z 细 C 粗是折中，不是炫技。

附：GMFoO 故障排查

症状	先查
大量非法形	解码器/数据，是否真在流形上
两层各玩各的	知识库 $\mathcal{M}(t)$ 是否传精英
粗层好细层崩	Z 维或正则
细层好粗层盲	C 是否太小或训练不足

附：流形优化的三日试点计划

D1：冻结欧氏坐标优化；只评估生成样本合法率。

D2：单潜空间小规模优化，记录非法率与性能。

D3：开双潜 + 知识库，对比「有相册/无相册」的重复搜索次数。


试点失败标准：合法率无提升、或两层不交班。失败就停，不扩算力硬刚。

图卡：潜维两难

Z 高维精但对焦难搜，C 低维好搜但信息少。GMFoO

的答案不是二选一，而是 C 构图 + Z 对焦

双潜协同——一个潜空间不够。




latent dilemma: 高维 Z 对焦 vs 低维 C 构图双潜协同

图卡：坐标 → 流形切换令

欧氏盒子里乱采大量非法点 =

交学费；切换到瘦流形上只产合法形状。GMFoO

的第一道口令是：还在变量坐标里硬搜吗？



manifold switch: 坐标乱采切换到流形合法形状

图卡：双潜相册传话

C 负责构图、Z

负责对焦，知识库相册是两者传话的介质。双潜不是两套孤立相机。



album pass: C 构图与 Z 对焦经相册传话协同

章末：30 秒复述 · 自测 · 元数据

30 秒复述稿（可朗读）：合法形状在瘦流形上。GMFoO 用双潜：C 粗搜、Z 细修，知识库传话。反派是潜维两难——太大浪费、太小表达不够。先离开欧氏方盒，再谈优化器。

自测（先做再对答案）：

1. 为何不直接优化坐标？
2. Z/C？
3. 知识库？

▼ 点开看参考答案


1. 易非法/自交。2. 细/粗。3. 跨层传好结构。本讲元数据（读完再看，不挡故事）| 项 | 值 | | :--- | :--- | | 规范编号 | 06 | | 原始文献 | IEEE Transactions on Cybernetics, 2023, 53(7): 4347–4360 | | DOI | 10.1109/TCYB.2022.3165044 | | 作者 | Zhendong Guo, Haitao Liu, Yew-Soon Ong, Xinghua Qu, Yuzhe Zhang, Jianmin Zheng | | 本地原文 | Generative_Multiform_Bayesian_Optimization.pdf | | 证据等级 | A（本

地原文逐句可查) |

! 著录更正: 仓库旧文档 (README、全集汇总、论文链接整理) 给出的 DOI 为 10.1109/TCYB.2022.3168744, 尾号错误。原文首页印刷及第三方期刊的参考文献著录均为 10.1109/TCYB.2022.3165044。详见 corpus/doi_verification.md。


本讲正是下图中第3阶段「生成式模型 (GAN / VAE) — 更省的代表」的开篇工作: 前两阶段 (代理模型、多保真) 省的是“算多少次”, 从本阶段起省的是“用什么来表示几何”。

AI4Turbomachinery 技术演进路线图



AI4Turbomachinery 技术演进路线图 (AI4Turbomachinery evolution map, 中文标注版; 本讲位于第3阶段)

AI for Turbomachinery: evolution map



AI4Turbomachinery evolution map (English labels; this lecture is stage 3: generative model)

| 反派绰号 | 潜维两难 || 主比喻 | 384 个坐标随便挪就会自交 |

动手任务

任务: 思考并回答: 如果你有 384 个翼型变量, 想压到 5 维搜索, 你会用什么方法? 写一个简短的分析 (200 字以内), 对比“直接用 PCA 降维”和“用 VAE 学潜空间”的优劣。

产出文件: your_notes/experiments/L06_潜空间降维分析.md

验收标准: 文件存在且包含你对两种方法的对比分析

【AI】做完后: 用主动回忆 Prompt 做补漏, 再用批判收尾 Prompt 做深度加工。

沉淀清单

学完本讲, 你应该产出以下文件:

- your_notes/knowledge_cards/L06_GMFoO.md — 知识卡片
- your_notes/experiments/L06_潜空间降维分析.md — 动手任务记录
- 个人 Prompt 库中新增 ≥ 2 个 Prompt

2. 源样本加权

3. 120→100 负荷跳跃会灾变

主比喻: 红烧肉火候不能原样套牛腩




第07讲心智图: 跨型号迁移与加权

看图三秒: 源域加权、流形可迁、120→100 跳跃; 反派生搬经验。

本讲赌注: 若不加权就迁, 高负荷分离泡可能直接把型号窗口打穿。

【补】读本讲前, 你只需要先知道 3 件事 (都出自 第零章 与 第零章 B · 四张补丁卡; 忘了就点回去看一眼, 不用背): 1. 自编码器与潜空间: 编码器压缩成一句话, 解码器还原成形成 (卡② B.2.4) 2. 训练 = 沿梯度下山; 损失函数 = 一本「差得有多离谱」的账 (卡② B.2.2) 3. 多保真: 把大量便宜样本与少量昂贵样本拼起来用 (第 02 讲)


1. 生活与物理直觉引子: 为什么“相关经验”能帮你, 也可能坑你



kitchen migrate 可迁工序结构 vs 死时钟

指读: 左: 先焯后炖可迁; 右: 90 分钟死表不可迁。

「120→100 负荷跳跃」



load jump 120 to 100 story 负荷跳跃与迁移救援 [原文 P08]

指读: 左: 温和分离; 右: 负荷一跳分离泡灾变; 中间加权迁移是救援桥, 不是装饰。

先看一个生活场景。你是一名厨师, 已经把“红烧肉”做到了极致。现在老板让你做一道从没做过的“红烧牛腩”。

你会怎么做? 显然不会从零开始瞎试——你会把红烧肉的经验搬过来: 先焯炒、再上糖色、小火慢炖……因为这两道菜的物理过程高度相似。这就是迁移学习 (transfer learning)。

但这里有个陷阱: 如果你把“猪肉要炖 90 分钟”这条经验原封不动地套到牛腩上, 可能就炖过头了。经验有价值, 但不能照搬——用得不好, 反而比不用更糟。在优化领域, 这叫负迁移 (negative transfer)。

【第07讲】SW-VAE /

KT-ASO: 把上一个型号的设计经验“搬”到新型号上 (论文 08)

【靶】开讲前 (5 分钟): 用预习向导 Prompt 让 AI 帮你建立直觉框架, 再开始读正文。

本讲开场 90 秒

上讲闪回: 上讲同分布生成; 本讲跨型号: 经验如何帮、如何坑。

本讲反派: 「生搬经验」

只要带走 3 句口诀:

1. 迁流形与先验, 不是死参数

把这个比喻映射到涡轮叶片设计：

- 源任务（source task）：某个已经优化完成的型号（比如 GE-E3 低压涡轮叶片在原负荷下）；
- 目标任务（target task）：新的设计要求（比如把叶片数从 120 减到 100，成为超高负荷叶片）；
- 要迁移的知识：源任务优化过程中积累的样本（几何 + 对应的 CFD 评估结果）。

本文要做的事：让这些“上一个型号”的样本，帮新型号的优化少烧几百次 CFD。

迁移的厨房纪律：

红烧肉的「先焯后炖」可以搬；「猪肉必须 90 分钟」不能死搬。源任务样本要加权，否则新型号数据会被旧型号淹没——像师傅回忆压过徒弟实测。

纪律：先焯后炖可迁；必须 90 分钟不能死迁。

先猜后揭：若本讲反派「生搬经验」赢了，你的下一笔 CFD/实验预算会怎样被浪费？揭晓贯穿 §3-§5。

生活元素	工程元素	符号
主比喻侧	源/目标	X_S/X_U
主比喻侧	几何正则	L_P
主比喻侧	性能损失	C_pt
主比喻侧	加权VAE	SW-VAE

红烧肉 vs 牛腩（加长）：

可迁的是焯水煨香慢炖的结构；不可迁的是「必须 90 分钟」死参数。120→100 负荷下分离泡会灾变，源域必须加权。

红烧肉迁移实验（加长剧本）：

师傅 A 的牛腩秘方写着「小火 90 分钟」。师傅 B 换了五花肉，仍照 90 分钟——柴。

可迁的是「先焯后煨再小火」的结构；不可迁的是时间表上的死数字。

叶片 120→100 负荷跳跃同理：源域经验要加权，相关的进厨房，不相关的别污染汤底。

失败会怎样：生搬几何参数表 → 分离泡灾变 → C_pt 冲到双位数 → 型号窗口关闭。迁移不是锦上添花，是救援绳。

跨型号厨房的完整菜单：

- 可迁：焯水→煨香→小火的工序结构，以及「别把肉炸糊」的正则。

- 不可迁：牛腩 90 分钟的死时钟、上一代最优安装角的照抄。


120→100 的负荷跳跃，像把火突然开大：源域经验仍有用，但必须加权——相关的进汤，不相关的别污染。

C_pt 是救援量表，不是榜单量表：

双位数损失掉到个位数，谈的是型号窗口还在不在；小数点第三位留给已稳住的阶段。


2. 叶轮机械中的真实工程死穴：高保真 CFD

越用越贵，预算却越来越少



transfer bridge 加权过河的迁移桥

指读：源域加权过桥；死参数不能原样搬；高负荷侧分离泡要被压住。



旧型号历史样本的再利用：叶片数 120→100 与预算收缩 (blade 120 to 100, 数值见 [原文 P08 §5], 手绘笔记版)

指读：这张图是本讲工程死穴的一张图版本。

原文开头的逻辑链很清晰：

涡轮叶片气动形状优化 (ASO) 是典型的昂贵黑箱问题。随着设计要求日益严格，高保真仿真的需求上升，仿真成本急剧增加，这意味着一个优化周期内允许的仿真调用次数越来越少。[原文 P08 摘要]

前几讲的所有方法 (CR-EI、Filter-GEI、GSDE、DA-EGO) 都在回答“下一个点算在哪里”。本文换了一个更根本的问法：

能不能干脆不“从零开始”？

如果上一个型号的优化过程已经产生了成百上千个样本，而这些样本与新型号共享大量气动规律，那么把这些历史样本当“免费的知识”用起来，是不是就能减少新任务需要的 CFD 次数？（本讲设问，具体降幅见本讲第 5 节的原文数据）

本文给出的答案：是的，而且效果显著——取得相近最优解时，KT-ASO 至少减少 50% 的函数调用 [原文 P08 摘要]。

现场感：周五下班前组长要数——你面对的不是可以慢慢推的练习题，而是算错一次就不可回收的预算。

高保真越用越贵的夹击：

新型号要更多

CFD，预算却更紧；还指望「把旧型号最优外形贴过来」。

贴过来的那一刻，你可能把源域的局部最优当成了目标域的全局——这是生搬经验的数学脸。


3. 数学公式从 0 到 1 推导

【AI】卡壳？数学推导看不懂时，不要硬啃。把你的困惑发给 AI，用苏格拉底引导 Prompt。先自己想 5 分钟，再让 AI 一步步追问。

先把公式关掉，用主比喻说一遍：


红烧肉火候不能原样套牛腩

本讲反派是「生搬经验」。下面公式是这句话的展开；每条核心式尽量带回译。知识总量不删——深潜只是阅读路径，不是垃圾桶。



SW-VAE 的样本加权与三项损失函数 (swvae weighting, 手绘手账版)

SW-VAE / KT-ASO：把上一个型号的经验搬过来（论文 08）



样本加权迁移与源任务排序（SW-VAE KT-ASO transfer，中文标注版）

上图是本讲全部数学的「一张图版本」：左图是 SW-VAE——旧型号设计库经编码器进入潜空间后，按「迁移价值」给样本加权（橙柱高低），高性能、高相似样本权重更大，用于热启动新任务；右图是 KT-ASO 的源任务排序——横轴为与目标域的 MMD² 距离，距离近的源任务带来正迁移（绿点），远的属负迁移（红点），KT-ASO 只挑最近邻。

3B. 本讲符号卡（建议截图留存）

符号	人话	备注
X _S /X _U	源/目标	
L _P	几何正则	
C _{pt}	性能损失	
SW-VAE	加权VAE	

【引】先认符号再读公式；主文核心式有「回译」，装不下的细节仍在正文完整保留（不删知识）。【引】读不动时：本讲 §3 只需抓住核心式+它下面的「回译」；标【深潜 | 可跳过】的框可整框跳过，直奔 §4 值班手册——不影响你今天会用这套方法。

3C. 主路径公式与推导（知识全保留）

第一步：VAE 参数化与它的损失函数

用 VAE 把叶型（向量 x 由 202 个二维散点组成）压进 10 维潜空间（编码器输出 $z \in \mathbb{R}^{10}$ ）[原文 P08: 202 two-dimensional; 网络图 Input $\in \mathbb{R}^{10}$]。损失函数是三项加权：
〔式〕 $L(x) = KL(x) + \lambda_1 MSE(x) + \lambda_2 L_P(x)$

回译：训练的总账本分三项——KL 管「潜空间别乱跑」，MSE 管「还原出来的叶型得像原图」， L_P 是叶片专属的规矩（尾缘不许薄于基准）。这一步负责的是把「长得像」与「能用」同时写进损失函数； $\lambda_2=500000$ 这个数字本身就说明最后一条是硬约束，不是装饰。

- KL: KL 散度，约束潜空间的分布；
- MSE: 输入叶型与重构叶型的均方误差；
 L_P : 叶片几何专属的正则项——约束尾缘不薄于基准，防止生成畸形叶型：【深潜 | 可跳过】几何正则项 L_P 的具体写法（只需知道「尾缘不许薄于基准，权重给到 500000」）

〔式〕 $L_P = E[(\max[0, (r^{ref}_{min} - r_{min}) / (r^{ref}_{min} - r_{min})])^2]$
实验取 $\lambda_1 = 1, \lambda_2 = 500000$ 。
读完可以回到主文 §4（值班手册），不影响你今天会用这套方法。

此外，解码器末端嵌入了一个 FFD 层：控制点为 6×5 网格；每个控制点有 2 个自由度（前缘/尾缘上的点除外），故主动设计变量共 50 个标量（不是「30 个点=30 维」）[原文 P08: 6×5 grid; total number of variables of FFD active control points is 50]，以保证生成叶型的光顺性。

第二步：核心难题——为什么源样本会被“淹没”，进而引发负迁移
原文引用 Tripp et al. 的观察：

VAE 所学设计空间中的样本分布，大致正比于其在训练集中的出现频率。这带来两个连锁问题：

1. VAE 有效训练需要上千个样本（本文用了 1010 个无标签叶型），而源样本只有几十个（本文每轮用 40 个）。直接混在一起训练，源样本的独特特征会被彻底淹没。
2. 更糟的是，源样本是“已完成任务的优化解”，它们往往落在训练集分布之外。于是用基础 VAE 把源样本重参数化进潜空间时，重构出的叶型和原始叶型差得很远——迁移过来的“知识”本身就是错的

，用它引导优化只会拖后腿。这就是负迁移。
第三步：样本加权训练策略（SW-VAE 的核心）
解法分两层。第一层：把源样本纳入训练集（让它不再位于分布之外）。〔式〕 $\mathcal{L}_w = \sum_{i=1}^n \lambda_i^S L(x^S_i) + \sum_{j=1}^n \lambda_j^T L(x^T_j)$
关键在于：在每个 epoch 的每个 batch 中，固定源样本数 n^S 与无标签样本数 n^T 的比例（实验中取 $n^S/n^T=1$ ），分别从源样本集 X_S 与无标签集 X_U 中随机抽取。这样一来，哪怕源样本只占全集的极小一部分，它们的特征也能被稳定地学进去。

第四步：为什么“纳入源样本”还有第二个好处？
因为源任务与目标任务的最优解，特征上是相似的（本文的 t-SNE 可视化证实了这一点：两者的最优解落在潜空间的相近区域）。所以，把源样本学进潜空间，等价于人为提高了潜空间中“高分候选解”的比例——优化器一上手就站在离好解更近的地方。
第五步：多保真代理——把源样本当低保真数据
源任务与目标任务的趋势“相似但不完全相同”，因此最合理的处理是：

源样本 = 低保真样本；目标样本 = 高保真样本。
多保真高斯过程的协方差结构：
目标/源任务的联合核：对角块 K_T, K_S ，交叉块 ρK_{ST} 与 ρK_{TS} ，加噪声 D ；预测协方差行向量

〔式〕 $k_M(z, z^*) = [k(z, z_T), \rho k(z, z_S)]$
〔式〕 $\hat{y}_M(z) = k_M(z, Z)K_M^{-1}[Y_T, Y_S]^T, \sigma_M^2(z) = k_M(z) - k_M(z, Z)K_M^{-1}k_M(Z^*, z) + \sigma^2_n, 1$

其中 ρ 建模源与目标的相关性， D 是噪声对角阵。随后用多保真版 EI 引导搜索：〔式〕 $El_M(z) = (y^*(t)_{min} - \hat{y}_M(z))\Phi(u_M) + \sigma_M(z)\phi(u_M), u_M = (y^*(t)_{min} - \hat{y}_M(z))/(\sigma_M(z))$
这一步与第 02 讲（Filter-GEI）的多保真思想同源，但“低保真”的来源从粗网格 CFD 换成了历史任务的样本——这是本讲最值得记住的迁移。

4. 算法控制流（KT-ASO）

【引】值班手册：先看「什么情况下走哪条分支」，公式是对白速记不是主角。

- （1）训练样本加权 VAE
无标签叶型集 XU（1010 个，由基准叶型做 $\pm 10\%$ 几何扰动生成，不经 CFD）+ 源样本集 {xS, vS}m（已完成任务的高分样本）
→ 按固定 $n(S)/n(T)$ 比例分 batch 训练
（2）用 LHS 在 VAE 潜空间生成目标任务的初始样本，做 CFD 评估 → {zT, yT}
（3）用 VAE 编码器把源样本 {xS, yS}m 重参数化进潜空间 → {zS, yS}m
（4）合并 {zT, yT}（高保真）与 {zS, yS}（低保真），建立多保真 GP
（5）用多保真 EI 选下一个查询点，评估后加入 {zT, yT}
（6）重复（4）（5）直至满足终止条件

一句话记住：迁流形与先验，不是死参数；进阶：源样本加权。
主比喻回扣：把上面的分支再翻译成「红烧肉火候不能原样套牛腩」——若某步在生活里说不通，多半是符号没对齐。

- KT-ASO 值班口令（人话）：
1. 源域样本先过加权门（SW-VAE / 相关权重）。
 2. 几何正则 L_P
守住尾缘等不可破底线——「宁可不好看，不能薄到脆」。
 3. 目标域无标签点靠流形对齐，不靠抄参数表。
 4. 优化时把迁移先验嵌进搜索，而不是优化完再后悔。

- KT-ASO 值班加长版：
1. 源域样本过加权门（相关高权重）。
 2. L_P 守几何底线（尾缘等）：「宁可不好看，不能薄到脆」。
 3. 目标域无标签点靠流形对齐，不靠抄表。
 4. 优化时迁移先验在场，而不是优化完再后悔。
 5. 出报告时同时给：加权策略、正则强度、失效案例（生搬对照）。

5. 实验验证与量化突破
先报胜负：
先读结论句与最大那一格，再读全表；表是证据架不是背诵清单。
数值验证（先验证多保真迁移本身）[原文 Table 1、Fig. 8]
• 源任务：0.9×Ackley6d + 0.1×Rosenbrock6d；目标任务：Ackley6d（均为 6

维， $x_i \in [-2, 2]$ ）；

- 源样本先在源任务上跑标准 BO 获得；初始样本数与源样本数均设为 6 倍维度；10 次独立运行 [原文 P08 Table 1 / Fig. 8] ；
- 结论：多保真版（MFO）收敛更快、最终解明显更好。

工程算例：GE-E3 低压涡轮第二级转子叶片（rb23）的超高负荷改型

- 做法：把叶片数从 120 减到 100（栅距由 25.006 mm 增大到 30.0072 mm），进出口边界条件保持不变；
- 代价：尾缘出现明显分离泡，总压损失系数 C_{pt} 从 4.22% 恶化到 12.99% [原文 Table 2、§ 5.1] ；
- 优化目标：最小化 C_{pt} ，约束流量在基准的 [0.98, 1.02] 倍内、尾缘最小半径不薄于基准；
- 边界条件：进口气流角 49.3°、进口总压 319,339.2 Pa、进口总温 1161 K、出口静压 245,618 Pa；轴向弦长 26.6 mm；
- 源任务：同一叶型在原负荷下的优化（假设已完成）；先在源任务上跑 10 次 BO 收集 1400 个中间样本，取 C_{pt} 最低的 400 个为候选，每次 KT-ASO 运行随机抽取 40 个作为源样本；
- 样本预算：所有对比流程统一 140 次 CFD，各运行 10 次。

先看重参数化精度——这是迁移能否成立的前提 [原文 Table 4，归一化 MSE]

模型	重构误差
基础 VAE	$(8.610 \pm 3.168) \times 10^{-3}$
样本加权 VAE	$(1.986 \pm 1.572) \times 10^{-4}$

误差降低一个数量级以上。原文的可视化也显示：基础 VAE 的潜空间里，40 个源样本落在边缘区域（几乎不被覆盖），重参数化后叶型与原叶型有明显偏差；而样本加权 VAE 的潜空间很好地覆盖了源样本，重参数化后几乎完全重合。

再看最终优化结果（10 次运行的中位数） [原文 Table 5]

方法	C_{pt} (%)	流量 $\dot{m}$	出口气流角 (°)
基准（超高负荷 rb23）	12.99	475.02	-60.86
FFD-BO（传统参数化）	4.96	472.45	-61.04
GAN-BO	4.86	474.47	-60.95
VAE-BO（基础 VAE）	4.85	470.18	-61.25
VAE-W-BO（样本加权 VAE）	4.75	468.78	-61.35
KT-ASO（加权 + 多保真迁移）	4.52	473.32	-61.06

这张表设计得非常干净，可以做两步“消融”：

1. FFD-BO → VAE-BO（4.96 → 4.85）：验证生成式参数化优于传统 FFD。原因是 FFD 的设计空间是围绕单个基准叶型扰动出来的，而 VAE 的设计空间是从 1010 个不同叶型中学出来的，形状多样性（高分候选解比例）高得多。
 2. VAE-BO → VAE-W-BO（4.85 → 4.75）：单独验证样本加权的收益。
- VAE-W-BO → KT-ASO（4.75 → 4.52）：单独验证多保真知识迁移的收益。
- KT-ASO 相对基准把 C_{pt} 从 12.99% 降到 4.52%；
3. 相对最好的非迁移基线 VAE-BO（4.85%），再降 0.33 个百分点 [由 Table 5 计算] ；
 4. 摘要给出的核心结论：与无知识迁移的 ASO 流程相比，KT-ASO 在取得相近最优解时至少减少 50% 的函数调用；在相同样本预算下则取得远优于对比流程的解。

体感换算：把关键字换成「工程师的周/月」或「一次签字的风险」——数字才进长期记忆。若原文给了墙钟时间或成本比，优先用原文换算。

C_{pt} 救援：损失从双位数降到个位数，迁移是从型号失败边缘拉回——看灾难是否解除，不只看均值小数点。

预习 08：有编码器则 embed；若只留点云，请看 GTO。

6. 审稿人批判与承前启后

把软肋放上可信度刻度（0=完全不信，5=可当默认工具）：

维度	打分	人话
动机	5	
效果	4	
超参	2	
理论	2	

可以攻击的点：

1. 源任务与目标任务是“人为构造”的同构问题。目标是同一 rb23 叶型减叶片数得到的超高负荷改型，源任务是同一叶型在原负荷下——两者过于相似。真实工程中“相关任务”未必这么规整，源与目标差多远时迁移会失效，本文没有给出判据。
2. 负迁移的边界未被量化。本文用样本加权规避了负迁移，但没有系统扫描“源目标相似度 vs 迁移收益”的曲线。
3. 训练样本 X_U 不含气动信息。1010 个叶型是纯几何扰动生成的、未经 CFD，只用于学形状流形——潜空间本身没有气动偏好。
4. 只是二维中截面优化。作者本人在结论中也承认框架“可进一步扩展到三维多学科优化”，即本文尚未做到三维。
5. 超参偏经验： $\lambda_2 = 500000$ 、 $n^*(S)/n^*(T) = 1$ 、源样本 40 个、潜空间 10 维，均未见系统的敏感性分析。
6. GAN-BO 基线的公平性存疑。原文自己也说 GAN 训练更困难，且其“样本重参数化与样本加权训练”尚需研究——也就是说，GAN-BO 是个“没吃饱”的对手。

承前：- 继承 VAE/GAN 参数化（论文 06 GMFoO）与多保真 GP（论文 02 Filter-GEI、论文 06）。- 关键跃迁：GMFoO 是“同一任务内多潜空间并行”，本文是“跨任务知识迁移”——后者才是真正能把 CFD 次数降一个量级的方向。

启后：- 论文

17（GTO）：本文的迁移是“把源样本当低保真喂给代理模型”；GTO 更进一步，用 GAN + 梯度重参数化让源域知识能直接以梯度方式参与目标优化；- 论文 13（EMFS / MSFO）：两者处理的是同一个隐患——“低保真（源）样本不会误导优化”。本文靠固定的多保真核处理，EMFS 则用 DBSCAN 主动侦测失真区，是同一问题的两种解法。

C_{pt} 救援怎么读：

若性能损失从双位数掉到个位数，迁移是在救型号窗口，不是在刷榜。读表时盯「灾难是否解除」与约束是否仍满足，不盯小数点第 3 位。

附：可迁 / 不可迁清单（厨房版）

可迁	不可迁
先焯后焗再慢炖的结构	「必须 90 分钟」的死时间表
形状流形与正则 L_P	源域最优的具体安装角照抄
加权源样本	不相关源等权污染


120→100 负荷跳跃：分离泡可能灾难——加权与正则就是安全带。

附：迁移项目开题三问

1. 源/目标负荷差是否可能触发分离机制质变？
2. 有没有可计算的相关/权重，而不是拍脑袋 0.5？
3. 失败定义是什么—— C_{pt} 阈值、约束违反，还是「看起来像」？三问答不全，先别开「全自动迁移」。

图卡：迁移加权过河


旧型号经验搬到新型号，靠的是加权样本过河，不是死搬时钟参数。可迁的是结构与分布形状；死数字掉河里。



weight bridge transfer: SW-VAE 加权过河 120→100 [原文 P08]

图卡: 可迁 / 不可迁清单


可迁: 工序结构、损失形状、加权经验; 不可迁: 死时钟转速、绝对叶片数、旧网格分辨率。开题三问之前先过这张厨房清单。



migrate checklist: 可迁结构经验 vs 不可迁死时钟数字

图卡: 迁移开题三问

① 源任务分布差多远? ② 哪些可加权哪些必须丢? ③ 失败如何回退单任务? 三问答不全, 迁移项目不准开题。



transfer three questions: 源差多远、谁可加权、失败如何回退

章末: 30 秒复述 · 自测 · 元数据

30 秒复述稿 (可朗读):

跨型号像换肉下锅: 迁结构与流形, 不死迁时间表。SW-VAE 加权源域, KT-ASO 把经验嵌进优化; 120→100 负荷跳跃靠迁移救命。生搬参数表是反派。

自测 (先做再对答案):

1. 举一个可迁与一个不可迁的例子 (厨房或叶片皆可)。
2. 为什么源样本要加权?
3. L_P 在守什么?

▼ 点开看参考答案

1. 可迁: 先编后炖的结构; 不可迁: 必须 90 分钟死时钟 / 照抄安装角。
2. 源非等权, 不相关会污染目标流形。3. 不可破的几何/工艺底线 (如尾缘不能薄到脆)。本讲元数据 (读完再看, 不挡故事) | 项 | 值 | :---| :---| 规范编号 | 08 | 原始文献 | Aerospace Science and Technology, 2024, 147: 108998 | DOI | 10.1016/j.ast.2024.108998 | 作者 | Zhendong Guo, Cunxi Li, Yun Chen, Liming Song*, Jun Li, Zhenping Feng | 本地原

文 | 1-s2.0-S1270963824001317-main.pdf | 证据等级 | A (本地原文逐句可查) |

【钉】命名规范: 完整流程叫 KT-ASO (Knowledge Transfer accelerated ASO, 知识迁移加速的气动形状优化); SW-VAE (sample-weighted VAE) 是其中的参数化组件。说"SW-VAE 算法"是不准确的。| 反派绰号 | 生搬经验 | 主比喻 | 红烧肉师傅做红烧牛腩 |

动手任务

任务: 用 code/transfer.py 的 mmd2

函数, 计算两组随机样本的分布差异。构造一组"近"样本 (均值差 0.5) 和一组"远"样本 (均值差 5.0), 观察 MMD² 的变化。

产出文件: your_notes/experiments/L07_MMD距离实验.md

验收标准: 文件存在且包含 MMD² 计算结果和你对"为什么 MMD² 可以用来判断源/目标差异"的一句话解释

【AI】做完后: 用 主动回忆 Prompt 做补漏, 再用 批判收尾 Prompt 做深度加工。

沉淀清单

学完本讲, 你应该产出以下文件:

- □ your_notes/knowledge_cards/L07_SW_VAE.md — 知识卡片
- □ your_notes/experiments/L07_MMD距离实验.md — 动手任务记录
- □ 个人 Prompt 库中新增 ≥ 2 个 Prompt

【第08讲】GTO: GAN

不会"反推", 那就用梯度硬算出来 (论文 17)

【靶】开讲前 (5 分钟): 用 预习向导 Prompt 让 AI 帮你建立直觉框架, 再开始读正文。

本讲开场 90 秒

上讲闪回:

07 有编码器; 本讲更残: 只会生成——梯度把点吸进潜空间。

本讲反派: 「参数化失传」

只要带走 3 句口诀:

1. 有G即可: 梯度反推 z^*
2. 无编码器也能学流形
3. 可嵌多保真思路

主比喻: 前辈只留坐标点云, 没有参数化图纸



第08讲心智图: GTO 梯度反推


看图三秒: 只有 G; z^* 吸点云; 对照 07 有编码器。

本讲赠注: 参数化失传时, 不会反推 z^* 就等于不会优化。

【补】读本讲前, 你只需要先知道 3 件事 (都出自 第零章 与 第零章 B · 四张补丁卡; 忘了就点回去看一眼, 不用背): 1. 生成器 G 只能正向「 $z \rightarrow$ 形状」, 没有现成的逆映射 (卡② B.2.5) 2. 梯度下降: 想找 z , 就让 $z \leftarrow z - \eta \cdot \partial L / \partial z$ 一步步挪 (卡② B.2.2) 3. 知识迁移 = 把上一个型号学到的经验搬到新型号上 (第零章 0.3 表)


本讲赠注: 不会把点云吸成 z^* , 参数化失传就等于优化权丧失。

1. 生活与物理直觉引子: 别人给的图纸, 只有一堆坐标点



lost param 参数化失传现场：只剩点云与 G

指读：硬盘里只有 STL；无编码器时用梯度把点吸进潜空间。



07 有编码器 vs 08 仅生成器+梯度反推

指读：左双箭头编码-生成；右只有 G，z 用梯度爬——两讲边界一眼看清。

第 07 讲讲过“把上一个型号的经验搬过来”。那里有个隐含的便利条件：源样本是我们自己用同一套参数化方法生成的，所以能通过 VAE 的编码器顺利映射进潜空间。

现在把场景换成更真实的工程处境：

你接手一个新叶型的设计任务。前辈留给你的，是几百个优化过的叶型，每个都由上百个坐标点描述——但当时用的是什么参数化方法（NURBS？FFD？控制点怎么定义的？），并没有留下（甚至这些结果来自别的单位）。

这时候，VAE 那套“用编码器逆推断”的便利没有了。更麻烦的是，如果你改用生成质量更强的 GAN，问题会更尖锐：GAN 根本没有逆推断能力——它只有生成器 G: z to x，没有编码器 x to z。

原文把这一点说得很直白：

当我们把源样本与目标样本一起用坐标散点表示时，可以用 GAN 学出一个共享潜设计空间……但如何把已完成任务的解仿射到待求解问题的设计空间，并不是一件平凡的工作。这可能解释了为什么迁移优化在以往的涡轮设计研究中鲜有涉及。[原文 P17 §3.1]

本文的第一个贡献，就是给 GAN 补上这个“反推”能力。

07 与 08 对照（防混）：

	第07讲 SW-VAE	第08讲 GTO
有没有编码器	有	往往没有
源样本形态	同参数化体系	可能只是坐标点云
关键动作	样本加权 + 迁移 BO	梯度反推 z^*

对照表请划住：有无编码器，是两讲边界。

先猜后揭：若本讲反派「参数化失传」赢了，你的下一笔 CFD/实验预算会怎样被浪费？揭晓贯穿 §3–§5。

生活元素	工程元素	符号
主比喻侧	生成器	$G(z)$
主比喻侧	反推潜码	z^*
主比喻侧	最大曲率	$k_{\max}$

失传现场：硬盘只有点云，参数化脚本在离职员工笔记本。优化前必须把点塞回生成模型潜空间——即 z^* 反推。

失传现场加长：

文件夹名还叫 blade_final_final2，里面只有

STL。参数化脚本在离职员工的加密盘。

你要做的第一件事不是开优化，而是问：有没有生成器 G？

- 有编码器 → 走 07，点云可 embed。

- 只有 G → 本讲：用梯度把 x 吸成 z^* ，再在潜空间动刀。

对照表请钉住：07 双箭头；08 单箭头 + 爬坡。

失传档案室（加长）：

- 抽屉 A：PDF 外形图，无参数。

- 抽屉 B：STL/点云，无脚本。

- 抽屉 C：传说中的「最终版」文件夹，编码器权重丢失。

GTO 的立场是：只要生成器 G 还在，点就能被梯度吸回潜空间。

吸回去之后，优化在 z 上做，解码回几何再评估——你重新获得「可微的参数化」，但必须用曲率等约束防止吸出不可制造的鬼形。

和 07 的边界再钉一次：


|| 07 SW-VAE/KT-ASO | 08 GTO || :--- | :--- | :--- || 编码器 | 有，可 embed |

无，靠反推 || 典型输入 | 成对/可编码样本 | 点云/无标签外形 ||

核心运算 | 加权迁移 + 潜空间优化 | $\argmin \|G(z) - x\|$ |

2. 叶轮机械中的真实工程死穴：二维叶型优化的 CFD 预算

高负荷低压涡轮：把栅距拉开之后



高负荷 LPT 叶栅几何与边界条件（blueprint points only，数值见 [原文 P17 Table 1]，手绘笔记版）

指读：这张图是本讲工程死穴的一张图版本。

本文的任务场景是高负荷低压涡轮（LPT）叶片设计。为什么高负荷叶片重要？

为响应提高航空发动机推重比的需求，目标任务是探索高负荷叶片——高负荷工况通过增大原 GE-E3 低压涡轮叶片的栅距来构造。[原文 P17 §4.1]

具体到本文：以 GE-E3 低压涡轮叶片为参考，把栅距从 25.006 mm 增大到 30.0072 mm，轴向弦长 26.6 mm、进口气流角 49.3°、进口总压 319 339.2 Pa、进口总温 1161 K、出口静压 245 618 Pa 均保持不变；出口气流角由 -64.19° 变为 -60.86° [原文 P17 Table 1]。高负荷基准的总压损失系数 ϵ_p 为 12.99% [原文 P17 Table 3 "Reference" 行]。

【附】同一算例的更多背景来自论文 08（第 07 讲）：该文指出这一栅距变化等价于叶片数从 120 减到 100，并给出原 GE-E3 叶片的损失系数 4.22%、以及高负荷后尾缘出现明显分离泡的流场描述 [原文 P08 §5 与 Table 2]。本文（P17）正文并未复述 4.22%、120→100 与分离泡，这些细节请以论文 08 为出处引用。

所以目标是：在这个高负荷条件下把总压损失重新压下去——而 CFD 预算只有每次运行不到 140 次评估 [原文 §4.3]。

现场感：周五下班前组长要数——你面对的不是可以慢慢推的练习题，而是算错一次就不可回收的预算。

二维叶型预算为什么仍贵：


即使是截面级 CFD，一轮设计要扫几何族 $\times$ 工况，次数仍轻松上千。生成式把搜索关进合法流形后，每一次 CFD 更可能花在合法形上——这是隐式省预算，不是魔法降网格成本。

3. 数学公式从 0 到 1 推导

【AI】卡壳？数学推导看不懂时，不要硬啃。把你的困惑发给 AI，用苏格拉底引导 Prompt。先自己想 5 分钟，再让 AI 一步步追问。

先把公式关掉，用主比喻说一遍：


前辈只留坐标点云，没有参数化图纸
本讲反派是「参数化失传」。下面公式是这句话的展开；每条核心式尽量带回译。知识总量不删——深潜只是阅读路径，不是垃圾桶。




生成器无逆映射，靠梯度下降反推 z^* (gradient reparam, 手绘手账版)

GTO: GAN 不会反推，那就用梯度硬算 (论文 17)

难点: GAN 只能正向，没有逆映射



GTO: 热启动新任务的优化



GAN 潜空间梯度反推与迁移热启动 (GTO gradient inversion, 中文标注版)

上图是本讲难点的「一张图版本」：左图是核心难点——生成器 G 只能正向 $z \rightarrow x$ 、没有逆映射，想把旧任务最优解 x 「翻译」回潜空间，只能在 z 上做梯度下降、最小化 $\|G(z) - x\|$ ，把 z 硬算出来；右图是收益——反推出的 z 作为新任务初始种群后，GTO (蓝线) 比无迁移基线 (灰虚线) 以更少的评估次数达到同等最优。

3B. 本讲符号卡 (建议截图留存)

符号	人话	备注
$G(z)$	生成器	
z^*	反推潜码	$\operatorname{argmin} \ G - x\ $
$\kappa_{\max}$	最大曲率	

【引】先认符号再读公式；主干核心式有「回译」，装不下的细节仍在正文完整保留 (不删知识)。【引】读不动时：本讲 §3 只需抓住核心式 + 它下面的「回译」；标【深潜 | 可跳过】的框可整框跳过，直奔 §4 值班手册——不影响你今天会用这套方法。

3C. 主路径公式与推导 (知识全保留)

第一步：样本加权 GAN (沿用第 07 讲的思想，换到 GAN 上)

GAN 损失加一项几何正则：〔式〕 $L(x) = \min_G \max_D V(D, G) + \lambda L_P(x)$

回译：GAN 的训练就是一场对抗——生成器 G

想造得以假乱真，判别器 D 想抓出假货， $\min/\max$

表示两人在同一个目标上对着干；后面加的 λL_P 是叶型的工程规矩 (不许尖角、不许自交)。这一步负责的是让生成器只在合法叶型的范围内发挥。

【深潜 | 可跳过】GAN 的原始目标函数与曲率正则 (只需知道「造假者与抓假者对打，外加不许尖角自交」)

〔式〕 $\min_G \max_D V(D, G) = E_{x \sim P_{\text{data}}} [\log D(x)] + E_{z \sim P_z} [\log (1 - D(G(z)))]$

正则项 L_P 用叶型最大曲率来抑制尖角与自交 (这是叶型生成的关键工程细节)：〔式〕 $\kappa_{\max} = \max(|\dot{x}\ddot{y} - \ddot{x}\dot{y}|) / (|\dot{x}^2 + \dot{y}^2|^{1.5})$

($\dot{x}, \dot{y}, \ddot{x}, \ddot{y}$ 用中心差分计算。)

读完可以回到正文 §4 (值班手册)，不影响你今天会用这套方法。

训练数据两部分的数量极不平衡：无标签叶型 X_U 有 1030 个，源样本只有 40 个。直接混训会淹没源样本特征，于是沿用第 07 讲的样本加权策略：

〔式〕 $L_w = \sum_{i=1}^n L(S_i) + \sum_{j=1}^n L(T_j)$

在每个 batch 中固定

$n^A(S)/n^A(T) = 1$ ——每批一半来自源样本、一半来自无标签样本。

第二步：本文的核心创新——梯度重参数化

把"把一个坐标叶型 x 映射回潜向量 z " 写成一个优化问题：〔式〕 $z^* = \operatorname{argmin}_z \|G(z) - x\|^2$

然后用 PyTorch 的自动微分做梯度下降：〔式〕 $z^{(n+1)} = z^{(n)} - \eta \cdot (\partial \|G(z^{(n)}) - x\|^2) / (\partial z^{(n)})$

一句话理解：GAN 没有编码器？那就用生成器本身做"反向搜索"——不断调整 z ，直到生成出来的叶型和目标叶型重合。

原文的可视化验证：把源样本先经梯度重参数化得到 z ，再用 $G(z)$ 重构出叶型 $\hat{x}$ ；原叶型与重构叶型几乎完全重合 [原文 Fig. 11、§4.2.2]。

第三步：多保真迁移——源样本当低保真 〔式〕 $\hat{y}_{\text{MFS}}(x) = \rho \cdot \hat{y}_{\text{LF}}(x) + d(x)$

其中 ρ 为缩放因子、 $d(\cdot)$ 为差异函数。

第四步：关键增强——用 EMFS 而不是普通 MFS

原文明确指出多保真的隐患：

当 HF 与 LF 的函数趋势相关性不好时，只用 HF 建的单保真代理 (SFS) 可能比 MFS 更准；随着 HF 样本增多，SFS 也可能反超 MFS。这时就会发生负迁移。[原文 §3.3]

这正是第 05 讲 (论文 13) 处理的问题。本文直接采用了论文 13 提出的 EMFS (集成加权多保真代理，GTO 的参考文献 [36] 即该文)：

〔式〕 $\hat{y}_{\text{EMFS}} = w_G \hat{y}_{\text{MFS}} + w_L \hat{y}_{\text{SFS}}, s^2_{\text{EMFS}} = w_G s^2_{\text{MFS}} + w_L s^2_{\text{SFS}}$

【深潜 | 可跳过】EMFS 自适应权重的解析式 (只需知道「谁更不确定，就少听谁一点」)

〔式〕 $w(x) = (s_{\text{L}}^2(x)) / (s_{\text{L}}^2(x) + s_{\text{G}}^2(x)), w_{\text{L}} = \operatorname{sigmoid}(m \cdot w - b) = (1) / (1 + e^{-(m \cdot w - b)}), w_{\text{G}} = 1 - w_{\text{L}}$

读完可以回到正文 §4 (值班手册)，不影响你今天会用这套方法。


其中：- s_{G}^2 ：用全部 HF 样本建的单保真 GP 的预测不确定性；- s_{L}^2 ：用 DBSCAN 检出的 HF 样本密集区内的局部样本建的 GP 的预测不确定性。

直观理解：MFS 能抓住全局趋势，局部 SFS 在 HF 样本密集区更准，EMFS 按不确定性自适应地加权融合，两者兼得。

采集函数相应改为多保真 EI：〔式〕 $EI_M(z) =$

$(f^A(t)_{\min} - \hat{y}_M(z)) \Phi(u_M) + \sigma_M(z) \phi(u_M), u_M = (f^A(t)_{\min} - \hat{y}_M(z)) / (\sigma_M(z))$

4. 算法控制流 (GTO / GAN-TO)



zstar climb 梯度爬坡六分镜

指读：①init z ② $G(z)$ ③距离 ④反传 ⑤曲率惩罚 ⑥得 z^* ——参数化失传被绕开，可制造没被绕开。

【引】值班手册：先看「什么情况下走哪条分支」，公式是对白速记不是主角。

- ① 收集数据集 X = 无标签叶型 XU (1030 个) + 源样本 {xS, yS}m (40 个, 坐标点表示)
② 用样本加权策略训练 GAN (每 batch 中源/无标签各半) → 共享潜设计空间 Z
③ 用梯度重参数化把源样本 xS 编码进潜空间 → {zS, vS}m
④ 目标侧: LHS 生成 40 个初始样本, 做 CFD 评估 → HF 样本
⑤ 以源样本为低保真、目标样本为高保真, 建立 EMFS (或 MFS)
⑥ 用多保真 EI 选点 → CFD 评估 → 更新样本集
⑦ 重复 ⑤⑥ 直到预算耗尽 (<140 次评估)

一句话记住：有G即可：梯度反推z*；进阶：无编码器也能学流形。
主比喻回扣：把上面的分支再翻译成「前辈只留坐标点云，没有参数化图纸」——若某步在生活里说不通，多半是符号没对齐。

梯度分镜：随机z → 算 G(z) 与 x 距离 → 反传更新 z → 直到像。曲率约束防止走出可制造悬崖。

反推分镜（可逐步指读）：
① 初始化 z；② 前向 G(z)；③ 算与目标点云/截面的距离；④ 反传 $\partial/\partial z$ ；⑤ 投影/惩罚曲率 $\kappa_{\max}$ ；⑥ 收敛得 z。
之后的优化在 z 上做，解码回几何再
CFD——参数化失传被绕开了，可制造约束没有被绕开。*

GTO 值班手册（可执行）：
输入：目标几何 x（点云/截面）+ 生成器 G
重复：
 $\hat{\mathbf{v}} = G(z)$
 $L = \|\hat{\mathbf{v}} - \mathbf{x}\| + \lambda \cdot \text{曲率/可制造惩罚}$
 $z \leftarrow z - \eta \nabla_z L$
输出：z*，此后在 z 邻域做设计搜索 / 迁移

停损条件：距离不再降、或曲率惩罚爆炸（说明在逼近非法形）。
回扣主比喻：反推是「把失传图纸重新装订进可编辑的本子」，不是「徒手描一张更漂亮的图」。

5. 实验验证与量化突破
先报胜负：
先读结论句与最大那一格，再读全表；表是证据架不是背诵清单。
算例：GE-E3 低压涡轮叶片高负荷改型（栅距 25.006 → 30.0072 mm）。

设置项	数值
边界条件	进口气流角 49.3°；进口总压 319,339.2 Pa；进口总温 1161 K；出口静压 245,618 Pa
叶型	轴向弦长 26.6 mm；栅距 25.006 → 30.0072 mm；出口气流角 -64.19° → -60.86°
参考设计损失	12.99%
求解器	RANS + SST γ - θ 转捩模型；对称边界 + 转捩周期；网格 492,700 单元
约束	流量在基准 [0.98,1.02] 倍内；尾缘最小半径 ≥ 0.2 mm（保证强度）
预算	初始样本 40（LHS），每次运行总评估 < 140；各方法 10 次运行

主要结果 [原文 Table 3]

设计	总压损失 ε_P (%)	流量 $\dot{m}$	出口气流角 (°)
参考（高负荷）	12.99	475.02	-60.86
FFD-EGO	4.72	471.50	-61.30
GAN-EGO	4.56	474.08	-61.05
GAN-TO-MFS	4.35	473.64	-61.10
GAN-TO-EMFS	4.29	467.70	-61.69

原文明确给出的三条结论：

- 为达到与 GAN-EGO 相近的优化结果，GAN-TO 所需的函数调用可减少 50% 甚至更多 [摘要与 § 4.4]；
- GAN-TO 的结果鲁棒性明显更好——其最优解的变动范围远小于 GAN-EGO；
- GAN-TO-EMFS 比 GAN-TO-MFS 收敛更快。原因是 MFS 抓住全局趋势、局部 SFS 抓住 HF 密集区的局部趋势，EMFS 的自适应融合兼得二者。

气动机理：优化后尾缘附近的分离泡几乎消失，吸力面尾缘的"压力平台区"也一并消失。相比 FFD-EGO，GAN-EGO 的叶片负荷更靠前、尾缘逆压梯度更平缓；而 GAN-TO-MFS 与 GAN-TO-EMFS 的设计还出现了二次加速（second accelerations），原文称其"of great help to reduce the pressure gradient along the suction surface, particularly the adverse pressure

gradients"（定性表述，未给梯度数值），因而总压损失更低 [原文 § 4.4]。

潜空间维度的敏感性分析（§ 4.5，很有价值）

- 维度增大 → GAN 更能捕捉叶片的精细局部几何 → 重参数化精度提高、设计空间中的真实最优更好；
- 但维度增大 → 建准代理需要更多训练样本；
- 在相同初始样本数与预算下：d=3 收敛最快但最终解较差，d=30 结果最差，d=5 是最佳折中。

跨论文对比（与第 07 讲是同一个基准问题）

两篇论文的 Table 1 / Table 2 数值完全一致（进口 49.3°、319,339.2 Pa、1161 K、245,618 Pa、26.6 mm、25.006→30.0072 mm、参考损失 12.99%） [对照原文 P08 Table 2 与 P17 Table 1]，因此可以在同一基准上排一条演进线：

方法	论文	总压损失 (%)
FFD-BO / FFD-EGO	08 / 17	4.96 / 4.72
GAN-BO / GAN-EGO	08 / 17	4.86 / 4.56
VAE-W-BO（样本加权，无迁移）	08	4.75
KT-ASO（VAE + 多保真迁移）	08	4.52
GAN-TO-EMFS（GAN + 梯度重参数化 + EMFS）	17	4.29

△ 对比须谨慎：论文 08 通篇用 BO 作优化器、论文 17 通篇用 EGO，且源样本构成略有差异，上表只能作为趋势参考，不是严格同条件对照。
体感换算：把关键数字换成「工程师的周/月」或「一次签字的风险」——数字才进长期记忆。若原文给了墙钟时间或成本比，优先用原文换算。

选型：有编码器→07；仅生成器/无标签点云→08。

6. 审稿人批判与承前启后
把软肋放上可信度刻度（0=完全不信，5=可当默认工具）：

维度	打分	人话
场景	5	
反推	3	
与07边界	4	
曲率	3	

可以攻击的点（其中涉及的设置与结论均出自原文 P17 § 4–§ 5）：

- 源任务与目标任务仍是"人为构造"的同构对（同一叶型、靠增大栅距制造高负荷），与论文 08 的构造完全相同。"源与目标差多远时迁移失效"这个最关键的问题，两篇都没有量化。
- 最优潜空间维度依赖预算。原文自己在结论里承认"如何高效找到生成模型的最优潜空间维度"仍需更多研究——d=5 只是本文预算下的结论。
- 梯度重参数化是逐样本的局部优化。 $\operatorname{argmin} \|G(z) - x\|^2$ 对非凸的 G 没有全局最优保证，且每个源样本都要单独跑一次梯度下降。
- GAN 的训练成本未被计入"节省的 50%"：4000 epochs、学习率调度、MMD 监控、模式崩溃风险——这些是实打实的工程开销。
- 仍是二维叶型优化，不涉及三维叶片与多学科约束。 [以上第 1–5 点均基于原文 P17 报告的方法设置与结果所作的合理质疑；其中"减少 50% 甚至更多"出自 P17 摘要与 § 4.4，d=5 的敏感性结论出自 § 4.5 与 § 5 结论(3)]

承前（本文是同组工作的集大成者）：

继承自	继承的内容
论文 08（KT-ASO / SW-VAE）	样本加权训练策略、多保真迁移的整体框架（把 VAE 换成 GAN）
论文 13（EMFS / MSFO）	多保真代理直接采用该文提出的 EMFS（含 DBSCAN 局部 SFS），见 GTO 参考文献 [36]
论文 06（GMFoO）	GAN 用于叶型参数化、潜空间优化的路线

本文的独特贡献：用梯度重参数化补上了 GAN 无法逆推断这一环，从而让生成质量更强的 GAN 也能用于迁移优化。
顺带成果：本文参考文献 [17] 提供了论文 14（VAE-NURBS 端壁参数化）的准确著录——C. Li, L. Song, Z. Guo, Z. Yang, J. Li, Z.

读高负荷改型结果的正确姿势：
先看是否在可制造约束内改善；再看相对无反推基线的增益。
若只有「外形更花」没有约束表，工程组应退回。摘要/全文数字以本讲 §5 原表为准，不在此处另造百分比。

附：选型树——07 还是 08？

有成对数据且编码器可用？
└─ 是 → 优先 07 (embed 稳、迁移工具链成熟)
└─ 否 → 只有 G / 点云 → 08 (梯度反推 z^*)
曲率/工艺约束是否进损失？
└─ 否 → 先补约束再优化 (否则 z^* 可能不可铣)

一句话：07 会编码；08 会爬坡。工具箱两把扳手都要会。

附：反推失败模式

现象	处理
距离不降	换 init z / 加步数
曲率爆炸	加大 κ 惩罚，承认目标形非法
可反推但 CFD 崩	光顺与网格门禁未过
与 07 结果差很远	检查是否该用编码器路线

图卡：编码器失踪案


07 讲有编码器；本讲现场更残——只剩生成器 G 与点云。GTO 用梯度把几何「吸」进潜空间得到 z^* ，硬算反推。



encoder missing GTO: 只有生成器 G，梯度反推 z^*

图卡：选型树 07 还是 08


有历史编码器 → 07 迁移路径；参数化失传只剩生成器 → 08 梯度反推 z^* 。选型先问「还剩什么映射」，再谈算法名词。



select 07 vs 08: 有编码器走 SW-VAE，只会生成走 GTO

图卡： z^* 爬坡六步

无编码器时，梯度把随机 z 一步步吸到匹配点云的 z^* 。六步不是魔法，是可重复的硬算工序。



zstar six steps: 梯度爬坡六步从随机 z 到 z^*

章末：30 秒复述 · 自测 · 元数据

30 秒复述稿（可朗读）：参数化失传时只剩点云。GTO 用生成器 G 与梯度把 x 吸成 z^* ，在潜空间再设计；曲率约束守可制造。07 有编码器可 embed，08 靠爬坡。工具箱两把扳手。

自测（先做再对答案）：

- 07 与 08 的关键差别是什么？什么场景必须上 08？
- z^* 在优化什么？曲率项为什么要进损失？
- 反推收敛但几何不可铣，说明值班手册缺了哪一步？

▼ 点开看参考答案

1. 07 有编码器可 embed；08 无编码器靠梯度反推。点云/失传参数化 → 08。2. 使 $G(z) \approx x$ ；曲率守可制造，防爬出非法形。3. 缺曲率/工艺惩罚或停损——距离降了不等于可生产。本讲元数据（读完再看，不挡故事）
| 项 | 值 | | :--- | :--- | | 规范编号 | 17 | | 原始文献 | Aerospace Science and Technology, 2026, 177: 112324 | | DOI | 10.1016/j.ast.2026.112324 | | 作者 | Fei Zeng (中国航发湖南动力机械研究所), Cunxi Li, Liming Song, Zhendong Guo (通讯) | | 本地原文 | 1-s2.0-S1270963826007042-main.pdf | | 证据等级 | A (本地原文逐句可查) |
【钉】命名：整体框架叫 GTO (Generative Transfer Optimization)；实验中把具体实现标为 GAN-TO，又分 GAN-TO-MFS (用 Co-kriging 多保真) 与 GAN-TO-EMFS (用集成加权多保真) 两个版本。| 反派绰号 | 参数化失传 || 主比喻 | 别人只留给你一堆坐标点的图纸 |

动手任务

任务：思考并回答：GAN 的潜空间为什么不能直接用 EI 优化？"梯度重参数化"解决了什么问题？写一个 200 字以内的简短解释，用"画家和鉴定师"的比喻。

产出文件：your_notes/experiments/L08_GAN潜空间分析.md

验收标准：文件存在且包含你对"反推"问题的解释

【AI】做完后：用 主动回忆 Prompt 做补漏，再用 批判收尾 Prompt 做深度加工。

沉淀清单

学完本讲，你应该产出以下文件：

- your_notes/knowledge_cards/L08_GTO.md — 知识卡片

- your_notes/experiments/L08_GAN潜空间分析.md — 动手任务记录
- 个人 Prompt 库中新增 ≥ 2 个 Prompt

【第09讲】VAE-NURBS 端壁参数化：把生成式参数化从叶型推广到非轴对称端壁（论文 14）

【靶】开讲前（5分钟）：用预习向导 Prompt 让 AI 帮你建立直觉框架，再开始读正文。

本讲开场 90 秒


上讲闪回：叶型生成后推到端壁：更脏、更3D、更易废。

本讲反派：「轴对称偷懒」

只要带走 3 句口诀：

1. 轴对称省事但挡不住通道涡
2. VAE提案+NURBS托底
3. 废品极多，生成式先滤合法

主比喻：端壁难捏的泥——轴对称挡不住横向流




第09讲心智图：合法 / 光顺 / 物理三关

看图三秒：VAE 提案、NURBS 托底、物理挡横流向；轴对称是偷懒。

本讲赌注：端壁参数化若不过三关，生成的是合法废品。

【补】读本讲前，你只需要先知道 3 件事（都出自 第零章 与 第零章 B · 四张补丁卡；忘了就点回去看一眼，不用背）：1. 端壁 = 叶片上下那两块壁面；二次流是那里损失的主要来源（卡③ B.3）2. NURBS = 只用少量控制点就能画出光顺曲线的工业标准表达（卡③）3. 潜空间 = 合法形状的压缩包（卡② B.2.4）

1. 生活与物理直觉引子：为什么端壁比叶型更难“捏形状”



axisym 轴对称假声明：看不见的二次流

指读：周向平均好看，通道涡不吃你的平均。

前面几讲一直在处理叶型（叶片的横截面）。现在换一个更麻烦的对象：端壁（endwall）——叶片根部所依附的那个环形壁面。

传统端壁是轴对称的：绕发动机轴线旋转一圈，形状处处一样，像一张被旋转扫掠出来的圆盘面。它便宜、好加工，但气动上并不好——因为流道里的压力分布是周向不均匀的：压力面一侧压力高、吸力面一侧压力低，气流会本能地从高压侧“横着”往低压侧跑，形成横向二次流，卷出马蹄涡、通道涡、角涡，造成损失。

非轴对称端壁造型（Non-axisymmetric Endwall Contouring, NEC）的做法是：把端壁做成周向起伏的三维曲面——压力高的一侧“鼓起来”——

点，压力低的一侧“凹下去”一点，用几何本身去抵消横向压力梯度。摘要第一句就把这一点当作已被证明的前提：NEC "has been proven effective in reducing the secondary losses of turbine cascades" [出版商页面 摘要]。

听起来很美，但工程上有一个硬骨头，摘要把它说成了一个三角权衡：样条类参数化在“设计空间维度”、“样本多样性”、“畸形几何比例”三者之间顾此失彼 [出版商页面 摘要]。想让形状够丰富，控制点就得多，维度就上去了；控制点多，随机组合出来的曲面里“长得不像端壁”的比例就飙升，白白浪费 CFD。

这正是第 06、07、08 讲那套生成式参数化要解决的同类问题——只不过对象从二维叶型换成了三维端壁。

为什么端壁更烦：

叶型是「一条曲线的艺术」；端壁是「一圈环面还要跟叶片根接上、还不能让二次流乱窜」。

设计空间里废品率极高——这就是 VAE 先学「什么算人样」、NURBS 层再保光顺的原因。

三层难：合法、敏感、可造。

先猜后揭：若本讲反派「轴对称偷懒」赢了，你的下一笔 CFD/实验预算会怎样被浪费？揭晓贯穿 §3–§5。

生活元素	工程元素	符号
主比喻侧	生成提案	VAE
主比喻侧	光顺层	NURBS
主比喻侧	轮毂/机匣	端壁

端壁更难捏：叶型有截面直觉；端壁缠着横向流与角区损失。轴对称等于假声明「周向无差异」。

端壁比叶型难捏的三层原因：

1. 三维壁面，缺少「中弧线」那种低维经典语言。
2. 横向流/通道涡/角区耦合，轴对称是假声明。
3. 废品率高：刀脊、对穿、陡坎随时出现。

所以 VAE 提案 + NURBS


托底，是「先合法再光顺」，不是「生成炫技」。

泥与刀：

端壁是泥（难捏），轴对称是偷懒刀法。

非轴对称不是为了「看起来高级」，是为了挡横流向。

2. 叶轮机械中的真实工程死穴：设计空间里绝大部分形状是“废品”




scrap museum 端壁废品三件展：刀脊对穿陡坎

指读：生成式要把概率质量挪出这三间展厅；NURBS 是出门安检。



three gates 端壁合法/光顺/物理三关

指读：VAE 过合法关，NURBS 过光顺关，物理关才挡得住横向流。



端壁设计空间的高维、窄流形与多参数化合流 (endwall harder, 手绘笔记版)

指读：这张图是本讲工程死穴的一张图版本。

把摘要的三角权衡翻译成设计师每天面对的三件事：

1. 维度高：三维光滑曲面若用 B 样条/NURBS 控制网格描述，设计变量轻易几十上百个；
2. 流形窄：在如此高维的空间里，“看起来像真实、可加工端壁”的形状只占极小一部分，绝大部分随机采样都是废品；
3. 评估贵：每个候选形状都要跑一次三维 RANS 才能知道好坏。

而且端壁参数化还有一个叶型没有的麻烦：同一个端壁可以被多种完全不同的参数化方法描述（正弦幅值×轴向包络、Bézier 控制网、直接的 B 样条曲面……），每种方法各有自己能表达和不能表达的形状。摘要给出的处理很有工程味：把一组经典 NEC 参数化方法各自生成的样本都收集起来，统一表示成散点坐标 (scatter coordinates)，拼成一个“覆盖充分”的设计空间 [出版商页面 摘要]。也就是说，训练数据不是靠一种参数化“撒网”得到的，而是几种参数化“合流”的产物——这样学到的低维流形不会被单一方法的表达能力锁死。

于是问题变成：能不能先学出一个“只生成合法端壁”的低维潜空间，再在这个潜空间里优化？——这就是本文标题所指的“生成模型参数化”。

现场感：周五下班前组长要数——你面对的不是可以慢慢推的练习题，而是算错一次就不可回收的预算。

废品率：随机控制点过陡、相交、不可铣。VAE

把概率放在曾合法区域；NURBS 托底光顺。

废品博物馆导览加长：

刀脊：曲率爆表，铣刀与网格双杀。

对穿：拓扑与叶片/圆角打架。

陡坎：看起来很「非轴对称」，分离与热斑一起爆。

VAE 把概率挪出展厅；NURBS 安检；物理关看横向流是否真被挡。


3. 数学公式：摘要给了骨架，细节不推导

【AI】卡壳？数学推导看不懂时，不要硬啃。把你的困惑发给 AI，用苏格拉底引导 Prompt。先自己想 5 分钟，再让 AI 一步步追问。

先把公式关掉，用主比喻说一遍：


端壁难推的泥——轴对称挡不住横向流

本讲反派是「轴对称偷懒」。下面公式是这句话的展开；每条核心式尽量带回译。知识总量不删——深潜只是阅读路径，不是垃圾桶。



VAE 解码器内嵌 NURBS 层保障光顺性 (vae nurbs layer, 手绘手账版)

VAE-NURBS 端壁参数化 (论文 14, 据出版商摘要)



端壁生成式参数化与内嵌 NURBS 层 (VAE NURBS endwall, 中文标注版)

上图是本讲全部数学的「一张图版本」(据出版商摘要示意, 正文未获取)：左图是压缩——多种经典 NEC 参数化方法的样本统一为散点坐标后，VAE 把端壁设计空间压进 9 个潜变量 [出版商页面 摘要]；右图是合法性保障——解码器内嵌一层 NURBS，没有它生成的型面可能畸形（红线），有了它才光顺（绿线）。

【禁】本文无全文，网络结构、损失函数、训练策略一概未获取，本讲不做任何推测性推导。以下只把摘要给出的三个“骨架事实”写清楚。

3B. 本讲符号卡（建议截图留存）

符号	人话	备注
VAE	生成提案	
NURBS	光顺层	
端壁	轮毂/机匣	

【引】先认符号再读公式；主文核心式有「回译」，装不下的细节仍在正文完整保留（不删知识）。【引】读不动时：本讲 §3 只需抓住核心式 + 它下面的「回译」；标【深潜 | 可跳过】的框可整框跳过，直奔 §4 值班手册——不影响你今天会用这套方法。

3C. 主路径公式与推导（知识全保留）

骨架一：生成模型是 VAE。摘要原话：“the Variational Autoencoder (VAE) is used to learn the intrinsic dimensions of the parameterized NEC design space” [出版商页面 摘要]。这与第 07 讲论文 08 的 SW-VAE 同属一族，而与第 08 讲论文 17 的 GAN 路线不同——旧版“GAN-Endwall”的错名很可能就是把 17 混进来了。

骨架二：光顺性靠结构约束，不靠事后过滤。摘要：“a layer of NURBS is incorporated into the neural network architecture of VAE” [出版商页面

摘要]。直觉上，解码器输出的不是裸的散点坐标，而是经过一层 NURBS 映射后的曲面——只要 NURBS 层在，输出天然就是光滑曲面，畸形几何在生成源头就被压掉。这一点和第 06 讲 GMFoO“生成后再筛”的思路形成对照。但 NURBS 层的节点向量、控制点数量、是否可训练，摘要一概没说，本讲不猜。

骨架三：潜空间维度为 9。摘要：“NEC parameterization ... with 9 variables” [出版商页面 摘要]。证据等级 B：仅摘要——不得把 9 拆成未给出的截面/控制点表；9 是优化用的潜变量个数（名义设计维），不是「9 个 CAD 控制点」。对比第 16 讲论文 03 手工 NEC 参数化的 13 个参数（优化 11 个） [原文 P03 §3.3]，9

维并非数量级的压缩——本文的卖点更在于这 9 维覆盖了多种参数化方法的并集，而不是把某一种方法压得更小。想看完整的数学骨架，请读有全文支撑的相邻讲次：

想理解的内容	请读
潜空间优化的基本框架、GAN/VAE 如何学出设计流形	第 06 讲（论文 06 GMFoO）
VAE 参数化 + 样本加权训练、多保真迁移	第 07 讲（论文 08 SW-VAE / KT-ASO）
梯度重参数化（把坐标点形状映射回潜空间）	第 08 讲（论文 17 GTO）
非轴对称端壁的气动原理与手工参数化（13 参数）	第 16 讲（论文 03 NAE-Purge）、第 17 讲（论文 09 NAE-Exp）

4. 算法控制流

【引】值班手册：先看「什么情况下走哪条分支」，公式是对白速记不是主角。

摘要只给了粗粒度流程，按原文顺序整理如下（每步都能在摘要中找到对应句子；步内细节未获取）：

- 1. 收集样本：用一组经典 NEC 参数化方法各自生成端壁样本 [出版商页面 摘要]；
- 2. 统一表示：把所有样本转换为统一格式的散点坐标，合并成一个设计空间 [出版商页面 摘要]；
- 3. 训练 VAE：学习该设计空间的内在维度（结果为 9 维），解码端含 NURBS 层 [出版商页面 摘要]；
- 4. 潜空间优化：以 9 个潜变量为设计变量做高压涡轮级 NEC 气动优化，并与其他 NEC 参数化方法做同样的优化作对比 [出版商页面 摘要]。

【禁】步骤 3 的损失函数（重构项 / KL 项权重）、步骤 4 用的优化器（EGO? DE?）与评估次数上限的具体值，均未获取。

一句话记住：轴对称省事但挡不住通道涡；进阶：VAE 提案+NURBS 托底。

主比喻回扣：把上面的分支再翻译成「端壁难捏的泥——轴对称挡不住横向流」——若某步在生活里说不通，多半是符号没对齐。

生成式端壁流水线（概念）：
VAE 提案（合法关）→ NURBS 托底（光顺关）→ CFD/指标（物理关）。
任一关失败都不得进入「可签字几何」库。

流水线门禁：
提案出门必须持「合法牌」；入 CFD 必须持「光顺牌」；入报告必须持「物理牌」。
缺牌者不得进入可签字库——这是配置管理，不是学术洁癖。

5. 实验验证与量化突破

先报胜负：
先读结论句与最大那一格，再读全表；表是证据架不是背诵清单。

△ 摘要只给定性结论，没有任何数字。本讲据此不列出任何百分比、降幅、CFD 次数。

摘要可确认的验证事实：

- 算例：一个高压涡轮级（high-pressure turbine stage）的非轴对称端壁气动优化 [出版商页面 摘要]；
- 对比对象："other NEC parameterization approaches"（具体哪几种、各自变量数未获取） [出版商页面 摘要]；
- 结论原话："the generative model based parameterization method can optimize aerodynamic performance more effectively while maintaining a lower limit on the number of performance evaluations" [出版商页面 摘要] ——即在更低的性能评估次数上限下取得更好的气动优化效果。

【删】再次明确：旧版白皮书 6.1 对比矩阵中"GAN-Endwall（2024）……消除九成畸变几何，设计空间极度紧凑"这一行属于无源填充，摘要亦不支持，继续从重建版删除。

体感换算：把关键数字换成「工程师的周/月」或「一次签字的风险」——数字才进长期记忆。若原文给了墙钟时间或成本比，优先用原文换算。

算。

桥到 16–17：本讲先合法参数化；风洞封口在后。

6. 审稿人批判与承前启后
把软肋放上可信度刻度（0=完全不信，5=可当默认工具）：

维度	打分	人话
问题	5	
骨架	4	
细节	2	
实验	3	

可以攻击的点（基于摘要即可提出）：

- 1. 收益未量化。与第 07、08 讲（有 Table 3/Table 4 硬数据）相比，本文公开摘要只有"more effectively"，读者无法判断"更有效"是 0.1 个百分点还是 1 个百分点。
- 2. 流形覆盖上限被训练集锁定。设计空间由既有参数化方法的样本"拼"成，VAE 学到的 9 维流形原则上只能覆盖这些方法能表达的形状的并集——若最优端壁不在任何一种经典方法的表达范围内，本方法会系统性漏掉它。摘要未讨论此风险。
- 3. NURBS 层的约束强度未知。"光顺"不等于"可加工"（还有最小曲率半径、与叶根倒圆的相容性等约束）；一句"a layer of NURBS"不足以判断可制造性是否被真正保证。
- 4. 会议论文篇幅有限。ASME Turbo Expo 论文通常单算例、无消融实验，这本身也是本讲只能到 B 级的成因。

承前：- 直接继承自论文 06（GMFoO）确立的"生成模型 + 潜空间优化"范式，以及论文 08（SW-VAE）的 VAE 参数化思路；- 应用对象（非轴对称端壁）承接论文 03（NAE-Purge）与论文 09（NAE-Exp）所研究的端壁气动问题。

启后：- 论文 17（GTO）在参考文献 [17] 中引用本文（这也是本仓库最初取得其著录的线索），并把"生成式参数化"推进为"生成式迁移优化"；- 与论文 10（FFD-Tip）共同构成"复杂三维几何的高效参数化"这一工程子方向：一个用生成模型，一个用自由变形（FFD）。

【附】升级路径：若能取得 GT2024-128792 全文 PDF，本讲可升级为 A 级证据，并补全：VAE 编码/解码结构、NURBS 层定义、训练样本数、对比的参数化方法清单、气动收益数值与评估次数上限。届时请先更新 corpus/facts/P14.md § 三/§ 五，再同步本讲。

读端壁生成结果的三问：

- 1. 合法率相对随机采样提升了多少（若原文有表，用表；无则只定性）？
- 2. 光顺后 CFD 网格是否还在「修洞」？
- 3. 横向流/角区指标有没有动——没有物理关，合法形只是博物馆藏品。

读生成端壁结果的验收序：
合法率 → 光顺/网格友好 → 横向流或角区指标是否动。
第三关不过，前两关只是「合法废品生产线」。

附：非轴对称端壁的「三关」

- 1. 合法关：不自交、不过陡、与叶片/通道拓扑兼容——VAE 提案。
- 2. 光顺关：可铣、可铸、网格好生成——NURBS 托底。
- 3. 物理关：真能改横向流与角区损失——最终要 16–17 的机理与实验。

反派轴对称偷懒的具体嘴脸：
图纸好看、网格好画、周向平均也「说得通」，可通道涡不吃你的平均。二次流是三维的，端壁却被降成二维旋转体——这是建模偷懒，不是物理结论。

和叶型生成的差别：
叶型有厚度、中弧线等经典语言；端壁更像「地形塑形」。废品率更高，所以生成式过滤合法形的价值更大。

附：端壁参数化选型会（15 分钟版）
议程三问：

1. 我们有没有成对的「合法端壁」数据？
2. 有 → VAE/生成式可以学流形；
无 → 先别幻想端到端生成，用 NURBS/FFD 加硬约束更稳。
- 废品率现在多少？
- 随机抽样里非法/过陡/干涉占比若非法/过陡/干涉占比已经高到「随机抽样经常中招」，生成式过滤的价值立刻超过「多几个控制点」。
- 下游谁接盘？
3. 只要 CFD：光顺与网格友好优先；
4. 要进 16-17 的机理与实验：几何幅度必须落在可加工公差。
- 轴对称偷懒的三种伪装：

伪装	听起来很对	物理上错在哪
「周向平均够了」	通流设计常用	二次流是三维的
「网格好画」	项目经理喜欢	好画 ≠ 流场对
「以前型号也轴对称」	经验	负荷一变，经验过期

三关检查单（合法 / 光顺 / 物理）
过两关不够：没有物理关，参数化只是「合法废品生成器」。

附：端壁「废品博物馆」（概念展板）
进馆三件展品（均为非法/高风险形，生成式要学会避开）：

1. 刀脊：局部曲率爆表，铣刀抬不起头，CFD 网格先哭。
2. 对穿：端壁与叶片/圆角拓扑打架。
3. 陡坎：
看起来「很非轴对称」，横向流被猛打，但分离与热斑一起爆。

VAE
的价值不是「更花哨」，是把概率质量从这三间展厅挪走；NURBS 是出门安检。


附：轴对称偷懒的三个伪装（再钉）
周向平均够了 / 网格好画 / 以前型号也这样。
三条都能通过项目经理，三条都可能在二次流上破产。

附：非轴对称端壁评审看板

关卡	绿	黄	红
合法	自交/干涉≈0	偶发可修	频发
光顺	网格一次过	需手工修	无法出网
物理	横向流/角区指标改善	持平	恶化


黄灯可带风险继续；红灯禁止入详设库。轴对称「省事」若物理红灯，仍算偷懒。

图卡：VAE 内嵌 NURBS
潜码经解码器后过 NURBS 层，输出端壁默认合法/光顺/可加工；刀脊、对穿、陡坎进废品堆。生成式参数化的物理保险丝。




NURBS embed VAE：解码器内嵌光顺层过合法三关

图卡：端壁废品三件展
刀脊、对穿、陡坎三件进博物馆；出口是合法·光顺·物理三关。生成式端壁的第一课是认识废品。



图卡：三关闸机
端壁几何必须连过合法、光顺、物理三关；任一失败进废品堆。NURBS 层是光顺闸机的机械装置。



章末：30 秒复述 · 自测 · 元数据
30 秒复述稿（可朗读）：端壁比叶型难捏。VAE 提案、NURBS 光顺、物理挡横向流，三关都过才算数。轴对称是偷懒假声明，不是物理最优。

自测（先做再对答案）：

1. 轴对称代价？
2. NURBS？
3. 废品？

▼ 点开看参考答案

1. 二次流/角区损失。2. 光顺可造。3. 随机型面大量非法。本讲元数据（读完再看，不挡故事） | 项 | 值 | | :--- | :--- | | 规范编号 | 14 | | 原始文献 | ASME Turbo Expo 2024 (GT2024, London, UK, 2024-06-24~28) , Vol. 12D, 论文号 GT2024-128792, 文章号 V12DT34A025 | | 作者 | Cunxi Li, Liming Song, Zhendong Guo, Zhao Yang, Jun Li, Zhenping Feng (郭老师列第三) | | DOI | 10.1115/GT2024-128792 (Crossref 2026-09-06 核验；在线 2024-08-28) | | 本地原文 | 无 (出版商摘要已获取；正文/图表需订阅) | | 证据等级 | B (权威著录 + 摘要全文可查；正文方法细节与数值未获取) |

△ 本讲的写作边界（务必先读） 本文没有本地全文。可核验的信息 = Crossref 著录 + 出版商页面摘要（逐字存于 corpus/web_evidence/P14.md）。因此本讲：✓ 只写摘要明确给出的方法定位、模型类型、变量数、验证对象与定性结论；✗ 不写任何百分比、损失降幅、CFD 次数、网络层数、损失函数——这些摘要没有。

【删】 两轮纠错记录（都保留，便于审计）：① 旧版白皮书把本文称作 "GAN-Endwall"，并写入 "消除九成以上的无效几何生成"——GAN 是错的，九成是编的。② 上一轮重建版虽删掉了数字，却又写成 "DOI 未检索到、摘要未获取、证据等级 C"——这也是错的：Crossref 按题名一查即中，摘要公开。摘要显示模型是 VAE + NURBS 层。本讲据此重写，标题代号改为 VAE-NURBS。 | 反派绰号 | 轴对称偷懒 | | 主比喻 | 端壁比叶型更难捏 |

动手任务

任务：思考并回答：VAE-NURBS 把端壁参数化从 200+ 维压到 9 维。这 9 个变量代表什么物理含义？它们和传统的控制点参数化有什么本质区别？写一个 200 字以内的分析。

产出文件：your_notes/experiments/L09_端壁参数化分析.md

验收标准：文件存在且包含你对潜空间变量物理含义的分析

【AI】做完后：用 主动回忆 Prompt 做补漏，再用 批判收尾 Prompt 做深度加工。

沉淀清单

学完本讲，你应该产出以下文件：

- ☐ your_notes/knowledge_cards/L09_VAE_NURBS.md — 知识卡片
 - ☐ your_notes/experiments/L09_端壁参数化分析.md — 动手任务记录
 - ☐ 个人 Prompt 库中新增 ≥ 2 个 Prompt
-